

重庆大学本科生毕业论文（设计）

基于深度学习的颅内动脉瘤检测与破裂风险 预测系统



学 生： 申建松

学 号： 20221556

指导教师： 文静

专 业： 计算机科学与技术

重庆大学计算机学院

2026 年 6 月

Undergraduate Thesis (Design) of Chongqing University

**Deep Learning-Based Intracranial
Aneurysm Detection and Rupture Risk
Prediction System**



By

SHEN Jiansong

Supervised by

Assoc. Prof. WEN Jing

and

Computer Science and Technology

College of Computer Science, Chongqing University

Chongqing University

June, 2026

摘 要

颅内动脉瘤是一种常见的脑血管异常，破裂后可引起蛛网膜下腔出血，危险性较高。CTA 能较清楚地显示载瘤血管和瘤体形态，但由于切片多、分叉复杂且存在骨伪影，人工阅片仍可能出现漏检或判断不一致。动脉瘤破裂风险又同时受到年龄、基础病、瘤体形态和位置等多种因素影响，单纯依靠传统量表或统计模型，往往难以全面刻画这些变量之间的非线性关系。因此，研究一种能够从影像中稳定分割动脉瘤，并结合临床信息进行风险分层的辅助方法，具有实际应用价值。

针对这一需求，本文在毕业设计阶段实现了两条可复现的技术路线。首先，在分割任务中采用三维 Attention U-Net。该模型保留了 U-Net 的多尺度跳跃连接，并在解码端加入注意力门控，对来自编码器的特征进行筛选，使网络在大量背景体素中更关注疑似瘤体区域。训练时采用病例级流式加载和三维补丁采样，并结合重采样与强度归一化，以便在有限显存下处理大体积 CTA 数据；损失函数由二元交叉熵和 Dice 损失组合而成，用于同时兼顾分类准确性和区域重叠度。推理时，模型对整例数据分块预测，再将结果拼接回原始空间，便于后续使用。

其次，在破裂风险预测任务中，本文面向表格型临床和影像衍生特征，构建基于交叉注意力的深度表格模型：数值与类别字段分别映射到统一隐空间，经多层交叉注意力融合后由多层感知机输出破裂概率。数据处理包括缺失值填补、低频类别合并、特征筛选，以及面向类别不平衡的加权损失与验证集阈值优选。

整体实现以配置驱动方式串联分割与风险两条流程，并提供简易交互界面，支撑从体数据读入到辅助分析演示的闭环。受数据脱敏与伦理审批进度限制，分割定量指标需结合具体实验设置解读；风险预测在正文给出固定划分下与传统方法的一次离线对比，尚不构成多中心外部验证结论。

关键词：颅内动脉瘤；CTA；三维分割；Attention U-Net；表格学习；交叉注意力；破裂风险预测

ABSTRACT

Intracranial aneurysms are a common cerebrovascular abnormality. If they rupture, they can cause subarachnoid hemorrhage and lead to serious outcomes. CTA can show the parent vessel and aneurysm shape clearly before treatment, but the full image series is large, and vessel bifurcations and bone artifacts make manual reading difficult. Rupture risk is also influenced by multiple factors such as age, comorbidities, aneurysm shape, and location, so traditional scores or simple statistical models often fail to capture the nonlinear relations among mixed data types. For this reason, a computer-aided method that can segment aneurysms from vascular images and stratify risk using clinical features is practically valuable.

To address this problem, this thesis implements two reproducible pipelines. First, for segmentation, a 3D Attention U-Net is used. The model keeps the multi-scale skip connections of U-Net and adds attention gates in the decoder to filter encoder features, helping the network focus on likely aneurysm regions in CTA volumes dominated by background voxels. Training uses case-wise streaming and 3D patch sampling, together with spacing resampling and intensity normalization, so that large CTA volumes can be processed with limited GPU memory. The loss combines binary cross-entropy and Dice loss to balance classification accuracy and region overlap. During inference, the full volume is predicted patch by patch and then stitched back into the original space for later use.

Second, for rupture-risk prediction, this thesis builds a cross-attention-based deep tabular model for clinical and imaging-derived features. Numeric and categorical fields are mapped into a shared latent space, fused through stacked cross-attention blocks, and passed to an MLP head for rupture probability. The pipeline includes missing-value imputation, rare-category grouping, feature selection, class-frequency-weighted loss, and validation-set threshold tuning to mitigate imbalance.

The implementation is configuration-driven for both branches and includes a lightweight web interface for volume upload and an end-to-end auxiliary-analysis demonstration. The data are de-identified and ethics review is ongoing, so quantitative segmentation should be read with the experimental setup in mind; the main text reports one offline comparison of the deep risk model with classical baselines on a fixed split, which is not a multi-center external validation.

Key words: intracranial aneurysm; CTA; 3D segmentation; Attention U-Net; tabular

learning; cross-attention; rupture risk prediction

目 录

摘要.....	I
ABSTRACT.....	II
1 绪论.....	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 动脉瘤与脑血管影像分析的传统途径	2
1.2.2 基于深度学习的分割与多模态预测	2
1.3 本文面临的问题与主要思路	2
1.4 课题来源与研究内容	3
1.5 论文结构安排	3
1.6 本章小结	3
2 相关理论基础.....	5
2.1 脑动脉瘤及分割基本原理	5
2.2 医学图像分割基本理论	5
2.3 卷积神经网络与 U-Net 结构	6
2.4 注意力机制与 Attention U-Net	6
2.5 类别不平衡与损失函数设计	6
2.6 表格数据学习与特征表示理论	7
2.7 临床风险评分与深度模型的互补关系	7
2.8 评价指标基础	8
2.9 本章小结	8
3 模型设计.....	9
3.1 系统总体架构	9
3.2 相关理论简述	9
3.2.1 全卷积分割与区域型损失	9
3.2.2 注意力门控跳跃连接	9
3.3 动脉瘤分割模块设计	10
3.3.1 数据组织与流式补丁采样	10
3.3.2 网络结构与输出层	10
3.3.3 损失函数与优化策略	10
3.3.4 检查点与整例推理重建	11
3.4 破裂风险预测模块设计	11

3.4.1	表格数据构建与预处理	11
3.4.2	RiskCrossAttentionModel 结构	11
3.4.3	损失函数、类别加权与阈值搜索	12
3.5	Web 服务与端到端演示	12
3.6	本章小结	12
4	实验与结果分析	13
4.1	实验设置	13
4.1.1	硬件与软件环境	13
4.1.2	评估指标	13
4.2	动脉瘤分割实验结果	13
4.2.1	训练与验证过程	13
4.2.2	结果分析（基于真实评估报告）	13
4.2.3	可视化与误差来源	14
4.3	破裂风险预测实验结果	14
4.3.1	模型表现	14
4.3.2	与传统基线对比	14
4.4	系统联调与闭环验证	14
4.5	本章小结	15
5	总结与展望	16
5.1	工作总结	16
5.2	主要结论	16
5.3	不足分析	16
5.4	未来展望	16
5.5	结束语	17
	参考文献	18
	附录 A：关键配置与复现实验步骤	21
	附录 A：关键配置与复现实验步骤	21
	致谢	23
	原创性声明和使用授权书	24

1 绪论

1.1 研究背景与意义

脑血管疾病在我国居民死因构成中长期居于前列，其中颅内动脉瘤（Intracranial Aneurysm, IA）可在无症状阶段经影像学检查偶然发现；一旦瘤壁完整性被破坏导致蛛网膜下腔出血（Subarachnoid Hemorrhage, SAH），病情往往凶险，遗留神经功能障碍的比例亦不容忽视。数字减影血管造影（DSA）被视为诊断“金标准”，但其有创性与费用限制了大规模筛查场景的普及。CT 血管成像（CT Angiography, CTA）无创、可及性高，已成为门诊与急诊情境下动脉瘤检出与术前评估的重要工具^[1,2]。

然而，临床实际工作中仍存在三方面痛点。其一，单次检查所产生的轴位切片可达数百层，医生需在三维空间中追踪迂曲血管并辨别微小隆起，长时间阅片易引起视觉疲劳与漏诊。其二，不同扫描协议、重建层厚与对比剂充盈程度会造成图像对比度与噪声水平的差异，同一算法在不同硬件条件下的稳定性面临考验。其三，是否建议干预不仅取决于“有没有瘤”，还与瘤体大小、形态不规则度、位置、患者年龄及合并症等因素耦合；现有临床管理往往还需参考 PHASES、ELAPSS 以及日本 UCAS 等研究所揭示的自然病程与增长风险规律^[3-6]。因此，若仅依赖分割掩膜而缺少风险分层，仍难以直接支撑个体化随访问隔或手术决策。

近年来，深度学习在医学影像分割任务上取得了令人瞩目的进展。全卷积网络与 U-Net 族结构能够在像素级输出病灶概率图，显著缩短标注辅助时间^[7,8]；三维卷积网络可直接建模沿血管走向的上下文信息，有利于保持瘤体在层间的连续性^[9,10]。Attention U-Net 在解码路径上对跳跃连接施加门控，使网络更关注与任务相关的空间区域，已在腹部脏器、胰腺等分割中得到验证^[11]。nnU-Net 的成功进一步说明，在医学分割中，网络骨架之外的数据预处理、补丁采样与后处理同样是性能的重要决定因素^[12]。在脑血管领域，已有工作尝试将粗定位与细分割结合，或利用多尺度三维卷积提升细小病灶检出率^[1,2,13]。与此同时，面向卒中结局或动脉瘤临床结局的多任务网络也开始出现，提示“影像 + 临床”联合建模的重要性^[14,15]。在表格学习方向，TabTransformer 与 FT-Transformer 等模型证明了注意力机制不仅适用于视觉特征建模，也适用于异构临床字段之间的上下文交互建模，为风险预测模块的设计提供了方法学参考^[16,17]。

在此背景下，本文依托课程设计任务，围绕“动脉瘤的自动分割定位”与“破裂风险的概率预测”两个相互衔接的子问题，实现一套以配置文件驱动、脚本可复现为特征的软件系统。该系统一方面减轻医师在体数据层面的重复勾画负担，另一方面为后续将影像组学特征或形态学参数与表型数据融合提供工程接口，具有

明确的辅助诊疗价值与教学演示意义。

1.2 国内外研究现状

1.2.1 动脉瘤与脑血管影像分析的传统途径

在深度学习普及之前，血管分割与病灶提取多采用基于强度的阈值分割、区域生长、水平集或基于几何先验的滤波器响应等方法。此类流程往往需要人工调节种子点、平滑核大小或曲率约束，且对低对比度瘤颈、邻近骨质高密度灶等干扰敏感，跨中心推广时常需重新调参。面向风险评估，临床多采用 Hunt-Hess 分级、WFNS 评分、PHASES 评分或 ELAPSS 评分等规则体系，其中 PHASES 侧重未破裂动脉瘤未来破裂风险，ELAPSS 更强调增长风险预测^[3,4]。这些评分简洁、可解释，便于临床沟通，但对瘤体形态不规则、局部血流动力学、影像纹理和多字段非线性交互的刻画能力有限。统计学习阶段则常见逻辑回归、随机森林等浅层模型；它们在变量个数较少、线性可分性较强的回顾性队列上可给出可解释结果，但对高维异构特征的自适应组合能力有限。

1.2.2 基于深度学习的分割与多模态预测

随着公开数据集与算力条件改善，U-Net 及其三维变体逐渐成为血管与病灶分割的主流骨架^[7,9]。nnU-Net 等工作进一步强调预处理、网络拓扑与后处理的自动化配置，提升了跨任务迁移的效率^[12]。针对颅内动脉瘤，研究者探索了从血管分割到瘤体检测的多阶段流程，或引入注意力与多尺度模块以强调细小结构^[1,2]。在预测层面，Transformer 与注意力机制为序列化或多模态特征融合提供了统一接口^[18]；StrokeNet 等多任务结构尝试同时编码影像与临床信息以预测卒中结局^[14]。这些工作表明：分割精度与下游临床推理并非割裂——高质量掩膜既可直接用于手术规划，也可作为体积、曲率等衍生特征的载体。

1.3 本文面临的问题与主要思路

综合文献与工程经验，本文将任务难点概括为三点。（1）**体数据占用与显存矛盾**：完整 CTA 体积可达数百兆字节以上，若一次性加载多病例批次，普通 GPU 难以承受；需要在“流式 IO—补丁采样—梯度更新”之间取得平衡。（2）**前景极度稀疏**：动脉瘤体素在整幅体积中占比极低，单纯交叉熵易使模型偏向预测背景；需要区域重叠型损失与采样策略共同约束。（3）**风险标签与特征异质性**：破裂与未破裂病例分布不均衡，类别字段存在长尾取值；需要合理的加权损失、阈值搜索与特征筛选，避免过拟合于训练集噪声。

针对上述难点，本文采用“分割骨干+表格风险头”的系统级方案：分割侧选

用三维 Attention U-Net，配合病例级流式训练与前景优先补丁采样；风险侧使用基于交叉注意力的表格模型，统一处理数值与类别特征，并在验证集上搜索决策阈值。

1.4 课题来源与研究内容

本课题来源于指导教师下达的毕业设计任务书，目标是对颅内动脉瘤 CTA 数据进行计算机辅助检测，并在临床表型与影像衍生特征基础上完成破裂风险的二分类预测。结合仓库实现，本文工作具体包括：

1. 基于 AttentionUnet 实现三维分割网络，完成编码器—解码器通道配置、注意力门控与 sigmoid 输出的端到端前向；
2. 在 MedicalPatchDataset 上实现多目录数据扫描、重采样、标准化及前景优先/顺序采样策略，支撑低显存条件下的长时间训练；
3. 基于 Dice/Tversky/Focal 与 BCE 的组合损失、Adam/AdamW/SGD 与余弦退火等配置化优化流程，训练过程写入 TensorBoard，并按间隔保存 latest.pth 与验证集最优 best.pth；
4. 推理阶段将补丁结果拼接为完整体积，恢复 spacing、origin、direction，输出概率体与二值掩膜供可视化或形态学特征提取；
5. 构建表格风险数据的清洗、互信息特征筛选、加权 BCE 训练、验证集 F1 最优阈值搜索及测试集报告导出（risk_report.json）；
6. 提供 FastAPI 交互界面，串联上传、分割与风险预测演示流程。

1.5 论文结构安排

全文共分五章。第一章介绍研究背景、国内外现状、问题难点与研究内容。第二章梳理医学图像分割、三维卷积网络、注意力机制、类别不平衡学习及表格建模等相关理论基础。第三章从系统架构出发，分述分割模块、风险模块的模型设计与实现要点，并简要说明 Web 服务接口。第四章介绍实验环境、数据集与预处理约定、评价指标与结果分析框架，说明如何根据日志与配置文件复现指标。第五章总结全文并展望未来改进方向。

1.6 本章小结

本章从临床需求与技术趋势两方面阐述了颅内动脉瘤辅助分析的研究动机，综述了传统方法与深度学习方法的优劣，归纳了本文面向的三个核心难点及对应思

路，并列出了源代码模块对应的研究内容。后续章节将展开算法与系统实现的细节。

2 相关理论基础

2.1 脑动脉瘤及分割基本原理

脑动脉瘤是指脑血管壁局部异常膨出所形成的囊状或梭形结构，最常发生于脑底部的 Willis 环及其主要分支。在 CTA 图像中，脑动脉瘤的主要表现为血管壁的局部囊状突出，呈现为“气球样”或“浆果样”的异常膨出结构。

其中，瘤颈（neck）是指动脉瘤与载瘤动脉之间的连接部位，其宽度和形态对治疗方案的选择具有重要意义。




图 2.1 实际脑动脉瘤 CTA 影像示例

如图所示，红色箭头指示区域中，上方血管轮廓相对正常，而下方箭头所指位置可见血管突然异常膨大，呈现典型的脑动脉瘤病灶特征。

2.2 医学图像分割基本理论

医学图像分割旨在像素或体素层面实现对目标解剖结构的精确定位，本质上属于密集预测（dense prediction）任务。与自然图像分割不同，CTA 体数据具有三维空间连续性、前景占比极低以及病灶形态变异大等特点。因此，模型不仅需要捕捉局部边缘与纹理信息，还必须维持跨层面的空间一致性。该研究范式已在医学影像深度学习综述中得到系统论证^[19-21]。

对于颅内动脉瘤分割任务而言，精确的分割结果既能为临床提供直观的可视化依据，也可进一步计算瘤体体积、最大径、形态不规则度等量化指标，成为后续破裂风险评估的重要基础。

在经典监督学习框架下，训练样本由输入图像 X 和金标准标签 Y 构成，模型的目标是学习从 X 到 Y 的映射函数 $f_{\theta}(X)$ 。由于医学图像标注成本高、类别分布极度不平衡以及成像条件复杂，实际训练中需在网络结构、损失函数和采样策略上进行协同设计，以平衡模型的表达能力和训练稳定性。

2.3 卷积神经网络与 U-Net 结构

卷积神经网络（CNN）通过局部感受野、权值共享和层次化特征提取，在医学图像分析中得到广泛应用。对于分割任务，Fully Convolutional Network（FCN）首次将分类网络扩展至像素级预测，实现端到端的密集输出^[8]。U-Net 则在此基础上引入对称的编码器-解码器结构和跳跃连接（skip connection），有效融合浅层细节信息与深层语义信息，显著提升了医学图像分割性能^[7]。

鉴于三维医学图像具有较强的层间连续性，3D U-Net 将二维卷积替换为三维卷积和三维上采样，能够同时建模切片内与切片间的空间上下文关系^[9,22]。在后续工作中，V-Net、UNet++ 与 nnU-Net 分别从体素级残差建模、跳跃连接重设计和自动化配置等角度进一步提升了医学分割性能^[10,12,23]。然而，三维卷积也带来了更高的计算和显存开销，因此实际应用中常采用补丁训练（patch-based training）、流式加载及混合精度训练等策略进行优化。

2.4 注意力机制与 Attention U-Net

注意力机制的核心在于使模型能够自适应地聚焦于与当前任务最相关的特征区域。对于体积小、背景血管复杂的颅内动脉瘤分割任务，若直接拼接所有跳跃连接特征，易将大量无关背景响应传递至解码器，增加误分割风险。Attention U-Net 在跳跃连接处引入注意力门控（Attention Gate）模块，对编码器特征进行筛选，使解码器更关注目标相关区域^[11]。

从实现机制来看，注意力门控通过将解码器特征与同尺度编码器特征进行联合映射，生成空间权重图，再对编码器特征进行加权。这一过程可视为空间相关性筛选：当某位置更可能属于动脉瘤或邻近血管时，权重被提升；反之则被抑制。该机制在减少背景干扰的同时，较好地保留了 U-Net 对局部边界细节的敏感性。

2.5 类别不平衡与损失函数设计

颅内动脉瘤在 CTA 体数据中通常仅占极小比例，属于典型的极度类别不平衡问题。若仅采用标准交叉熵损失，模型容易陷入“全部预测为背景”的平凡解，导致整体准确率虚高而病灶检出能力不足。因此，需要引入侧重前景区域重叠的损失函数。

本项目当前实现并未直接采用 Dice+BCE 作为训练损失，而是在二元交叉熵（BCE）的基础上，根据配置选择 Tversky 损失或 Focal 损失作为形状/难例约束项^[24-26]。Tversky 损失可视为 Dice 损失在假阳性与假阴性惩罚权重上的推广，其定义如下：

$$\mathcal{L}_{\text{Tversky}} = 1 - \frac{TP + \epsilon}{TP + \alpha FP + \beta FN + \epsilon}, \quad (2.1)$$

其中 TP 、 FP 、 FN 分别表示软预测意义下的真阳性、假阳性和假阴性， α 与 β 控制两类错误的权重， ϵ 为平滑系数。配置默认采用 `tversky_bce`，即 $\mathcal{L} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Tversky}}$ ；若选择 `focal_bce`，则使用 Focal 项替代 Tversky 项，以强化难分类体素对梯度的贡献。验证阶段仍计算 Dice 系数作为主要分割重叠指标。

对于后续的动脉瘤破裂风险预测任务，由于正负样本同样存在不平衡，通常需采用正类加权或基于验证集的阈值优化策略，以提升模型对少数类（破裂组）的敏感性。

2.6 表格数据学习与特征表示理论

除影像数据外，临床信息、人口统计学特征及既往病史等多以结构化表格形式存在。传统机器学习方法（如逻辑回归、随机森林）在特征维度较低时表现良好，但在高维混合特征（数值型 + 类别型）且存在复杂非线性交互时，表达能力受限。

近年来，深度表格学习借鉴 NLP 中的 Token 化思想，将每个特征字段映射为统一维度的隐向量，再通过注意力机制建模字段间的交互关系。TabTransformer 利用上下文嵌入增强类别变量表达，FT-Transformer 则进一步验证了对数值字段进行 token 化并使用 Transformer 编码的有效性^[16,17]。该类方法无需人工构造高阶交叉特征，且能统一处理连续与离散变量，为多模态融合提供了灵活高效的特征表示空间。本文的风险预测模块即基于这一思路构建；同时，传统集成学习方法如随机森林和梯度提升树仍是小样本表格任务中的重要比较基线^[27-29]。

2.7 临床风险评分与深度模型的互补关系

未破裂颅内动脉瘤的管理并非单纯的图像分割问题。PHASES 评分综合人群来源、高血压、年龄、动脉瘤大小、既往蛛网膜下腔出血史和部位等因素，用于估计未来破裂风险^[3]；ELAPSS 评分则将年龄、部位、大小、形态和既往蛛网膜下腔出血等因素纳入未破裂动脉瘤增长风险预测^[4]。此外，大规模自然病程队列研究也提示，不同部位、不同直径和形态不规则程度的动脉瘤具有不同的破裂倾向^[5,6]。

上述评分体系具有解释性强、使用门槛低的优点，但其变量项相对固定，难以充分吸收三维分割衍生出的体积、表面不规则度、瘤颈宽度、影像组学纹理等高维

信息。深度学习模型则可在数据充分且划分严格的前提下学习非线性交互，但也存在可解释性不足、外部验证不足和校准性不稳定等问题。因此，本文将风险预测定位为辅助性概率估计：既参考经典风险因素，也通过表格注意力模型探索字段间潜在联系，并在实验章节强调验证集阈值搜索与数据泄漏防护。

2.8 评价指标基础

分割任务与分类任务的评价侧重点不同。分割任务常用 Dice 系数、敏感度 (Sensitivity)、特异度 (Specificity)、Hausdorff 距离等指标，其中 Dice 系数重点衡量预测区域与真实区域的重叠程度。分类与风险预测任务则常用准确率、精确率、召回率、F1 值以及 AUC-ROC 等指标。AUC 反映模型整体排序能力，F1 值则在不平衡场景下更能综合体现精确率与召回率的平衡。

针对极度稀疏的医学分割任务，单纯依赖总体准确率易产生误导。因此，本文在实验中同时报告 Dice 系数、体素级 F1、多阈值统计结果及基于直方图近似的 voxel-wise AUC，以实现模型性能的全面评估；对于不平衡二分类场景，PR 曲线与校准分析同样具有重要参考价值^[30-33]。

2.9 本章小结

本章系统概述了本文研究所需的核心理论基础，包括脑动脉瘤的影像学表现、三维医学图像分割基本问题、U-Net 及其注意力变体、类别不平衡下的损失函数设计、表格数据深度表征方法，以及相关评价指标体系。这些理论为后续章节的模型设计、优化策略与实验分析提供了坚实的理论支撑。

3 模型设计

3.1 系统总体架构

本文构建的系统围绕两项相互衔接的任务展开：其一是基于 CTA 体数据的动脉瘤分割，其二是基于临床与影像表型信息的破裂风险预测。整体流程遵循“影像分析—特征汇聚—风险建模”的思路：首先对原始 CTA 体数据进行空间归一化与强度规范化，随后通过三维分割模型定位病灶并生成概率图与掩膜；在此基础上，进一步结合分割结果、形态学信息及临床表格数据构建风险预测所需的结构化特征表示，最终输出破裂风险概率并通过验证集完成判别阈值的确定。

从系统设计角度看，分割模块承担病灶定位与结构量化的基础任务，风险模块则在多源信息融合的基础上实现患者层面的风险评估。二者共同形成一个由像素级识别向病例级决策延伸的处理链条，体现了医学影像智能分析中“局部表征—全局判断”的典型范式。

3.2 相关理论简述

3.2.1 全卷积分割与区域型损失

全卷积结构将分类网络中的全连接层替换为卷积层，使网络可直接输出与输入同分辨率的空间概率图^[7,8]。对于动脉瘤这类前景体素占比极小的任务，仅在像素级优化交叉熵往往导致预测偏向背景。Dice 系数衡量预测区域与标注区域的重叠程度，验证阶段仍以 Dice 作为主要重叠指标。训练实现则采用 BCE 与 Tversky/Focal 项组合的方式^[24-26]，其中 Tversky 项可通过 α 与 β 分别调节假阳性和假阴性的惩罚权重，更适合漏检代价较高的小病灶分割场景。

3.2.2 注意力门控跳跃连接

标准 U-Net 将编码器特征直接与解码器特征拼接，可能引入大量与病灶无关的背景响应。Attention U-Net 在每次上采样后与跳跃特征融合前，引入门控图对跳跃特征进行逐元素加权^[11]。设 g 为解码器当前分辨率下的特征图， s 为同尺度跳跃特征，门控权重的计算可概括为：

$$a = \sigma(\psi(\text{ReLU}(W_g(g) + W_s(s)))) \quad (3.1)$$

$$\hat{s} = a \odot s \quad (3.2)$$

其中 W_g 、 W_s 为 $1 \times 1 \times 1$ 卷积与归一化组成的线性投影， ψ 将通道压缩为单通道并经 Sigmoid 得到 a ， $\odot$ 为逐元素乘法， σ 与实现中的 Sigmoid 一致。解码器最终接收的是经过滤波的 $\hat{s}$ 与上采样特征拼接后的张量。本项目在 UpSampleBlock 中调

用 AttentionGate 实现上述过程。

3.3 动脉瘤分割模块设计

3.3.1 数据组织与流式补丁采样

三维 CTA 体数据具有体积大、结构细粒度强、前景占比低等特点，因此分割模块更适合采用面向病例的流式处理思路。本文在数据组织上强调统一的空间重采样、强度规范化以及基于补丁的局部学习机制，使模型能够在有限显存条件下充分利用全体积信息，同时保持对病灶边界的敏感性。训练阶段通过偏向前景区的补丁采样提升病灶可见性，验证与推理阶段则采用覆盖式滑窗策略，以保证整例体数据的系统性评估。

为缓解小目标分割中常见的类别不平衡问题，数据采样策略在设计上兼顾了前景补充与背景约束：前者有助于提升模型对动脉瘤体素的识别能力，后者则用于维持对血管周围组织和复杂解剖背景的区分能力。总体而言，该模块的设计目标不是单纯追求高吞吐量的数据读取，而是在医学影像分割任务的约束下实现稳定、可控且具有病灶针对性的训练数据供给。

3.3.2 网络结构与输出层

本文采用的三维 Attention U-Net 保留了编码器—解码器与跳跃连接的主干结构，同时在特征融合阶段引入注意力门控，以增强对关键病灶区域的响应并抑制无关背景信息。编码器负责提取多尺度上下文表示，解码器则逐级恢复空间分辨率；在这一过程中，跳跃连接并非简单拼接，而是经过选择性加权后再与高层语义特征融合，从而提升模型对小体积病灶的聚焦能力。输出阶段通过逐点映射得到体素级类别概率，为后续阈值化与定量分析提供基础。

3.3.3 损失函数与优化策略

模型训练以兼顾像素级分类准确性与区域级重叠质量为目标，因而在目标函数设计上同时考虑了逐体素误差与结构一致性约束。除二元交叉熵外，本文进一步引入适合小目标分割的重叠类损失，以缓解前景稀疏所带来的类别不平衡问题，并提高模型对漏检区域的敏感性。整体而言，该损失设计的核心思想是：既要保证分割结果在局部体素层面具有可靠判别性，也要在整体形态上保持与标注区域的一致。

优化过程采用常规深度学习训练范式，通过自适应优化器与学习率调度机制提升收敛稳定性，并结合验证集上的重叠指标对模型进行选择。训练过程中同步记录损失与性能曲线，有助于分析模型在不同阶段的学习状态；同时，通过周期性

评估与最优权重保留机制，减少偶然波动对最终结果的影响。

3.3.4 检查点与整例推理重建

为保证实验过程的可追溯性，本文在训练和验证阶段对模型参数、优化状态及关键性能指标进行同步保存。检查点机制不仅便于中断后恢复训练，也为不同轮次模型的横向比较提供了依据。验证结果则统一汇总为结构化报告，以支持后续的定量分析与结果复核。

在推理阶段，系统采用覆盖式滑窗对整例体数据进行逐块分析，并通过重建策略将局部预测拼接回完整体积。为降低块边界带来的伪影干扰，拼接时优先保留每个局部预测的高置信度中心区域，再恢复到原始影像空间，形成连续的概率分布与二值分割结果。该设计兼顾了大体积影像的计算可行性与输出结果的空间一致性，也为后续的体积测量、形态学分析与临床展示奠定了基础。

3.4 破裂风险预测模块设计

3.4.1 表格数据构建与预处理

风险预测模块以临床字段、影像组学特征及分割结果所导出的定量信息作为输入来源，其核心目标是将异质性较强的病例信息转化为适合深度学习建模的结构化表示。为此，本文在数据准备阶段对不同来源特征进行了统一整理：一方面保留临床表型中的关键变量，另一方面筛选可稳定提取的影像学字段，并通过训练、验证与测试集的规范划分保证评估过程的独立性。

在预处理层面，数值变量主要进行缺失值填补与尺度标准化，以减弱量纲差异对模型优化的影响；类别变量则转化为离散索引，便于后续通过嵌入层建立可学习表示。整体设计强调的是特征空间的一致性和可比较性，而非对原始表格信息做过度人工加工，从而为后续的学习表示保留足够的模型自由度。

3.4.2 RiskCrossAttentionModel 结构

本文采用的风险模型并未将所有字段简单拼接后输入浅层分类器，而是将每一类输入视为独立 token，并通过注意力机制建模字段之间的交互关系。数值特征与类别特征分别被映射到统一的隐空间，随后在跨字段的交互过程中逐步融合上下文信息。这种设计与近年来表格数据深度学习方法的思路一致，即先构造字段级表示，再通过注意力或上下文建模捕获变量之间的非线性关联^[16-18]。

在表征融合层面，模型通过交替更新不同特征流的方式实现信息传播，使数值变量与类别变量之间形成双向依赖关系。最终，系统对聚合后的全局表示进行判别，输出患者层面的破裂风险概率。与传统基于显式打分规则的风险评估方法相

比，该模型更注重从数据中自动学习高阶交互项，但同时也需要依赖规范的数据划分、适度正则化以及外部验证来保证泛化性能。

3.4.3 损失函数、类别加权与阈值搜索

考虑到破裂病例通常少于未破裂病例，本文在训练中采用类别加权策略，以提升模型对少数类样本的学习敏感性。损失函数以二元交叉熵为基础，并通过样本权重调整优化方向，使模型在类别不均衡场景下仍能保持较稳定的判别能力。

在模型选择阶段，本文并不直接以固定阈值进行二分类，而是基于验证集概率分布搜索最优判别阈值，以 F1 等综合指标作为主要参考。这一做法有助于根据数据分布自适应确定决策边界，减少默认阈值带来的偏置。最终在测试阶段固定最优阈值后报告准确率、F1 与 AUC 等指标，并据此评估模型在病例层面的分类性能。

3.5 Web 服务与端到端演示

为便于展示系统能力，本文还设计了一个轻量化的 Web 交互界面，用于串联影像上传、分割推理、结果回传与风险预测等步骤。该界面强调流程可视化与结果可解释性，能够帮助使用者直观理解从原始 CTA 到最终风险输出的完整链路。

从系统实现意义上看，Web 端并非独立的临床决策平台，而是用于验证前述模型在统一交互框架下的协同工作能力。其价值主要体现在两个方面：一是将分割与风险评估纳入同一操作入口，降低系统使用门槛；二是为后续部署、演示与功能扩展预留统一接口。

3.6 本章小结

本章围绕模型设计讨论了分割与风险预测两部分核心内容，重点说明了系统在数据组织、特征表示、注意力建模、损失设计与结果重建等方面的设计思想，并尽量从学术角度概括实现目标与方法选择。下一章将进一步结合实验环境、评价指标与实验结果，对模型性能进行分析。

4 实验与结果分析

4.1 实验设置

本文实验围绕“动脉瘤分割”和“破裂风险预测”两条任务主线展开。分割任务以 CTA 三维体数据为输入，输出动脉瘤概率图与二值掩膜；风险任务以临床与影像组学表格特征为输入，输出破裂概率与二分类结果。两条主线在工程上通过配置文件、统一日志目录与可视化报告进行管理，保证可复现性与可追溯性。

4.1.1 硬件与软件环境

实验采用 Linux 环境，深度学习框架为 PyTorch，医学影像读写与空间信息处理基于 SimpleITK，实验记录使用 TensorBoard 与 YAML 配置。风险预测相关实验依赖 Pandas 与 scikit-learn。

4.1.2 评估指标

分割任务主要采用 AUC、F1、IoU、精确率、召回率、特异度等指标综合评估；风险预测任务采用 Accuracy、Precision、Recall、F1 与 AUC。考虑到医学任务常见类别不平衡问题，本文特别关注 F1 与 Recall 的变化，并结合阈值搜索分析模型在误报与漏报之间的权衡。

4.2 动脉瘤分割实验结果

4.2.1 训练与验证过程

分割模型采用三维 Attention U-Net，并结合顺序补丁采样策略进行训练。根据 run_17-02-23 的评估报告，本文统计了第 80–100 轮的验证结果用于对比。该阶段模型整体已进入稳定收敛区间，主要指标波动较小。

4.2.2 结果分析（基于真实评估报告）

以 eval_epoch_0097.json 为本轮训练中的最优代表结果，在阈值 0.5 下体素级指标为：AUC=0.999997、F1=0.8830、IoU=0.7906、Precision=0.8058、Recall=0.9767。对应混淆矩阵为 TP=336、TN=4914779、FP=81、FN=8，说明模型在保持较高召回率的同时，误报体素进一步下降。

若以最新一轮 latest.json (epoch=100) 作为“最终检查点”报告，则在阈值 0.5 下 AUC=0.999996、F1=0.8660、IoU=0.7636、Precision=0.7778、Recall=0.9767，混淆矩阵为 TP=336、TN=4914760、FP=96、FN=8。可见，最终轮次与最优轮次相比主要差异体现在精确率和 IoU 的轻微回落，但总体判别能力仍保持在较高水平。

从阈值扫描结果看（以 latest.json 为例），当阈值从 0.05 提升至 0.90 时，Precision 由 0.3716 上升至 0.8953，而 Recall 由 0.9971 下降至 0.8953，体现了典型的精确率—召回率权衡关系。在该报告中，最佳 F1 出现在阈值 0.9，取值为 0.8953，且预测阳性比例（ 6.9987×10^{-5} ）与真实阳性比例一致，说明在该样本上高阈值有利于抑制假阳性并提升综合重叠质量。

此外，在另一组验证日志中，模型出现了明显的“高 AUC、低固定阈值 F1”现象：Validation Loss 为 1.0791，AUC=0.9516，F1@0.50=0.0000，BestF1=0.0000（阈值 0.10），但 Recall@best 仍达到 0.8182，PredPos@best 为 0.066760。该结果说明在类别极不平衡或概率分布偏移时，AUC 与 Recall 仍能反映模型的排序与检出能力，而固定阈值下的 F1 对阈值设定更敏感；因此本文在结果汇报中优先保留 AUC 与 Recall 作为关键辅助指标。

4.2.3 可视化与误差来源

对典型病例进行可视化后可见，模型在大多数病灶区域可实现较好轮廓贴合；在病灶体积较小、边界模糊或邻近高密度结构干扰时，仍可能出现局部漏检或边界偏差。该现象提示后续可从前景采样策略、损失函数组合与后处理机制进一步优化。

4.3 破裂风险预测实验结果

4.3.1 模型表现

风险预测模块在训练、验证、测试三级划分下进行评估。交叉注意力模型能够学习临床字段与影像相关字段之间的交互关系，并输出可解释的风险概率。实验结果显示，该模型在 F1 与 AUC 上具备一定判别能力。

4.3.2 与传统基线对比

在同一数据划分下，本文同时比较了逻辑回归、随机森林、支持向量机与 k 近邻等基线模型。对比结果表明：在样本规模有限时，部分传统集成模型具有较强稳健性；交叉注意力模型则在特征交互表达方面具备潜力。该结果说明风险预测性能仍受样本规模、特征质量与超参数设置共同影响。

4.4 系统联调与闭环验证

为验证系统完整性，本文将分割与风险模块接入同一 Web 演示流程，形成“数据上传—分割推理—风险估计—结果返回”的任务闭环。联调结果表明系统具备端到端运行能力，能够满足毕业设计原型验证需求。

4.5 本章小结

本章对实验环境、指标体系、分割结果、风险预测结果及系统联调情况进行了系统分析。基于第 80–100 轮真实评估报告，分割模型在体素级 AUC、F1 与 IoU 上均达到较好水平，且阈值优化可进一步提升综合表现。总体来看，所提出方案在当前数据条件下达到了预期目标，同时也暴露了小样本与类别不平衡场景下的进一步优化空间，为下一章“总结与展望”提供了依据。

5 总结与展望

5.1 工作总结

本文围绕“颅内动脉瘤检测与破裂风险预测”完成了从方法设计到系统实现的整体工作，构建了覆盖分割与风险评估的双任务流程。主要完成内容包括：

- 基于 CTA 三维体数据实现了动脉瘤分割模型训练与推理流程；
- 基于临床与影像相关表格特征实现了破裂风险预测模型；
- 建立了统一配置、日志记录与模型管理机制；
- 通过 Web 接口实现了端到端演示闭环。

5.2 主要结论

实验结果表明：分割模型在体素级判别指标上表现稳定，能够较好完成病灶区域识别；风险预测模型在当前数据规模下具备一定判别能力，并在与传统模型对比中呈现出可优化空间。整体系统已具备毕业设计阶段的可运行性和可复现性。

5.3 不足分析

受数据规模、标注成本与实验周期限制，当前研究仍存在以下不足：

- 多中心外部验证不足，模型泛化能力有待进一步验证；
- 部分实验仍以单次划分结果为主，统计稳健性可继续增强；
- 风险预测模型在小样本条件下对超参数较敏感，稳定性仍需提升。

5.4 未来展望

后续工作可从以下方向推进：

- 扩展多中心数据并引入更严格的交叉验证与置信区间分析；
- 在分割任务中探索更强的三维特征建模与不平衡学习策略；
- 在风险预测中加强特征工程、概率校准与临床可解释性分析；
- 完善系统部署能力，包括权限控制、审计日志与推理性能优化。

5.5 结束语

总体而言，本文完成了面向颅内动脉瘤场景的算法与系统原型设计，并形成了较为完整的实验分析与工程实现基础。该工作可为后续深入研究与临床转化探索提供可复用的技术起点。

参 考 文 献

- [1] Chen S, Xu Z, Zhao X, et al. Coarse-to-fine guided salient object detection for automatic cerebral aneurysm identification[J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 3052-3063.
- [2] Ou Y, Hua K L, Cheng X, et al. Automatic diagnosis of 3D cerebral vascular images using deep learning[J]. IEEE Access, 2022, 10: 34281-34291.
- [3] Greving J P, Wermer M J H, Brown R D J, et al. Development of the PHASES score for prediction of risk of rupture of intracranial aneurysms[J]. The Lancet Neurology, 2014, 13(1): 59-66.
- [4] Backes D, Rinkel G J E, Laban K G, et al. ELAPSS score for prediction of risk of growth of unruptured intracranial aneurysms[J]. Neurology, 2017, 88(17): 1600-1606.
- [5] Morita A, Kirino T, Hashi K, et al. The natural course of unruptured cerebral aneurysms in a japanese cohort[J]. The New England Journal of Medicine, 2012, 366(26): 2474-2482.
- [6] Thompson B G, Brown R D J, Amin-Hanjani S, et al. Guidelines for the management of patients with unruptured intracranial aneurysms: A guideline for healthcare professionals from the american heart association/american stroke association[J]. Stroke, 2015, 46(8): 2368-2400.
- [7] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2015: 234-241.
- [8] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 3431-3440.
- [9] Cicek O, Abdulkadir A, Lienkamp S S, et al. 3D u-net: learning dense volumetric segmentation from sparse annotation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2016: 424-432.
- [10] Milletari F, Navab N, Ahmadi S A. V-net: Fully convolutional neural networks for volumetric medical image segmentation[C]//2016 Fourth International Conference on 3D Vision (3DV). IEEE, 2016: 565-571.
- [11] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-net: Learning where to look for the pancreas [A]. 2018.
- [12] Isensee F, Jaeger P F, Kohl S A A, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature Methods, 2021, 18(2): 203-211.
- [13] Kamnitsas K, Ledig C, Newcombe V F J, et al. Efficient multi-scale 3D CNN with fully connected CRF for accurate brain lesion segmentation[J]. Medical Image Analysis, 2017, 36: 61-78.

- [14] Chen J, Zhuang J, Shen Y, et al. StrokeNet: A multi-task neural network for stroke outcome prediction[J]. *NeuroImage: Clinical*, 2022, 33: 102927.
- [15] Xiong L, Wang Y, Chen H, et al. Multimodal deep learning for predicting ischemic stroke outcome [J]. *IEEE Transactions on Medical Imaging*, 2025, 44(2): 523-534.
- [16] Huang X, Khetan A, Cvitkovic M, et al. Tabtransformer: Tabular data modeling using contextual embeddings[A]. 2020.
- [17] Gorishniy Y, Rubachev I, Khrulkov V, et al. Revisiting deep learning models for tabular data[C]// *Advances in Neural Information Processing Systems*. 2021.
- [18] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]// *Advances in Neural Information Processing Systems*. 2017: 5998-6008.
- [19] Litjens G, Kooi T, Bejnordi B E, et al. A survey on deep learning in medical image analysis[J]. *Medical Image Analysis*, 2017, 42: 60-88.
- [20] Shen D, Wu G, Suk H I. Deep learning in medical image analysis[J]. *Annual Review of Biomedical Engineering*, 2017, 19: 221-248.
- [21] Maier A, Syben C, Lasser T, et al. A gentle introduction to deep learning in medical image processing[J]. *Zeitschrift f"ur Medizinische Physik*, 2019, 29(2): 86-101.
- [22] Cicek O, Abdulkadir A, Lienkamp S, et al. 3d u-net: Learning dense volumetric segmentation from sparse annotation[C]// *MICCAI*. 2016: 424-432.
- [23] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. Unet++: A nested u-net architecture for medical image segmentation[J]. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, 2018: 3-11.
- [24] Sudre C H, Li W, Vercauteren T, et al. Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations[J]. *DLMIA/ML-CDS@MICCAI*, 2017: 240-248.
- [25] Salehi S S M, Erdogmus D, Gholipour A. Tversky loss function for image segmentation using 3d fully convolutional deep networks[J]. *MLMI@MICCAI*, 2017: 379-387.
- [26] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]// *Proceedings of the IEEE International Conference on Computer Vision*. 2017: 2980-2988.
- [27] Breiman L. Random forests[J]. *Machine Learning*, 2001, 45(1): 5-32.
- [28] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[J]. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016: 785-794.
- [29] Hastie T, Tibshirani R, Friedman J. The elements of statistical learning[J]. *Springer Series in Statistics*, 2009.
- [30] Saito T, Rehmsmeier M. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets[J]. *PLOS ONE*, 2015, 10(3): e0118432.

- [31] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[J]. International Conference on Machine Learning, 2017: 1321-1330.
- [32] Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning[J]. Proceedings of the 22nd International Conference on Machine Learning, 2005: 625-632.
- [33] Chicco D, Jurman G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation[J]. BMC Genomics, 2020, 21(1): 6.

附录 A：关键配置与复现实验步骤

附录 A：关键配置与复现实验步骤

A.1 项目结构说明

本项目采用模块化目录布局，便于维护、扩展与复现实验：

- core/：配置数据结构、YAML 加载与随机种子管理；
- data/：医学影像补丁数据管线与风险表格数据处理；
- model/：分割模型（aneurysm）与风险模型（risk）；
- script/：训练、评估与对比实验入口脚本；
- ui/：FastAPI 服务与推理接口封装；
- utils/：日志、路径与通用工具函数。

A.2 环境配置建议

Python ≥ 3.8

torch $\geq 1.9.0$

monai $\geq 0.7.0$

numpy $\geq 1.21.0$

pandas $\geq 1.3.0$

scikit-learn $\geq 1.0.0$

SimpleITK $\geq 2.1.0$

tensorboard

tqdm

fastapi

uvicorn

建议安装后执行 `python -c "import torch; print(torch.cuda.is_available())"` 验证 GPU 可用性。

A.3 分割任务复现实验步骤

1. 准备 NIfTI 影像与标签数据，确保命名规则与配置文件一致；
2. 复制并修改配置文件（如 config/host.yaml），填写训练/验证路径；

3. 运行训练命令：python script/train_split.py -config path/to/your.yaml;
4. 通过 TensorBoard 观察收敛曲线并记录最优检查点；
5. 运行评估脚本导出指标与可视化结果。

A. 4 风险预测复现实验步骤

1. 准备包含标签列与病例 ID 的表格数据（Excel/CSV）；
2. 在配置中启用风险模块并设置特征与训练参数；
3. 运行训练命令：python script/train_risk.py -config path/to/your.yaml;
4. 查看输出 risk_report.json 并记录 F1、AUC 与最优阈值；
5. 可选运行 compare_risk_models.py 与传统模型进行统一对比。

A. 5 关键参数说明

- 分割参数：train.epochs、train.patch_size、train.learning_rate、eval_interval；
- 风险参数：risk.hidden_dim、risk.num_heads、risk.num_layers、risk.threshold_search_steps；
- 数据参数：data.patch_sampling_mode、risk.feature_select_method。

A. 6 常见问题与排查建议

- **显存不足**：减小 patch_size 或减少每例补丁数量；
- **训练不收敛**：检查学习率、标签映射及数据归一化流程；
- **指标异常波动**：固定随机种子并核查数据划分一致性；
- **LaTeX 目录报错**：清理 .aux/.toc/.out 后重新编译。

致 谢

本论文的完成离不开各位老师、同学和家人的支持与帮助。

首先，我要感谢我的指导教师，感谢您在论文选题、研究方法和实验设计等方面的悉心指导，您的严谨治学态度和渊博的专业知识使我受益匪浅。

其次，我要感谢实验室的各位同学，在项目开发过程中，大家互相交流、共同探讨，营造了良好的学术氛围。特别感谢师兄师姐们在技术实现方面给予的宝贵经验和建议。

再次，我要感谢我的家人，感谢你们一直以来的理解、支持和鼓励，让我能够安心完成学业。

最后，感谢所有为本研究提供数据和技术支持的机构和个人。正是有了各方的支持与帮助，本研究才能够顺利完成。

原创性声明

郑重声明：所呈交的论文（设计）《_____》，是本人在导师的指导下，独立进行研究取得的成果。除论文（设计）中已经标注引用的内容外，本论文（设计）不包含其他人或集体已经发表或撰写过的作品成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

论文（设计）作者签名：_____

日期：_____

使用授权书

本论文（设计）作者完全了解学校有关保留、使用论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）复印件和电子版，允许论文（设计）被查阅和借阅。本人授权重庆大学将本论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制方式保存和汇编本论文（设计）。

本论文（设计）属于：

保 密 ☐ 在_____年解密后适用本授权书

不保密 ☐

论文（设计）作者签名：_____

指导教师签名：_____

日期：_____

日期：_____