

重庆大学本科学士毕业论文（设计）

基于深度学习的颅内动脉瘤检测与破裂风险 预测系统



学 生：王建华
学 号：20XXXXXX
指导教师：杨 XX
助理指导教师：李 XX
专 业：

重庆大学 XXXXXX 学院

20XX 年 6 月

Undergraduate Thesis (Design) of Chongqing University

**Deep Learning-Based Intracranial
Aneurysm Detection and Rupture Risk
Prediction System**



By

WANG Jianhua

Supervised by

Prof. YANG XX

and

Prof. LI XX

XXXXXX

XXXXXX

Chongqing University

June, 20XX

摘 要

颅内动脉瘤是常见的脑血管异常，一旦破裂可引发蛛网膜下腔出血，致死率与致残率均较高。CTA 能在术前较清晰地显示载瘤血管与瘤体形态，但完整序列切片数量多、血管分叉及骨伪影复杂，医生在长时间读片下仍可能出现漏检或意见分歧。与此同时，破裂风险受年龄、基础病、瘤体形态与位置等多源异质信息共同影响，传统量表或单一统计模型难以同时刻画连续变量与类别变量之间的非线性交互。因此，研究“从血管影像中稳定勾画动脉瘤，并结合临床表型进行风险分层”的计算机辅助方法，对提高筛查效率与促进诊疗规范化具有现实意义。

针对上述需求，本文在毕业设计阶段实现并串联了两条可复现的技术路线。第一，在分割子任务中采用三维 Attention U-Net：编码器—解码器结构保留 U-Net 的多尺度跳跃融合能力，在解码端每个上采样阶段引入注意力门控，对来自编码器的跳跃特征进行加权抑制，使网络在背景体素占比较高的 CTA 体积中更关注疑似瘤颈与瘤体区域；训练侧采用病例级流式加载与三维补丁采样，配合体素间距重采样与强度标准化，在有限显存条件下完成大规模体数据的迭代优化；损失函数由二元交叉熵与 Dice 损失加权组合，以兼顾逐体素分类概率与区域重叠度。推理阶段对整例体数据按顺序切块前向，再将补丁预测结果拼接还原，并写回与原始影像一致的坐标系信息，便于与放射工作站或后续组学流程对接。

第二，在破裂风险预测子任务中，面向表格型临床与影像衍生特征，构建了数值通道与类别通道分离编码的 RiskCrossAttentionModel：连续特征经可学习的尺度因子与偏置映射为特征维上的 token，离散特征经嵌入层映射到同一隐空间；多层交叉注意力块在两路 token 之间交替更新表示，最后对两路池化向量拼接后经多层感知机输出破裂概率。数据管线集成缺失值填补、低频类别合并、基于互信息的特征筛选以及训练集上的类别频次加权损失；验证集上执行阈值网格搜索以最大化 F1，并将最优阈值固定在测试评估阶段，从而缓解类别不平衡带来的默认 0.5 切分失真问题。

工程层面，上述模块通过 YAML 统一配置，训练脚本 train_split.py 与 train_risk.py 分别输出分割检查点与 risk_report.json 等指标摘要；系统还提供基于 FastAPI 的简易交互界面，支持上传体数据、触发补丁推理及表格风险预测，形成“分割—特征—风险”闭环演示流程。需要说明的是，受医院数据脱敏与伦理审批进度影响，本文在摘要层面侧重方法论与系统架构叙述；具体量化指标应以读者在本地复现实验后获得的验证/测试集评价为准。

关键词：颅内动脉瘤；CTA；三维分割；Attention U-Net；表格学习；交叉注意力；破裂风险预测

ABSTRACT

Intracranial aneurysms are a frequent cerebrovascular abnormality; rupture may lead to subarachnoid hemorrhage with high morbidity and mortality. CTA depicts parent vessels and aneurysm morphology well before intervention, yet reviewing full volumetric series remains time-consuming, and inter-observer disagreement persists under complex vascular geometry and artifacts. Rupture risk is governed by heterogeneous clinical and morphologic factors; classical scales or shallow models struggle to capture nonlinear interactions between numeric and categorical signals. Building a computer-aided pipeline that robustly segments aneurysms on CTA and stratifies rupture risk is therefore clinically motivated.

This thesis implements two reproducible tracks aligned with the course project. For segmentation, a 3D Attention U-Net is adopted: an encoder–decoder backbone retains multi-scale skip connections, while attention gates re-weight skip features at each up-sampling stage so that the network emphasizes plausible aneurysm regions in predominantly background voxels. Training uses case-wise streaming and patch-wise sampling with spacing resampling and intensity normalization; the objective combines binary cross-entropy with Dice loss to balance pixel-wise calibration and overlap. At inference time, sequential patch prediction is stitched back to a full volume and exported with restored image geometry for downstream use.

For rupture risk, tabular clinical and derived features are encoded in a dedicated RiskCrossAttentionModel: numeric inputs are scaled and projected per feature into tokens, categorical fields use embeddings, and stacked cross-attention blocks mutually refine the two streams before a fused MLP head outputs a rupture probability. The tabular pipeline covers imputation, rare-category pooling, mutual-information feature selection, and class-frequency–weighted loss; a validation-set threshold search optimizes F1 before fixing the operating point for testing.

Configuration is centralized in YAML; `train_split.py` and `train_risk.py` produce checkpoints and JSON metric summaries respectively. A lightweight FastAPI UI demonstrates volume upload, patch-based segmentation, and tabular risk inference. Quantitative claims in this abstract are intentionally conservative: final numbers should be taken from institution-approved datasets and the project’s own evaluation logs after replication.

Key words: intracranial aneurysm; CTA; 3D segmentation; Attention U-Net; tabular learning; cross-attention; rupture risk prediction

目 录

摘要	I
ABSTRACT	III
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 动脉瘤与脑血管影像分析的传统途径	2
1.2.2 基于深度学习的分割与多模态预测	2
1.3 本文面临的问题与主要思路	2
1.4 课题来源与研究内容	3
1.5 论文结构安排	3
1.6 本章小结	4
2 系统实现与方法设计	5
2.1 系统总体架构	5
2.2 相关理论简述	5
2.2.1 全卷积分割与 Dice 损失	5
2.2.2 注意力门控跳跃连接	6
2.3 动脉瘤分割模块设计	6
2.3.1 数据组织与流式补丁采样	6
2.3.2 网络结构与输出层	7
2.3.3 损失函数与优化策略	7
2.3.4 检查点与整例推理重建	7
2.4 破裂风险预测模块设计	8
2.4.1 表格数据构建与预处理	8
2.4.2 RiskCrossAttentionModel 结构	8
2.4.3 损失函数、类别加权与阈值搜索	8
2.5 Web 服务与端到端演示	9
2.6 本章小结	9
3 实验设计与结果分析	10
3.1 实验说明与可复现性	10
3.2 实验环境与主要依赖	10
3.2.1 硬件与软件	10
3.2.2 随机种子与版本记录	11

3.3 数据协议与预处理约定. 11

3.3.1 分割任务数据 11

3.3.2 破裂风险任务数据. 11

3.4 主线 A：动脉瘤分割实验设计. 12

3.4.1 训练协议与超参数（与配置项对齐） 12

3.4.2 训练过程监控与产出文件. 12

3.4.3 整例推理与空间一致性 12

3.4.4 分割结果的多维度解读（建议在答辩中展开） 12

3.4.5 横向对比与消融实验框架. 14

3.5 主线 B：破裂风险预测实验设计 14

3.5.1 数据划分与泄漏防护 14

3.5.2 模型超参数与训练细节 15

3.5.3 优化目标与决策阈值 15

3.5.4 产出物与结果登记表 16

3.5.5 风险模型的结果解读要点. 16

3.6 系统集成与演示实验 17

3.6.1 Web 接口层面的任务闭环. 17

3.6.2 任务书交付物对照表 17

3.7 消融实验与灵敏度分析. 17

3.8 可视化与定性案例分析. 18

3.9 本章小结 18

4 结论与展望. 20

4.1 工作总结 20

4.1.1 分割子任务：从数据协议到可交付模型. 20

4.1.2 风险子任务：从表格清洗到阈值固定的决策规则. 20

4.1.3 工程集成与演示 21

4.1.4 与参考范式的对照. 21

4.2 主要特点与创新点归纳（本科论文尺度） 21

4.3 不足与展望 21

4.3.1 数据与评测层面 21

4.3.2 算法与建模层面 22

4.3.3 系统与合规层面 22

4.3.4 个人收获与后续学习计划. 22

4.4 结束语. 22

参考文献 23

5 参考文献 23

附录 A：关键配置与复现实验步骤 25

6 关键配置与复现实验步骤 25

6.1 项目结构说明 25

6.2 环境配置 25

6.3 训练流程说明 26

6.3.1 动脉瘤分割模型训练 26

6.3.2 破裂风险预测模型训练 26

6.4 关键配置参数说明（与仓库默认值对齐） 26

6.4.1 分割相关 26

6.4.2 风险相关 27

6.5 推理与演示 27

致谢 28

7 致 谢 28

原创性声明和使用授权书 29

1 绪论

1.1 研究背景与意义

脑血管疾病在我国居民死因构成中长期居于前列，其中颅内动脉瘤（Intracranial Aneurysm, IA）可在无症状阶段经影像学检查偶然发现；一旦瘤壁完整性被破坏导致蛛网膜下腔出血（Subarachnoid Hemorrhage, SAH），病情往往凶险，遗留神经功能障碍的比例亦不容忽视。数字减影血管造影（DSA）被视为诊断“金标准”，但其有创性与费用限制了大规模筛查场景的普及。CT 血管成像（CT Angiography, CTA）无创、可及性高，已成为门诊与急诊情境下动脉瘤检出与术前评估的重要工具 [6, 8]。

然而，临床实际工作中仍存在三方面痛点。其一，单次检查所产生的轴位切片可达数百层，医生需在三维空间中追踪迂曲血管并辨别微小隆起，长时间阅片易引起视觉疲劳与漏诊。其二，不同扫描协议、重建层厚与对比剂充盈程度会造成图像对比度与噪声水平的差异，同一算法在不同硬件条件下的稳定性面临考验。其三，是否建议干预不仅取决于“有没有瘤”，还与瘤体大小、形态不规则度、位置（如前交通动脉瘤与后循环动脉瘤的管理策略差异）、患者年龄及合并症等因素耦合；若仅依赖分割掩膜而缺少风险分层，仍难以直接支撑个体化随访问隔或手术决策。

近年来，深度学习在医学影像分割任务上取得了令人瞩目的进展。全卷积网络与 U-Net 族结构能够在像素级输出病灶概率图，显著缩短标注辅助时间 [2, 20]；三维卷积网络可直接建模沿血管走向的上下文信息，有利于保持瘤体在层间的连续性 [3, 17]。Attention U-Net 在解码路径上对跳跃连接施加门控，使网络更关注与任务相关的空间区域，已在腹部脏器、胰腺等分割中得到验证 [4]。在脑血管领域，已有工作尝试将粗定位与细分割结合，或利用多尺度三维卷积提升细小病灶检出率 [7, 6]。与此同时，面向卒中结局或动脉瘤临床结局的多任务网络也开始出现，提示“影像 + 临床”联合建模的重要性 [9, 10]。

在此背景下，本文依托课程设计任务，围绕“动脉瘤的自动分割定位”与“破裂风险的概率预测”两个相互衔接的子问题，实现一套以配置文件驱动、脚本可复现为特征的软件系统。该系统一方面减轻医师在体数据层面的重复勾画负担，另一方面为后续将影像组学特征或形态学参数与表型数据融合提供工程接口，具有明确的辅助诊疗价值与教学演示意义。

1.2 国内外研究现状

1.2.1 动脉瘤与脑血管影像分析的传统途径

在深度学习普及之前，血管分割与病灶提取多采用基于强度的阈值分割、区域生长、水平集或基于几何先验的滤波器响应等方法。此类流程往往需要人工调节种子点、平滑核大小或曲率约束，且对低对比度瘤颈、邻近骨质高密度灶等干扰敏感，跨中心推广时常需重新调参。面向风险评估，临床多采用 Hunt-Hess 分级、WFNS 评分或基于直径阈值的简单规则，统计学习阶段则常见逻辑回归、随机森林等浅层模型；它们在变量个数较少、线性可分性较强的回顾性队列上可给出可解释结果，但对高维异构特征的自适应组合能力有限。

1.2.2 基于深度学习的分割与多模态预测

随着公开数据集与算力条件改善，U-Net 及其三维变体逐渐成为血管与病灶分割的主流骨架 [2, 3]。nnU-Net 等工作进一步强调预处理、网络拓扑与后处理的自动化配置，提升了跨任务迁移的效率 [5]。针对颅内动脉瘤，研究者探索了从血管分割到瘤体检测的多阶段流程，或引入注意力与多尺度模块以强调细小结构 [6, 8]。在预测层面，Transformer 与注意力机制为序列化或多模态特征融合提供了统一接口 [11]；StrokeNet 等多任务结构尝试同时编码影像与临床信息以预测卒中结局 [9]。这些工作表明：分割精度与下游临床推理并非割裂——高质量掩膜既可直接用于手术规划，也可作为体积、曲率等衍生特征的载体。

与国际前沿相比，国内医院信息化水平与数据共享机制仍在完善过程中，完全复现文献中的绝对精度往往需要匹配相同的扫描协议与标注规范。对本科毕业设计而言，更务实的目标是在理解算法原理的基础上，完成从数据接口、模型训练到推理交付的完整链路，并在文档中清楚交代可复现条件与已知局限。

1.3 本文面临的问题与主要思路

综合文献与工程经验，本文将任务难点概括为三点。（1）**体数据占用与显存矛盾**：完整 CTA 体积可达数百兆字节以上，若一次性加载多病例批次，普通 GPU 难以承受；需要在“流式 IO—补丁采样—梯度更新”之间取得平衡。（2）**前景极度稀疏**：动脉瘤体素在整幅体积中占比极低，单纯交叉熵易使模型偏向预测背景；需要区域重叠型损失与采样策略共同约束。（3）**风险标签与特征异质性**：破裂与未

破裂病例分布不均衡，类别字段存在长尾取值；需要合理的加权损失、阈值搜索与特征筛选，避免过拟合于训练集噪声。

针对上述难点，本文采用“分割骨干+表格风险头”的系统级方案：分割侧选用三维 Attention U-Net，配合病例级流式训练与前景优先补丁采样；风险侧使用基于交叉注意力的表格模型，统一处理数值与类别特征，并在验证集上搜索决策阈值。该路线与仓库中的 `train_split.py`、`train_risk.py` 及 Web 演示模块一致，便于答辩演示与后续扩展。

1.4 课题来源与研究内容

本课题来源于指导教师下达的毕业设计任务书，目标是对颅内动脉瘤 CTA 数据进行计算机辅助检测，并在临床表型与影像衍生特征基础上完成破裂风险的二分类预测。结合仓库实现，本文工作具体包括：

1. 基于 AttentionUnet 实现三维分割网络，完成编码器—解码器通道配置、注意力门控与 sigmoid 输出的端到端前向；
2. 在 MedicalPatchDataset 上实现多目录数据扫描、重采样、标准化及前景优先/顺序采样策略，支撑低显存条件下的长时间训练；
3. 基于 Dice 与 BCE 的组合损失、Adam/AdamW/SGD 与余弦退火等配置化优化流程，训练过程写入 TensorBoard，并按间隔保存 latest.pth 与验证集最优 best.pth；
4. 推理阶段将补丁结果拼接为完整体积，恢复 spacing、origin、direction，输出概率体与二值掩膜供可视化或形态学特征提取；
5. 构建表格风险数据的清洗、互信息特征筛选、加权 BCE 训练、验证集 F1 最优阈值搜索及测试集报告导出（risk_report.json）；
6. 提供 FastAPI 交互界面，串联上传、分割与风险预测演示流程。

1.5 论文结构安排

全文共分四章。第一章介绍研究背景、国内外现状、问题难点与研究内容。第二章从系统架构出发，分述分割模块、风险模块的原理与实现要点，并简要说明

Web 服务接口。第三章介绍实验环境、数据集与预处理约定、评价指标与结果分析框架，说明如何根据日志与配置文件复现指标。第四章总结全文并展望未来改进方向。

1.6 本章小结

本章从临床需求与技术趋势两方面阐述了颅内动脉瘤辅助分析的研究动机，综述了传统方法与深度学习方法的优劣，归纳了本文面向的三个核心难点及对应思路，并列出了与源代码模块对应的研究内容。后续章节将展开算法与系统实现的细节。

2 系统实现与方法设计

2.1 系统总体架构

本文实现的系统由两个核心任务组成：CTA 体数据的动脉瘤分割任务，以及基于表型数据的破裂风险二分类任务。整体数据流如下：

1. 输入 NIfTI 格式的 CTA 体数据，在线完成体素间距重采样与强度标准化；
2. 基于三维 Attention U-Net 进行病灶分割，输出与原始坐标系对齐的概率图与二值掩膜；
3. 可选地由分割掩膜提取形态学参数，或与影像组学流水线衔接；结合 Excel/CSV 中的临床字段构建风险建模特征表；
4. 采用 RiskCrossAttentionModel 对数值与类别特征联合编码，输出破裂风险概率，并在验证集上确定推理阈值。

上述流程在代码层面由两个入口脚本驱动：script/train_split.py 负责分割模型训练与验证指标回调，script/train_risk.py 在配置项 risk.enabled=true 时独立训练风险模型。二者共享同一 YAML 配置文件（如 config/remote.yaml），便于统一管理随机种子、设备与日志目录。

2.2 相关理论简述

2.2.1 全卷积分割与 Dice 损失

全卷积结构将分类网络中的全连接层替换为卷积层，使网络可直接输出与输入同分辨率的空间概率图 [20, 2]。对于动脉瘤这类前景体素占比极小的任务，仅在像素级优化交叉熵往往导致预测偏向背景。Dice 系数衡量预测区域与标注区域的重叠程度，基于 Dice 的损失函数可显式增大阳性区域的梯度贡献，其常用形式为：

$$\mathcal{L}_{Dice} = 1 - \frac{2 \sum_i p_i g_i + \epsilon}{\sum_i p_i + \sum_i g_i + \epsilon}, \quad (2.1)$$

其中 $p_i \in [0, 1]$ 为体素 i 的预测概率， $g_i \in \{0, 1\}$ 为对应标签， ϵ 为小常数用于数值稳定。

2.2.2 注意力门控跳跃连接

标准 U-Net 将编码器特征直接与解码器特征拼接，可能引入大量与病灶无关的背景响应。Attention U-Net 在每次上采样后与跳跃特征融合前，引入门控图对跳跃特征进行逐元素加权 [4]。设 g 为解码器当前分辨率下的特征图， s 为同尺度跳跃特征，门控权重的计算可概括为：

$$a = \sigma(\psi(\text{ReLU}(W_g(g) + W_s(s)))) \quad (2.2)$$

$$\hat{s} = a \odot s \quad (2.3)$$

其中 W_g 、 W_s 为 $1 \times 1 \times 1$ 卷积与归一化组成的线性投影， ψ 将通道压缩为单通道并经 Sigmoid 得到 a ， $\odot$ 为逐元素乘法， σ 与实现中的 Sigmoid 一致。解码器最终接收的是经过滤波的 $\hat{s}$ 与上采样特征拼接后的张量。本项目在 UpSampleBlock 中调用 AttentionGate 实现上述过程。

2.3 动脉瘤分割模块设计

2.3.1 数据组织与流式补丁采样

三维医学影像体积大、显存占用高。为适应单卡训练环境，MedicalPatchDataset 采用病例级流式策略：每个迭代步仅完整加载一例体积，在线完成重采样、标准化与补丁裁剪后再参与前向与反向传播，必要时释放中间缓存。数据集模块支持的主要机制包括：

- 多目录扫描与图像—标签路径匹配（依据文件名后缀规则推断标签文件）；
- 将各向异性 spacing 重采样到 YAML 中指定的目标间距，减少不同扫描仪之间的尺度差异；
- 对强度进行 z-score 或窗口化等标准化（以配置为准），抑制极端 HU 值对梯度的影响；
- foreground_priority、foreground_only、sequential 等补丁采样模式：训练阶段偏向包含前景的立方体补丁，验证/推理阶段可采用顺序滑窗以覆盖全体积。

针对前景稀疏问题，配置项 `background_per_foreground` 控制“每个前景补丁后附带多少个背景补丁”的配比，使模型既见到足够动脉瘤体素，又不遗忘血管周边组织的判别边界。补丁尺寸由 `train.patch_size` 给定，仓库默认示例为 $128 \times 128 \times 128$ 体素立方体；每例体积的最大补丁采样次数由 `patches_per_volume`、`max_patches_per_volume` 等字段约束。

2.3.2 网络结构与输出层

分割模型类 `AttentionUnet` 继承统一的 `Unet` 骨架：`UnetEncoder` 逐层下采样并记录各尺度通道宽度，`UnetDecoder` 自瓶颈层逐级上采样；每一级上采样后通过 `UpSampleBlock` 融合跳跃特征，其中即包含前一节所述注意力门控。输出层使用 $1 \times 1 \times 1$ 卷积将通道映射为类别数，并对动脉瘤二分类任务采用 `Sigmoid` 激活得到体素级概率。

2.3.3 损失函数与优化策略

训练目标采用二元交叉熵与 `Dice` 损失的加权组合（实现见 `combined_loss`）：

$$\mathcal{L}_{seg} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice}. \quad (2.4)$$

优化器由配置 `train.optimizer` 选择 `Adam`、`AdamW` 或 `SGD`；学习率调度支持余弦退火、阶梯衰减或恒等映射（`train.scheduler`）。训练脚本在每个 `epoch` 后将标量损失写入 `TensorBoard`（日志位于 `log_dir/tensorboard`），并按 `eval_interval` 在验证集上评估 `Dice`，维护验证集最优权重。

2.3.4 检查点与整例推理重建

每次触发保存时，脚本将当前 `epoch`、模型参数、优化器状态及验证 `Dice` 序列化至磁盘：默认写入 `checkpoints/latest.pth`；若当前验证性能超过历史最优，则额外写入 `best.pth`。这一命名约定便于断点续训与部署阶段直接加载最优模型。

评估与推理阶段将数据集采样模式切换为顺序遍历，对整例体积进行补丁前向，再依据空间索引将补丁预测拼接回完整三维数组；随后利用 `SimpleITK` 将数组写回 `NIfTI`，并恢复原始影像的 `spacing`、`origin` 与 `direction`，保证与 `PACS` 或 `RadiAnt` 等查看器对齐。系统可同时导出连续概率图与经固定阈值二值化后的掩膜，后者

便于快速统计瘤体体积或作为形态学特征提取输入。

2.4 破裂风险预测模块设计

2.4.1 表格数据构建与预处理

风险建模的数据源由配置中的 `risk.excel_path`、标签列、标识列及可选特征列指定。管线 `build_risk_data_bundle` 完成训练/验证/测试划分，并对数值与类别字段分别处理：缺失值可用列统计量填补；低频类别可合并为“其他”；数值列与类别列经互信息等方法筛选至不超过 `auto_max_features` 维，以降低噪声维度。配置中还包含临床先验列（如年龄、性别、既往病史等）与影像组学特征开关，便于课题后续扩展。

2.4.2 RiskCrossAttentionModel 结构

与“单一全连接层拼接所有字段”的浅层网络不同，本文实现的 `RiskCrossAttentionModel` 将每个数值字段映射为隐空间中的一枚 `token`：先通过可学习的逐维缩放与偏置校正量纲差异，再将标量经线性层投影为 $\mathbb{R}^{d_h}$ 向量。类别字段则通过各自的嵌入表映射到同一维度。若某次实验中不存在离散字段，实现中将数值 `token` 的均值作为占位类别 `token`，以避免注意力模块退化。

在 `token` 序列层面，模型堆叠若干层“数值 $\rightarrow$ 类别”与“类别 $\rightarrow$ 数值”交替的 `CrossAttentionBlock`：每一层内部采用 PyTorch 的 `MultiheadAttention`，以一批 `token` 为 `query`、另一批为 `key/value`，经残差连接与前馈网络（FFN）更新表示，形式上与 Transformer 编码子层一致 [11]。最终将数值流与类别流分别沿 `token` 维做均值池化，拼接后送入 `LayerNorm` 与两层 `MLP`，经 `Sigmoid` 得到破裂概率标量。

2.4.3 损失函数、类别加权与阈值搜索

训练阶段采用加权二元交叉熵：正样本权重由训练集正负样本数量比自动估计（可由 `use_pos_weight` 控制），以缓解破裂样本稀少带来的梯度淹没。验证阶段在固定模型参数的前提下，对验证集预测概率在 $(0.05, 0.95)$ 区间内做线性阈值扫描，以宏平均 F1 为主准则选取最优阈值；测试阶段固定该阈值输出准确率、精确率、召回率与 AUC。最优模型参数与指标摘要写入 `risk_save_dir/risk_cross_attention.pt` 与 `risk_report.json`。

2.5 Web 服务与端到端演示

项目提供基于 FastAPI 的轻量 Web 服务（ui/main.py）：支持上传 CTA 体积、调用与训练阶段一致的补丁推理流程，并可选加载训练好的风险模型对表单特征进行推断。接口层同时预留与健康检查、静态资源路由等基础能力，便于在局域网环境下向答辩评委演示“上传—分割—预测”闭环。该模块偏重工程集成，核心算法仍以前述两类训练脚本为准。

2.6 本章小结

本章从总体架构出发，介绍了三维 Attention U-Net 分割管线在数据层、网络层与损失层的设计选择，说明了与代码路径对应的检查点与 NIfTI 输出格式；随后阐述了表格风险模型的 token 化编码、多头交叉注意力融合及加权损失与阈值搜索策略；最后简要概括 Web 端的串联作用。下一章将围绕实验环境、评价指标与结果分析框架展开。

3 实验设计与结果分析

3.1 实验说明与可复现性

本章的任务书对应关系可以概括为两条并行主线：**主线 A（影像）**——在 CTA 体数据上训练三维 Attention U-Net，输出与金标准可比对的分割概率图与二值掩膜；**主线 B（表型）**——在 Excel/CSV 表格上训练破裂风险二分类模型，输出校准前的风险概率及测试集评价摘要。两条主线在工程上通过可选的形态学/组学特征字段衔接，在答辩演示上通过 Web 界面串联。

需要强调的是：受医院数据脱敏、伦理审批进度与算力排期等限制，不同复现者在 Dice、AUC 等具体数值上可能存在差异；**正式归档时，应以经审批数据集上、由本项目脚本与日志导出的客观记录为准**。下文除特别标注外，凡出现“示例性”表格或百分比，均可在定稿前整体替换为实测；章节后半部分则尽量扩充与**代码一致的过程性描述**，避免仅有少量数字而缺少实验设计交代。

3.2 实验环境与主要依赖

3.2.1 硬件与软件

本课题开发与调试的典型环境如下（答辩材料中可按实验室机器实录微调）：

- 操作系统：Linux（Ubuntu 20.04 LTS 或兼容发行版）；
- GPU：NVIDIA CUDA 兼容显卡（例：RTX 3090，24GB 显存），用于三维卷积与批量矩阵运算；
- Python：3.8 及以上（建议与 PyTorch 官方 wheel 版本说明一致）；
- 深度学习框架：PyTorch，配合 MONAI 中的体数据变换、度量实现（若实际未调用 MONAI API，也可在论文中写“计划对接 MONAI 指标以统一口径”）；
- 医学图像 IO：SimpleITK，用于读写 NIfTI、保留 spacing/origin/direction；
- 实验管理：TensorBoard（训练曲线）、tqdm（终端进度条）、YAML（超参）；
- 风险任务：Pandas、scikit-learn（划分、互信息、ROC/AUC）；
- 演示服务：FastAPI、Uvicorn。

设备由配置文件中的 device 指定，并可用命令行 `-device cuda|cpu` 覆盖，便于笔记本 CPU 调试与服务器 GPU 训练切换。

3.2.2 随机种子与版本记录

为便于问题复现，项目在 core 层对随机种子进行统一设置（如 NumPy、PyTorch CUDA）。建议在毕业论文附录中**固定给出**：Python 与 PyTorch 版本号、CUDA/cuDNN 版本、关键依赖包版本、所用配置文件路径（如 config/remote.yaml）及 Git 提交哈希（若适用）。答辩评委追问“结果能否复现”时，上述信息是最直接的技术答复。

3.3 数据协议与预处理约定

3.3.1 分割任务数据

动脉瘤分割数据以 NIfTI (.nii 或 .nii.gz) 为主。训练与验证目录由 data.train_dirs、data.eval_dirs 分别列出；若未单独指定验证目录，代码侧可能回退到训练目录（日志中会出现警告），此时验证 Dice 的独立性较弱，论文中应如实说明划分策略。

图像与标签通过文件名规则配对：file_patterns 列出影像候选模式（如 *_origin.nii.gz），label_suffix 列出标签后缀（如 _label.nii.gz、_ias.nii.gz）。该设计允许同一批原始数据以不同预处理版本共存，只要后缀规则可唯一推断标签路径。

体素各向异性通过重采样统一到目标 spacing；强度在补丁读取管线中标准化，以减轻不同扫描参数带来的灰度分布偏移。与二维分类数据集“固定张数图片”不同，体数据实验需额外记录：**纳入病例数**、**每例层厚/重建矩阵**、**标注金标准来源**（单专家/双专家融合）、**最小动脉瘤直径纳入标准**等，否则难以与其他文献横向对比。

3.3.2 破裂风险任务数据

风险建模依赖表格文件路径 risk.excel_path、标签列 label_column（如“破裂”）、病例 ID 列 id_column。特征列可以显式枚举，也可以留空触发基于互信息（feature_select_method: mutual_info）的自动筛选，并受 auto_max_features 上限约束。配置中还包含临床先验列（如性别、年龄、合并症等）、类别低频合并阈值（categorical_min_frequency）以及是否与影像组学特征对齐（use_pyradiomics_overlap_only）等开关——这些字段决定了**实际输入模型的特征数量与语义**，论文中建议用表格

列出“最终进入训练的数值列数、类别列数、各类基数”，而不是笼统写“数十个特征”。

3.4 主线 A：动脉瘤分割实验设计

3.4.1 训练协议与超参数（与配置项对齐）

分割训练入口为 `script/train_split.py`，核心超参由 YAML 的 `model` 与 `train` 段驱动。表 3.1 归纳了与本仓库默认思路一致、且应在论文中逐项交代的关键项（具体取值以你实际使用的配置文件为准）。

3.4.2 训练过程监控与产出文件

每轮训练将 `epoch` 损失写入 TensorBoard 标量（目录一般为 `log_dir/tensorboard`）。验证阶段由 `eval_split.evaluate` 计算 `Dice`，并触发 `save_checkpoint`：始终更新 `checkpoints/latest.pth`；若当前验证 `Dice` 高于历史最优，则写入 `checkpoints/best.pth`。论文中可截取 TensorBoard 中 `Loss/train_epoch` 与验证 `Dice` 曲线各一张，作为“训练收敛行为”的定性证据。

此外，脚本可选保存训练/验证过程中的补丁预测预览（路径与 `prediction_dir` 相关），便于肉眼排查标签颠倒、强度窗口错误等低级问题。

3.4.3 整例推理与空间一致性

验证或离线测试时，数据集将补丁采样模式切换为顺序遍历，并对整例体积进行切块推理与拼接；随后利用 SimpleITK 写回 NIfTI，并恢复原始影像的 `spacing`、`origin`、`direction`。这一环节是临床可用性的关键：若缺失几何元数据，后续与放疗计划系统或手术导航叠加将失败。实验章节建议单独用一小节文字说明：推理输出包含**概率图**与**二值掩膜**两类文件，及其后缀命名约定。

3.4.4 分割结果的多维度解读（建议在答辩中展开）

即使暂不报告大量病例统计，也可以在文中预先搭建分析框架：

- **整体层面**：病例平均 `Dice`、`Dice` 的中位数与四分位距，反映算法稳定性；

表 3.1 分割任务关键超参数与典型取值（请按实际 YAML 填写最终列）

配置键	含义与实验设计说明
model.depth, model.base_filters model.norm_type, model.activation, model.dropout	控制网络宽度与深度；深度越大感受野越大，但显存与过拟合风险同步上升。 归一化与激活选择影响小批量统计稳定性； Dropout 在体数据中需谨慎开启。
train.epochs	总轮数；需结合 eval_interval 观察验证 Dice 是否仍上升，避免无效延长训练。
train.batch_size	本项目训练循环按“病例”迭代，常见取值为 1；应在文中解释为何不以更大 batch 堆叠多病例。
train.patch_size	三维补丁边长，直接决定显存占用；可在消融中对比 96^3 与 128^3 等。
train.max_patches_per_volume data.patches_per_volume	每例最多采样补丁数，影响单 epoch 时长与前景覆盖。
data.patch_sampling_mode	训练用 foreground_priority 可提高前景占比；验证/整例推理常改为 sequential。
data.background_per_foreground	前景补丁与背景补丁配比，用于压制“全预测背景”的平凡解。
train.optimizer, train.learning_rate, train.weight_decay	优化器选择与正则；可在附录给出学习率曲线截图。
train.scheduler, train.warmup_epochs	学习率调度策略；若代码中 scheduler 步进尚未完全接线，应在论文中如实说明当前实际生效部分。
eval_interval	每隔多少 epoch 做一次验证并刷新 best.pth。
checkpoint.save_interval	周期性保存 latest.pth，用于防止中断后回滚。

- **病灶尺度分层**：按瘤体等效直径将病例分桶，讨论小动脉瘤是否 Dice 偏低（部分体素过少导致 Dice 方差大）；
- **解剖部位分层**：Willis 环与前循环、后循环动脉瘤在血管曲率与对比剂充盈上的差异，可能导致分割难易不同；
- **错误类型**：假阴性（漏分割）与假阳性（血管锥或邻近骨质高密度误判）在临床上后果不同，可分别统计体素级敏感度/特异度；
- **边界指标**：除 DSC 外，报告 95% Hausdorff 距离，敏感于瘤颈区域的细小偏差。

3.4.5 横向对比与消融实验框架

表 3.2 给出分割任务常见的横向对比排版方式。**基线模型行**可通过三种途径之一填充：（1）在同一数据划分上复现文献公开配置；（2）在项目中临时替换 build_model 为纯 3D U-Net 并保持相同补丁协议；（3）若工期不足，则删除基线数值，仅保留本文方法与定性讨论。

表 3.2 动脉瘤分割任务：方法—指标对比表（示例性数值，提交前请替换为实测）

方法	DSC(%)	95%HD(mm)	敏感性 (%)	特异性 (%)	训练时间 (h)
3D U-Net	78.3	4.2	76.8	94.2	12.5
3D U-Net++	81.2	3.6	79.5	94.8	16.8
V-Net	79.6	3.9	78.2	94.5	14.2
本文 Attention U-Net	85.7	2.8	84.1	96.3	15.3

消融实验建议覆盖第二章涉及的机制：注意力门控是否启用、损失是否包含 Dice、补丁采样是否前景优先、是否使用深度监督（若代码未实现则不予编造）。表 3.6 给出记录模板。

3.5 主线 B：破裂风险预测实验设计

3.5.1 数据划分与泄漏防护

train_risk.py 通过 test_size、val_size 与 random_state 完成训练集、验证集与测试集的划分。论文中应明确：互信息特征筛选**仅在训练集上拟合**，再将同一变

换应用到验证与测试；若误用全部样本做筛选，会造成标签泄漏，AUC 虚高。若课题使用病例 ID 去重或家族簇抽样，也需在文中说明，否则表格任务的“独立同分布”假设不成立。

3.5.2 模型超参数与训练细节

表 3.3 列出风险模块在配置中的主要接口，与 RiskCrossAttentionModel 构造函数一一对应。

表 3.3 破裂风险任务关键超参数与含义（按实际 YAML 填写取值）

配置键	含义
risk.hidden_dim	隐空间维度，需与 num_heads 整除约束一致。
risk.num_heads	多头注意力头数；头数过多在小样本下可能过拟合。
risk.num_layers	双向交叉注意力堆叠层数，depth 越大模型容量越大。
risk.dropout	Dropout 比率，配合 LayerNorm 与 GELU 缓解过拟合。
risk.epochs, risk.batch_size	表格任务通常可采用较大 batch；若类别极不均衡，可适当减小 batch 以增加梯度噪声、配合加权损失。
risk.learning_rate, risk.weight_decay	优化器通常采用 AdamW；权重衰减对嵌入表同样生效。
risk.use_pos_weight	是否根据训练集正负比自动设置正类权重。
risk.threshold_search_steps	验证集上阈值扫描的离散点数；影响 F1 最优解的分辨率。
risk.early_stopping_patience 等	早停策略，防止验证集指标长期不升时过训练。

3.5.3 优化目标与决策阈值

训练损失为加权二元交叉熵，正类权重由训练集样本频次估计。验证阶段在每个 epoch 结束后，将验证集预测概率在 (0.05,0.95) 上做多阈值搜索，以**宏平均 F1**为主准则更新当前阈值；测试阶段固定验证集上选出的最优阈值，输出准确率、

精确率、召回率与 AUC。论文中建议补充一句：若临床更重视“不漏诊破裂风险”，可在讨论中改用召回率或加权代价敏感准则重新搜索阈值。

3.5.4 产出物与结果登记表

训练结束后，目录 risk.save_dir 下通常生成：

- risk_cross_attention.pt：模型权重与还原所需的列名、类别基数等元数据；
- risk_report.json：验证集最优 F1、AUC、阈值及测试集指标摘要。

答辩材料可将 JSON 中字段摘抄为表 3.4 的“本文方法”行，避免手工抄错。

表 3.4 破裂风险预测任务：方法—指标对比表（示例性数值，提交前请替换为 risk_report.json 实测）

方法	准确率 (%)	精确率 (%)	召回率 (%)	F1 分数 (%)	AUC	训练时间 (mi
逻辑回归	72.4	69.8	73.2	71.5	0.756	2.3
SVM	73.8	71.2	72.6	71.9	0.763	4.7
Random Forest	74.6	72.1	74.3	73.2	0.771	3.8
XGBoost	76.2	73.5	75.8	74.6	0.785	5.2
本文交叉注意力模型	81.4	79.3	82.1	80.7	0.842	8.7

3.5.5 风险模型的结果解读要点

除整体 AUC 外，建议在讨论中预留以下分析维度：

- **校准性**：预测概率是否系统性偏高/偏低（可通过可靠性曲线或分箱后的 observed rate 评估）；
- **少数类表现**：破裂阳性样本较少时，单独报告阳性子集的敏感度；
- **特征维度敏感性**：改变 auto_max_features 或手动剔除某类临床字段后，AUC 变化是否剧烈，用以判断模型是否依赖个别字段；
- **与分割衔接**：若 UI 或后处理脚本将分割体积导入形态学特征（如瘤体体积、长径），应说明该特征是否纳入风险模型及噪声来源（分割误差传递）。

3.6 系统集成与演示实验

3.6.1 Web 接口层面的任务闭环

ui/main.py 提供 HTTP API：上传 CTA 体积后调用与训练一致的补丁推理逻辑；风险预测端加载 risk_cross_attention.pt 并对表单字段编码。论文中可增加一小段“演示实验”：记录一次端到端请求耗时、占用显存峰值、返回 JSON 字段是否齐全。该类实验不替代离线批量评测，但能证明**集成链路可用**。

3.6.2 任务书交付物对照表

为方便评委核对“是否完成题目要求”，可将交付物梳理为表 3.5（路径按仓库实际为准）。

表 3.5 毕业设计任务与仓库产出物对照（示例）

任务书要求	对应实现与佐证材料
动脉瘤分割/检测	train_split.py、eval_split.py、best.pth、验证 Dice 曲线、NIfTI 预测结果
破裂风险预测	train_risk.py（需 risk.enabled: true）、risk_report.json、混淆矩阵（可自行脚本绘制）
可视化或交互 可复现实验	FastAPI UI、上传接口日志、浏览器截图 YAML 配置、随机种子、依赖版本说明、附录训练命令

3.7 消融实验与灵敏度分析

表 3.6 汇总分割与风险两侧可做的消融维度。实施原则是：每次只改一个因素，固定随机种子与数据划分。

灵敏度分析建议至少覆盖：patch_size、patches_per_volume、risk.hidden_dim、互信息保留特征数。可将横轴为超参取值、纵轴为验证指标的折线图附在答辩附录。

表 3.6 消融实验记录模板（请替换为实测）

配置	DSC(%)	95%HD(mm)	准确率 (%)	AUC
去除注意力门控	78.3	4.2	-	-
仅 BCE、无 Dice	83.1	3.2	-	-
完整分割管线	85.7	2.8	-	-
浅层 MLP 风险基线	-	-	76.2	0.785
加入交叉注意力层	-	-	79.8	0.821
再加入验证集阈值搜索	-	-	81.4	0.842

3.8 可视化与定性案例分析

图 3.1 建议展示至少两类病例：**Dice 较高**的代表性成功病例，与 **Dice 偏低或存在临床关切误差**的困难病例；每张图旁配以简短文字说明可能原因（瘤体过小、运动伪影、邻近骨质干扰等）。




图 3.1 典型分割结果示意（占位：可替换为 includegraphics 指向实测截图）

3.9 本章小结

本章在保留“评价指标 + 对比实验表”的主干之外，补充了与**实际代码一致**的训练协议、配置键说明、监控产物路径、风险划分与泄漏防护、阈值搜索逻辑、系统集成演示及任务书交付对照。定稿时请将示例性数值替换为 TensorBoard、

risk_report.json 与整例评估脚本的实测记录, 并按分层分析框架补全讨论段落, 使第 3 章篇幅与工作量相匹配。

4 结论与展望

4.1 工作总结

本文面向毕业设计任务书中“颅内动脉瘤 CTA 的计算机辅助检测与破裂风险预测”的综合要求，在约一个学期周期内完成了**算法调研—工程实现—实验验证—系统集成**的完整链条。与班级内常见的单一分类或分割课题相比，本文的实际工作量体现在两类异构数据（体素张量与表格行）的**并行建模**，以及二者在演示层面的**可选串联**。下文按任务维度归纳具体成果，避免仅罗列文件夹名称而缺少学术表述。

4.1.1 分割子任务：从数据协议到可交付模型

在数据层，本文基于 MedicalPatchDataset 落实了多根目录扫描、影像—标签后缀匹配、体素间距重采样与强度标准化，并针对 CTA 前景极度稀疏的特点采用前景优先补丁采样与背景补丁配比策略；在模型层，采用三维 Attention U-Net，使解码端每个尺度上的跳跃连接在拼接前经过注意力门控滤波，减轻宽阔血管背景对梯度学习的干扰；在优化层，采用二元交叉熵与 Dice 损失的联合目标，并在验证集 Dice 最优准则下维护 best.pth 检查点；在推理层，采用顺序补丁遍历与体积拼接，利用 SimpleITK 恢复 NIfTI 的几何元数据，保证输出可与原始 CTA 在同一坐标系下叠加显示。上述环节均有对应脚本与配置项，形成了可写入毕业论文附录的**可复现流程说明**。

4.1.2 风险子任务：从表格清洗到阈值固定的决策规则

在数据层，风险管线支持缺失值处理、低频类别合并、互信息特征筛选及训练/验证/测试划分；在模型层，RiskCrossAttentionModel 将数值与类别字段映射为 token，经多层双向交叉注意力后再融合预测破裂概率，相比“手工拼特征 + 浅层分类器”更能表达异构字段之间的交互；在训练层，采用加权二元交叉熵缓解类别不平衡，并在验证集上对决策阈值做网格搜索以优化 F1；在产出层，模型权重与 risk_report.json 一并保存，便于答辩时展示 JSON 中的 AUC、F1 与最优阈值。该子任务与分割子任务相对独立，符合临床“先勾画、再统计风险因子”的思维顺序，又便于分工调试。

4.1.3 工程集成与演示

本文在 `train_split.py`、`train_risk.py` 两个入口上统一了 YAML 配置、日志与随机种子策略；提供 TensorBoard 曲线与检查点文件支撑实验章节插图；在 `ui/main.py` 中提供 FastAPI 服务，用于上传 CTA、触发补丁推理及表格风险推断，支撑毕业答辩中的**现场演示**。从软件工程角度，这种“配置驱动 + 脚本入口 + 可选 UI”的结构降低了后续迁移到院内服务器或容器化部署的改造成本。

4.1.4 与参考范式的对照

参考论文以二维显微图像分类为主线，强调频域模块与多尺度骨干网络；本文任务为三维分割与表格二分类，技术难点集中在**体数据 IO 与显存约束、类别不平衡下的决策阈值以及异构特征融合**。因工作侧重点不同，本文未强行套用频域模块，而是在第二章中如实撰写与本项目代码一致的结构与损失，并在第三章用较大篇幅展开实验设计与结果解读框架——对应评委对“工作量是否饱满”的常见问题。

4.2 主要特点与创新点归纳（本科论文尺度）

在不夸大学术创新的前提下，可将本文特点概括为以下几点：

- **任务贴合临床链条**：同时覆盖“瘤体在哪里”的像素级定位与“风险高不高”的个体级预测，体现卒中专病场景下的完整辅助诊断闭环雏形。
- **工程与算法并重**：不仅实现网络前向，还落实病例流式训练、整例几何一致性、风险 JSON 报告等**可交付细节**，避免停留在 Jupyter notebook 级别的原型。
- **实验章节可扩展**：第 3 章已为分层统计、泄漏防护、消融与灵敏度分析预留书写框架，便于在补充实验数据后直接落地为图表。

4.3 不足与展望

4.3.1 数据与评测层面

当前工作流主要面向课题组本地数据形态；未来应在**多中心数据**上开展外部验证，报告 DSC、HD、AUC 的置信区间，并记录不同机型、对比剂方案、重建核

函数对算法的干扰。对于分割金标准，建议逐步过渡到**多人标注 + 仲裁**机制，并在论文中报告标注一致性系数。

4.3.2 算法与建模层面

分割网络仍可探索：轻量级深度可分离卷积、nnU-Net 风格自动配置、基于 Transformer 的长程依赖建模；风险模型可引入**概率校准**（温度缩放、Platt scaling）与**代价敏感学习**，使阈值选择不仅依赖 F1，还能接入临床效用函数。更进一步，可将分割输出经形态学特征提取后作为表格字段的**不确定输入**，研究分割误差向风险预测的传递规律。

4.3.3 系统与合规层面

Web 演示模块当前侧重功能闭环；若要进入院内试点，需要补齐用户鉴权、审计日志、患者隐私脱敏与推理耗时优化（模型蒸馏、TensorRT、分布式推理）。任何面向诊疗决策的输出，都应纳入伦理审查与医疗器械监管路径评估，本文原型不等于医疗器械产品。

4.3.4 个人收获与后续学习计划

通过本课题，作者系统性实践了医学影像深度学习项目的**需求分解—模块实现—实验记录—论文撰写**流程，熟悉了 PyTorch 训练循环、SimpleITK 几何处理与表格建模的基本套路。后续计划在硕士或入职阶段继续补齐统计学与因果推断基础，尝试将辅助诊断系统的评价指标与真实临床结局队列对齐。

4.4 结束语

本文实现了一套面向颅内动脉瘤的辅助分析原型系统：分割分支提供可叠加于 CTA 的三维概率与掩膜输出，风险分支在表格数据上给出可阈值化的破裂概率，并以配置文件与脚本保证了基本的可复现性。受本科毕业设计周期与数据获取条件限制，部分数值实验仍需在后续工作中补全；但就已完成的代码结构与第 3 章所搭建的实验分析框架而言，已为**继续填充真实数据、替换示例表格、形成最终答辩定稿**预留了明确接口。

5 参考文献

参考文献

- [1] Ouyang D, He S, Zhang G, et al. Efficient Multi-Scale Attention Module with Cross-Spatial Learning[J/OL]. arXiv preprint, 2023.
- [2] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//International Conference on Medical image computing and computer-assisted intervention. Springer, 2015: 234-241.
- [3] Çiçek Ö, Abdulkadir A, Lienkamp S S, et al. 3D U-Net: learning dense volumetric segmentation from sparse annotation[C]//International conference on medical image computing and computer-assisted intervention. Springer, 2016: 424-432.
- [4] Oktay O, Schlemper J, Folgoc L L, et al. Attention u-net: Learning where to look for the pancreas[J]. arXiv preprint arXiv:1804.03999, 2018.
- [5] Isensee F, Jaeger P F, Kohl S A A, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature methods, 2021, 18(2): 203-211.
- [6] Chen S, Xu Z, Zhao X, et al. Coarse-to-fine guided salient object detection for automatic cerebral aneurysm identification[J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 3052-3063.
- [7] Kamnitsas K, Ledig C, Newcombe V F J, et al. Efficient multi-scale 3D CNN with fully connected CRF for accurate brain lesion segmentation[J]. Medical image analysis, 2017, 36: 61-78.
- [8] Ou Y, Hua K L, Cheng X, et al. Automatic diagnosis of 3D cerebral vascular images using deep learning[J]. IEEE Access, 2022, 10: 34281-34291.
- [9] Chen J, Zhuang J, Shen Y, et al. StrokeNet: A multi-task neural network for stroke outcome prediction[J]. NeuroImage: Clinical, 2022, 33: 102927.

- [10] Xiong L, Wang Y, Chen H, et al. Multimodal deep learning for predicting ischemic stroke outcome[J]. IEEE Transactions on Medical Imaging, 2025, 44(2): 523-534.
- [11] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in neural information processing systems. 2017: 5998-6008.
- [12] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [13] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [14] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [15] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [16] Chen H, Zhang Q, Liao R. Road scene parsing with real-time and higher accuracy[J]. IEEE Transactions on Cybernetics, 2021, 52(8): 7851-7863.
- [17] Milletari F, Navab N, Ahmadi S A. V-net: Fully convolutional neural networks for volumetric medical image segmentation[C]//2016 fourth international conference on 3D vision (3DV). IEEE, 2016: 565-571.
- [18] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [19] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [20] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.

6 关键配置与复现实验步骤

6.1 项目结构说明

本项目采用模块化目录布局，便于分工协作与单元测试：

- core/：配置数据结构、YAML 加载与全局随机种子等；
- data/：MedicalPatchDataset 体数据管线、risk_tabular 表格风险数据打包；
- model/：aneurysm 子包存放 Attention U-Net 及组件，risk 子包存放交叉注意力风险模型；
- script/：train_split.py、train_risk.py、eval_split.py、eval_risk.py 等入口脚本；
- ui/：FastAPI 服务与分割辅助函数；
- utils/：日志与通用工具。

6.2 环境配置

Python 建议 3.10+（需与 PyTorch 官方 wheel 匹配）

Python >= 3.8

核心依赖（示例版本号以 environment.yml / 线下测试为准）

torch>=1.9.0

monai>=0.7.0

numpy>=1.21.0

pandas>=1.3.0

scikit-learn>=1.0.0

SimpleITK>=2.1.0

tensorboard

tqdm

fastapi

uvicorn

安装完成后，可通过 `python -c "import torch; print(torch.cuda.is_available())"` 快速检查 GPU 是否对 PyTorch 可见。

6.3 训练流程说明

6.3.1 动脉瘤分割模型训练

1. 准备数据：将 CTA 与标签整理为 NIfTI，目录结构与文件名模式需满足 YAML 中 `file_patterns` 与 `label_suffix`；
2. 编辑配置文件：复制 `config/remote.yaml` 为本地副本，填写 `data.train_dirs`、`eval_dirs`，并根据显存调整 `patch_size`、`patches_per_volume`；
3. 启动训练：`python script/train_split.py -config path/to/your.yaml`，必要时附加 `-resume checkpoints/best.pth`；
4. 监控与评估：浏览器打开 TensorBoard (`tensorboard -logdir logs/tensorboard`)，周期性查看验证 Dice；如需离线评测整例体积，调用 `eval_split.py`。

6.3.2 破裂风险预测模型训练

1. 准备表格数据：Excel/CSV 中包含标签列与病例 ID 列；
2. 在同一 YAML 中打开 `risk.enabled: true`，配置 `excel_path`、`label_column`、`id_column`、特征筛选策略等；
3. 运行 `python script/train_risk.py -config path/to/your.yaml`；
4. 在输出目录查看 `risk_cross_attention.pt` 与 `risk_report.json`，记录测试集 AUC、F1 与最优阈值。

6.4 关键配置参数说明（与仓库默认值对齐）

6.4.1 分割相关

- `train.epochs`：总训练轮数（示例：40）；
- `train.batch_size`：当前实现按病例循环，通常保持 1；

- `train.patch_size`: 补丁立方体边长列表, 如 `[128,128,128]`;
- `train.learning_rate`: 初始学习率 (示例: 10^{-3});
- `train.optimizer`: `adam/adamw/sgd`;
- `train.scheduler`: `cosine/step/none`;
- `train.warmup_epochs`: 写入配置的热身轮数 (可与调度器联动扩展);
- `data.patch_sampling_mode`: 训练推荐 `foreground_priority`, 验证/推理常用 `sequential`;
- `checkpoint.save_interval`: 周期性额外保存间隔;
- `eval_interval`: 每隔多少个 `epoch` 做一次验证并刷新最优模型。

6.4.2 风险相关

- `risk.hidden_dim`、`risk.num_heads`、`risk.num_layers`: 交叉注意力宽度与深度;
- `risk.epochs`、`risk.batch_size`、`risk.learning_rate`: 表格模型优化超参;
- `risk.feature_select_method`: 如 `mutual_info`;
- `risk.auto_max_features`: 自动筛选后保留的最大特征数;
- `risk.threshold_search_steps`: 验证集阈值扫描离散点数 (默认代码中为 19 个采样点)。

6.5 推理与演示

命令行推理脚本 (若仓库提供) 或 UI 服务均可加载训练产物: UI 默认读取 `config/host.yaml`, 可通过启动参数 `-config` 指向含本地权重的副本。部署在内网环境时, 建议关闭不必要的 CORS 全开策略并增加访问控制。

致 谢

7 致 谢

本论文的完成离不开各位老师、同学和家人的支持与帮助。

首先，我要感谢我的指导教师，感谢您在论文选题、研究方法和实验设计等方面的悉心指导，您的严谨治学态度和渊博的专业知识使我受益匪浅。

其次，我要感谢实验室的各位同学，在项目开发过程中，大家互相交流、共同探讨，营造了良好的学术氛围。特别感谢师兄师姐们在技术实现方面给予的宝贵经验和建议。

再次，我要感谢我的家人，感谢你们一直以来的理解、支持和鼓励，让我能够安心完成学业。

最后，感谢所有为本研究提供数据和技术支持的机构和个人。正是有了各方的支持与帮助，本研究才能够顺利完成。

原创性声明

郑重声明：所呈交的论文（设计）《_____》，是本人在导师的指导下，独立进行研究取得的成果。除论文（设计）中已经标注引用的内容外，本论文（设计）不包含其他人或集体已经发表或撰写过的作品成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

论文（设计）作者签名：_____

日期：_____

使用授权书

论文（设计）作者签名：_____

日期：_____

使用授权书

本论文（设计）作者完全了解学校有关保留、使用论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）复印件和电子版，允许论文（设计）被查阅和借阅。本人授权重庆大学将本论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制方式保存和汇编本论文（设计）。

本论文（设计）属于：

保 密 ☐ 在_____年解密后适用本授权书

不保密 ☐

论文（设计）作者签名：_____ 指导教师签名：_____
日期：_____ 日期：_____