

重庆大学本科学士生毕业论文（设计）

动脉瘤精确检测与破裂风险预测



学 生： 申建松

学 号： 20221556

指导教师： 文静

专 业： 计算机科学与技术

重庆大学计算机学院

2026 年 6 月

Undergraduate Thesis (Design) of Chongqing University

**Accurate Detection of Aneurysms and
Prediction of Rupture Risk**



By

SHEN Jiansong

Supervised by

Assoc. Prof. WEN Jing

and

Computer Science and Technology

College of Computer Science, Chongqing University

Chongqing University

June, 2026

摘 要

颅内动脉瘤是较为常见的脑血管异常类型，一旦发生破裂就会引起蛛网膜下腔出血，整体危险性较高。CTA 可以清楚地把载瘤血管和瘤体形态显示出来，但是由于切片数量多、血管分叉关系复杂，再加上骨伪影的干扰，人工阅片时仍然会出现漏检或者判断不一致的情况。与此同时，动脉瘤破裂的风险还会受到年龄、基础病、瘤体形态、瘤体位置等各个因素的影响，只能依靠传统的量表或者统计模型来研究这些变量之间的非线性关系。亟需一种可同步完成影响文档分割与临床风险分层的辅助方法。

为了满足此需求，我们考虑将其分割为两个任务即分割任务与预测任务。在分割任务中，以三维 Attention U-Net 为基础，融入 ASPP 多尺度上下文模块和三维坐标注意力，并在解码端引入注意力门控筛选编码器特征，增强对小目标动脉瘤的捕捉能力；损失函数采用二元交叉熵与 Dice 损失及其变体的组合，兼顾分类精度与区域重叠度。推理阶段采用分块预测并拼接回原始空间。在破裂风险预测任务中，针对表格型临床信息与影像衍生特征，设计了一种基于交叉注意力的深度表格模型，并进一步将其与传统机器学习模型融合，构建融合模型。在此基础上，以配置驱动的方式将分割与风险预测两条流程集成为一个交互式算法演示 GUI 程序，可完成从体数据读取到辅助分析演示的全过程。

实验表明，分割模型在验证集上 Dice 值达 0.8659，IoU 为 0.75。在固定训练、验证、测试划分下，融合模型取得最高 F1 值 0.7330、AUC 0.8568；本文所提的交叉注意力深度表格模型 F1 值 0.7266、AUC 0.8546，整体性能与最优结果接近，且优于逻辑回归、支持向量机及 K 近邻等传统方法。结果表明，所提方法能有效辅助动脉瘤分割与风险分层，具有较好的实际应用价值

关键词：颅内动脉瘤；CTA；三维 Attention U-Net；交叉注意力；破裂风险预测

ABSTRACT

Intracranial aneurysms are a common type of cerebrovascular abnormality. Rupture can cause subarachnoid hemorrhage with high mortality. CTA clearly displays parent vessels and aneurysm morphology, but manual interpretation is prone to missed detections or inconsistent judgments due to large slice counts, complex vessel bifurcations, and bone artifacts. Meanwhile, aneurysm rupture risk is influenced by multiple factors including age, comorbidities, aneurysm morphology, and location. Traditional scoring systems or statistical models struggle to capture nonlinear relationships among these variables. Therefore, developing an auxiliary method that can stably segment aneurysms from images and combine clinical information for risk stratification has strong practical value.

To address this need, we propose two reproducible technical pipelines. For the segmentation task, we employ a derivative model of 3D Attention U-Net, which further incorporates an ASPP multi-scale context module and a 3D coordinate attention module on top of the base 3D Attention U-Net architecture. The base model retains U-Net's multi-scale skip connections but adds attention gates in the decoder to filter encoder features, enabling the network to more clearly capture aneurysm and surrounding region characteristics. The loss function combines binary cross-entropy and Dice loss with its variants, balancing classification accuracy and region overlap to achieve better segmentation performance for small objects like aneurysms. During inference, the model performs patch-based prediction on entire cases and stitches results back to the original space for subsequent use.

Secondly, for the rupture risk prediction task, we propose a cross-attention-based deep tabular model for tabular clinical information and imaging-derived features. Compared with traditional machine learning models or standalone deep tabular models, the fusion model combining it with traditional machine learning networks demonstrates better generalization performance.

In the implementation of the aneurysm segmentation model, our model achieves a Dice coefficient of 0.8659 and an IoU of 0.75 on the validation set. For the risk prediction model, under fixed training, validation, and test splits, we conducted offline comparisons of the proposed model with random forest, logistic regression, support vector machines, k-nearest neighbors, and ensemble models. Results show that the ensemble model achieves the highest F1 score of 0.7330 and AUC of 0.8568 on the test set; our cross-attention model achieves an F1 score of 0.7266 and AUC of 0.8546, with overall performance close to the best results and superior to standalone logistic regression, support vector machines, and

k-nearest neighbors methods.

Overall, we connect the segmentation and risk prediction pipelines through a configuration-driven approach and provide a simple interactive interface, completing a full closed loop from volume data reading to auxiliary analysis demonstration.

Key words: intracranial aneurysm; CTA; 3D segmentation; Attention U-Net; tabular learning; cross-attention; rupture risk prediction

目 录

摘要.....	I
ABSTRACT.....	II
1 绪论.....	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 传统动脉瘤与脑血管影像分析的途径	2
1.2.2 分割与多模态预测的深度学习实现	2
1.2.3 当前研究仍然存在的不足之处	3
1.3 本文面临的问题与主要思路	3
1.4 课题来源与研究内容	3
1.5 论文结构安排	4
1.6 本章小结	4
2 相关理论基础.....	5
2.1 脑动脉瘤及分割基本原理	5
2.2 医学图像分割基本理论	6
2.3 卷积神经网络与 U-Net 结构	7
2.4 注意力机制与 Attention U-Net	7
2.5 类别不平衡与损失函数设计	8
2.6 表格数据学习与特征表示理论	9
2.7 临床风险评分与深度模型的互补关系	10
2.8 评价指标基础	11
2.9 本章小结	12
3 模型设计.....	13
3.1 研究方法总体框架	13
3.2 分割任务的理论基础与建模动机	14
3.3 动脉瘤分割模块设计	15
3.3.1 输入表示与数据采样机制	15
3.3.2 三维 Attention U-Net 主干结构	16
3.3.3 注意力门控跳跃连接机制	17
3.3.4 ASPP 多尺度上下文增强模块	18
3.3.5 三维坐标注意力模块	18
3.3.6 输出映射与整例重建	19

3.3.7 分割损失函数和优化目标	20
3.4 破裂风险预测模块设计	21
3.4.1 多源特征表示与问题定义	21
3.4.2 交叉注意力特征交互机制	23
3.4.3 全局聚合与风险概率输出	23
3.4.4 风险预测损失函数	24
3.5 训练与优化过程	24
3.6 本章小结	25
4 实验与结果分析	26
4.1 实验设计概述	26
4.2 实验环境及基本设置	26
4.3 评价指标	27
4.3.1 分割任务评价指标	27
4.3.2 风险预测评价指标	28
4.4 动脉瘤分割实验	29
4.4.1 实验目的与训练过程	29
4.4.2 分割结果和阈值分析	30
4.4.3 可视化分析与误差来源	30
4.4.4 分割模型消融分析	31
4.5 破裂风险预测实验	32
4.5.1 实验目的与模型设置	32
4.5.2 对比实验结果	33
4.5.3 阈值选择与不平衡分类讨论	34
4.5.4 风险模型结果讨论	34
4.6 结果综合讨论	35
4.7 系统展示	36
4.8 本章小结	37
5 总结与展望	38
5.1 研究工作总结	38
5.2 主要研究结论	38
5.3 研究不足	39
5.4 未来工作展望	40
5.5 结束语	41
参考文献	42

附录 A：关键配置与复现实验步骤.....	45
致谢.....	47
原创性声明和使用授权书.....	48

1 绪论

1.1 研究背景与意义

我国居民死因构成中，脑血管疾病常年排在靠前位置，颅内动脉瘤也就是 Intracranial Aneurysm 即 IA，在无症状阶段时，往往会在影像学检查过程中被偶然发现。瘤壁完整性一旦被破坏，就可能造成蛛网膜下腔出血，病情通常比较凶险，遗留神经功能障碍的比例也不容忽视。数字减影血管造影即 DSA 被当作诊断的“金标准”来使用，但它属于有创检查，并且在费用方面也存在一定限制，因此较难在大规模筛查场景中开展普及。CT 血管成像也就是 CT Angiography 即 CTA，具有无创以及临床可及性较高的特性，在当前门诊以及急诊环境当中，是开展动脉瘤检出和术前评估工作的重要工具^[1,2]。近年来，深度学习方法在医学影像分析中的应用不断增多，相关综述和代表性工作表明，U-Net、3D U-Net、Attention U-Net 和 nnU-Net 等结构已经成为医学图像分割任务中的重要基础模型^[3-8]。其中，分割任务的核心目标是准确识别 CTA 中的动脉瘤位置和边界，为后续定量分析提供可靠的空间掩膜。由于动脉瘤体积通常较小，且与周围血管、骨结构和噪声背景相互交织，分割模型既需要足够大的三维感受野来捕捉上下文信息，也需要保持较高的空间分辨率来恢复病灶边界，这也是三维卷积、注意力门控和多尺度特征融合广泛应用于该任务的重要原因。

与此同时，动脉瘤研究并不只停留在“是否存在病灶”的层面，更重要的是进一步评估其破裂风险。临床是否需要开展干预工作，判断依据不只是存在动脉瘤这一核心事实，还要结合瘤体大小、形态规则度、位置、患者年龄和合并症等各方面因素来综合考虑；目前临床诊断过程中还会参照 PHASES 以及日本 UCAS 等研究得出的自然病程规律和风险评估标准^[9,10]。因此，破裂风险预测任务的目标是将影像分割结果、病灶形态特征以及病例层面的临床信息联合起来，建立病例级风险判断模型。该类模型不仅需要处理影像数据中的空间结构信息，还需要融合表格数据中的异构变量，从而学习动脉瘤形态、临床背景与破裂结局之间的复杂关联关系。只有病灶分割掩膜和风险预测结果一起才能完成完整的临床规划工作。

近些年来，依靠以多层神经网络为中心的深度学习技术，医学影像分割任务已经有了较多的进展。全卷积网络以及 U-Net 族结构可以输出像素级的病灶概率图，从而把临床医师进行标注辅助工作的时间缩短了^[5,11]；三维卷积网络可以直接对沿血管走向的上下文信息进行建模，同时对瘤体层间连续性等形态学特征的识别也更加有利^[6,12]。Attention U-Net 在解码路径中引入了注意力门控单元，可以引导网络把重点放在任务相关的空间区域上，同时模型的分割表现也得到提高，相关效果已经在腹部脏器、胰腺等分割任务中得到验证^[7]。nnU-Net 的应用结果表明，

在做医学分割任务时，除了网络骨架之外，数据预处理、补丁采样、后处理等环节都会对最终结果造成影响^[8]。在脑血管研究领域，已经有工作把粗定位和细分割结合起来使用，或者用多尺度三维卷积来提高细小病灶的检出率^[1,2,13]。与此同时，融合动脉瘤临床信息以及本体属性的风险预测网络也已经出现，这进一步说明“影像+临床”的联合建模路径具有实际应用价值^[14,15]。在表格数据学习领域当中，注意力机制也被广泛用于多维临床字段之间的交互建模，这给本项目风险预测模块的设计提供参考。

根据以上背景，本文就动脉瘤自动分割定位和破裂风险概率预测这两个相互衔接的子问题，创建出一套以配置文件为驱动、可以利用脚本进行复现的软件系统。一方面可以减轻医师处理体数据时重复勾画的工作量，另一方面也为后续融合影像组学特征、形态学参数和表型数据预留了工程接口，有比较明确的辅助诊疗价值，也为整合医学影像和临床信息的医学软件系统提供了一套完整的方案。

1.2 国内外研究现状

1.2.1 传统动脉瘤与脑血管影像分析的途径

在深度学习还没有大规模应用的时候，血管分割、病灶提取等任务基本都是用传统的图像处理方法来完成的，常用的有基于强度的阈值分割、区域生长、水平集方法，以及部分基于几何先验设计的滤波器。在这样的处理流程中，种子点、平滑核大小、曲率约束等参数一般要人工去调整。同时该类方法对于低对比度瘤颈、邻近骨质的高密度灶等干扰因素比较敏感，在面对不同的数据集时，还需要重新做调参工作。风险评估环节中，临床诊断一般会使用 Hunt-Hess 分级、WFNS 评分、PHASES 评分等规则体系，其中 PHASES 更重视未破裂动脉瘤的后续破裂风险^[9]。评分体系比较简洁，而且有较强的可解释性，比较适合临床沟通；但是不能很好地捕捉瘤体形态不规则、局部血管形态变化、影像纹理等非线性特征。统计学习阶段常用的逻辑回归、随机森林等传统机器学习模型，可以给出可解释的结果，但是对多维关联特征的自动建模能力还有待提高。

1.2.2 分割与多模态预测的深度学习实现

随着公开数据集和算力条件的不断改善，U-Net 以及三维变体已经逐渐成为血管和病灶分割领域的主要网络骨架^[5,6]。nnU-Net 相关的研究更重视预处理、网络拓扑、后处理等环节的自动化配置工作，从而提高跨任务迁移的效率^[8]。颅内动脉瘤相关研究中，一种技术路径就是建立从血管分割到瘤体检测的多阶段处理流程，另一种技术路径就是使用注意力和多尺度模块来加强细小结构识别的效果^[1,2]。同时也有使用超分辨率进行数据预处理优化模型分割效果的实现^[16]，有效降低了 cta

模糊带来的效果降低的影响。在预测研究中，Transformer 和注意力机制给序列化、多模态特征融合提供了一种比较标准的实现方式^[17]，像 StrokeNet 这样的多任务结构可以对影像信息和临床信息进行编码，最后得到卒中结局的预测结果^[14]。这些研究结果共同表明，分割精度和下游临床推理并不是彼此割裂的，高质量掩膜既可以用于手术规划，也可以把形态学等衍生特征当作载体来使用。

1.2.3 当前研究仍然存在的不足之处

当前的部分研究仍主要集中在单一的任务部分，比如单独对动脉瘤或者对象进行分割^[8,11,12,18]。其虽取得了较好的效果，却并未使用动脉瘤的分割结果与形态学特征进行后续的处理以生成完整的临床风险预测参考，这导致了模型仅能分割动脉瘤却无法继续为医师生成较为完善的可供参考的临床诊断。同时 Ishikawa^[19]的工作虽然进行了动脉瘤分割，但是在后续的处理中单独使用 UCAS 的报告结果，并未充分利用现有的结果。亦有完善了二阶段任务，但仍然需要人手工对特征处理^[20]的缺点。其部分虽然取得了较好的预测效果，但是在数据变更或出现不同数据条件时，人手工往往难以快速完成特征转换。

1.3 本文面临的问题与主要思路

根据已有研究文献以及实际工程经验，本文将本次任务遇到的难点归纳为三个方面。（1）体数据占用和显存的矛盾，单份完整的 CTA 数据体积可达数百兆字节，如果一次性加载多组病例批次全部数据，普通 GPU 一般无法完成相应的运算需求，因此需要在流式 IO、补丁采样、梯度更新等环节上进行调整。（2）前景极度稀疏，动脉瘤对应的体素在整幅体积中所占的比例非常小，单独使用交叉熵损失时，模型很容易把预测结果偏向背景，因此需要采用区域重叠型损失和采样策略共同约束。（3）风险标签与特征的异质性，破裂和未破裂病例的样本分布不均，类别字段中还存在着长尾取值，因此需要配合合理的加权损失、阈值搜索、特征筛选步骤，来防止模型只学习到训练集分布而造成过拟合。

针对以上问题，本文提出了一种“分割骨干 + 表格风险预测”的系统级方案。分割模块使用三维 Attention U-Net，病例级流式训练和前景优先补丁采样一起做；风险评估模块用基于交叉注意力的表格模型，对数值特征、类别特征做统一处理，在验证集上做决策阈值搜索。

1.4 课题来源与研究内容

本课题来源于指导教师下发的毕业设计任务书，研究的主要任务有两个，一是对颅内动脉瘤的 CTA 数据进行计算机辅助检测，二是利用临床表型和影像衍生特

征来实现破裂风险的二分类预测。本文具体工作为：

1. 用 AttentionUnet 搭建三维分割网络的编码器—解码器通道配置、注意力门控和带 sigmoid 输出的端到端前向传播全过程；
2. 在 MedicalPatchDataset 上做多目录数据扫描、重采样和标准化工作，设置前景优先和顺序采样两种可选策略，支持低显存条件下的长时间训练；
3. 使用配置化的优化流程，对 Dice/ Tversky/ Focal 和 BCE 的组合损失、Adam/ AdamW/ SGD 优化器和余弦退火策略进行统一的管理，把训练过程写入 TensorBoard，按设定的间隔保存最新的模型和验证集最优模型；
4. 推理阶段将补丁结果拼接成完整的体积，对 spacing、origin、direction 进行恢复，输出概率体和二值掩膜，便于之后做可视化或者形态学特征提取；
5. 完成表格风险数据清洗、互信息特征筛选、加权 BCE 训练、验证集 F1 最优阈值搜索、测试集报告导出等流程构建；
6. 搭建一套基于 FastAPI 的交互界面，用于开展文件上传、分割、风险预测等流程。

1.5 论文结构安排

本文共分为五章。第一章主要对研究背景、国内外研究现状、当前问题难点以及本文的核心内容进行阐述。第二章对医学图像分割、三维卷积网络、注意力机制、类别不平衡学习、表格建模等方向的理论基础进行整理。第三章以系统整体架构为研究对象，分别对分割模块和风险模块的模型设计思路 and 实现要点进行说明，并简要介绍 Web 服务接口。第四章列出实验运行环境、数据集及预处理规则、评价指标和结果分析框架，说明如何依靠日志和配置文件复现相关指标。第五章对全文进行总结，并对后续可行改进方向进行展望。

1.6 本章小结

本章主要从颅内动脉瘤辅助分析研究动机出发，从临床实际需求和现有技术发展趋势两个方面进行了说明，对传统的和深度学习的方法进行了比较，总结出本文要解决的三个主要问题以及相应的思路，对应该与源代码模块相对应的研究内容做了列举。之后还会继续对算法以及系统实现做更多的展开。

2 相关理论基础

2.1 脑动脉瘤及分割基本原理

脑动脉瘤是指脑血管壁局部异常膨出后形成的囊状或者梭形结构，常见发生位置为脑底部 Willis 环及其主要分支。CTA 图像上脑动脉瘤一般会显示为血管壁局部的囊状突起，也就是“气球样”或者“浆果样”的异常膨出结构。

瘤颈即 neck，是指动脉瘤与载瘤动脉之间的连接部位，它的宽度以及形态对临床诊断和治疗方案的选择有着重要的意义。




图 2.1 实际脑动脉瘤 CTA 影像示例

如图2.1所示，红色箭头指示的区域上部血管轮廓较正常，下部箭头所指位置可以看见血管突然膨大，有典型的脑动脉瘤病灶表现。

图像分割是指将图像划分为若干具有语义一致性的区域，并从中提取出感兴趣目标的过程。在医学影像分析中，分割是病灶量化、三维可视化与辅助诊断的基础。对于颅内动脉瘤的 CTA 图像而言，分割任务要求算法能够自动识别动脉瘤区域，并将其与载瘤血管、骨质及周围软组织逐像素区分开来。该任务面临的主要难点包括：动脉瘤本身体积小、形态多变，极易受骨伪影和血管分叉复杂结构的影响；目标与背景间的像素占比严重不平衡，易导致小目标漏检；瘤颈与载瘤动脉的界限模糊，使得边界精确勾画更加困难。

传统的分割方法（如阈值法、区域生长法、水平集方法等）多依赖人工设计的图像特征，在面对动脉瘤形态多变、噪声干扰大的情况时鲁棒性不足。近年来，以 U-Net 为代表的深度学习分割网络通过编码器-解码器结构结合跳跃连接，能够端

到端地学习多层次特征表示，在医学图像小目标分割中表现出显著优势，已成为动脉瘤分割的主流技术路线。本文正是在此基础上，通过引入注意力机制与多尺度上下文模块，进一步增强网络对动脉瘤及其周边结构的建模能力。

2.2 医学图像分割基本理论

医学图像分割是用像素或者体素来完成目标解剖结构的精确定位，属于密集预测即 dense prediction 任务。与自然图像分割不同的是，CTA 体数据有三维空间连续、前景占比很小、病灶形态差异大等特点。因此，模型不仅要局部边缘和纹理信息进行捕捉，还要保证跨层面的空间一致性。该研究范式已经在医学影像深度学习综述中得到明确论证^[3,4,21]。

从数学形式上看，三维医学图像分割可以表示成对每个体素位置 $u \in \Omega$ 的类别估计问题，其中 $\Omega \subset \mathbb{R}^3$ 是体数据空间的定义域。给定输入图像 $X \in \mathbb{R}^{H \times W \times D}$ ，模型要学习条件概率 $p(y_u = 1 | X)$ ，根据它来生成概率图 $P = \{p_u\}_{u \in \Omega}$ 。给定一个阈值 $\tau \in [0, 1]$ ，二值分割结果就可以表示为：

$$\hat{y}_u = \mathbb{I}(p_u \geq \tau) = \begin{cases} 1, & \text{if } p_u \geq \tau \\ 0, & \text{otherwise} \end{cases} \quad (2.1)$$

其中， $\hat{y}_u$ 表示体素 u 的二值分割结果， p_u 表示该体素属于前景的预测概率， τ 是用于二值化的阈值， $\mathbb{I}(\cdot)$ 为示性函数。分割模型应该输出有空间连续性的概率分布，在局部边界处也要保持足够的敏感性。对于动脉瘤分割任务，我们期望模型能够在最小化预测边界与真实边界之间的距离同时最大化区域重叠度。这种密集预测任务的优化目标可以形式化为：

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{(X,Y) \sim \mathcal{D}} [\mathcal{L}(f_{\theta}(X), Y)] \quad (2.2)$$

其中， θ 表示模型参数， θ^* 为最优参数， X 为输入图像， Y 为真实标签， $\mathcal{D}$ 为训练数据分布， $\mathcal{L}$ 为损失函数， $f_{\theta}(X)$ 为模型对输入图像的预测结果。分割模型需要在局部纹理特征和全局上下文信息之间取得平衡，使风险预测模型能更准确地捕捉到病灶形态的细节。

对于颅内动脉瘤分割任务来说，准确的分割结果可以给临床提供直观的可视化依据，还可以计算出瘤体体积、最大径、形态不规则度等量化指标，是后续破裂风险评估的重要基础。

在经典的监督学习框架中，训练样本由输入图像 X 和金标准标签 Y 组成，模型的目标就是学习从 X 到 Y 的映射函数 $f_{\theta}(X)$ 。由于医学图像标注成本高、类别分布极度不平衡、成像条件复杂，实际训练中需要在网络结构、损失函数、采样策

略之间进行权衡，从而兼顾模型表达能力与训练稳定性。

2.3 卷积神经网络与 U-Net 结构

卷积神经网络即 CNN，依靠局部感受野、权值共享以及层级特征提取的方式，可以较好地利用图像中层次化的特征。对于一个三维卷积操作，其输出特征可以表示为：

$$F_{l+1}(x,y,z) = \sigma \left(\sum_{c=1}^{C_l} \sum_{i=-k}^k \sum_{j=-k}^k \sum_{m=-k}^k W_c(i,j,m) \cdot F_l(x+i,y+j,z+m) + b \right) \quad (2.3)$$

其中， F_l 和 F_{l+1} 分别表示第 l 层和第 $l+1$ 层的特征图， (x,y,z) 是三维空间位置， C_l 表示第 l 层的通道数， $W_c(i,j,m)$ 为第 c 个通道对应的三维卷积核权重， k 为卷积核半径， b 为偏置项， σ 为非线性激活函数。

对于分割任务，Fully Convolutional Network 即 FCN 第一次把分类网络扩展到像素级预测，实现端到端的密集输出^[11]。U-Net 在此基础上采用对称的编码器-解码器结构和跳跃连接即 skip connection，使浅层细节信息和深层语义信息得到融合。编码器的每一层可以表示为：

$$E_i = \text{DownSample}(\text{ConvBlock}(E_{i-1})), \quad i = 1, 2, \dots, L \quad (2.4)$$

其中， E_i 表示第 i 层编码器特征， E_{i-1} 表示上一层输入特征， $\text{ConvBlock}(\cdot)$ 表示卷积块操作， $\text{DownSample}(\cdot)$ 表示下采样操作， L 为编码器层数。解码器通过上采样和特征拼接恢复空间分辨率：

$$D_i = \text{ConvBlock}(\text{UpSample}(D_{i+1}) \oplus E_{L-i}), \quad i = L-1, \dots, 0 \quad (2.5)$$

其中， D_i 表示第 i 层解码器特征， D_{i+1} 表示下一层解码输入， $\text{UpSample}(\cdot)$ 表示上采样操作， E_{L-i} 表示与当前尺度对应的编码器特征， $\oplus$ 表示通道维度上的拼接操作。这种结构大大地提高了医学图像分割的效果^[5]。

由于三维医学图像在层间有很强的连续性，3D U-Net 把二维卷积替换成三维卷积和三维上采样，可以同时得到切片内部和切片之间空间上下文信息^[6,22]。V-Net、UNet++、nnU-Net 等后续出现的模型对体素级残差建模、跳跃连接设计、自动化配置等进行了改进，从而提高了医学图像分割性能^[8,12,23]。但是三维卷积也会带来更大的计算量和内存占用，因此实际应用中会采用补丁训练 (patch-based training)、流式加载 (streaming loading)、混合精度训练 (mixed precision training) 等方式来减轻资源的压力。

2.4 注意力机制与 Attention U-Net

注意力机制的核心就是使模型可以自动地把焦点放在与当前任务有关的区域上。Attention Gate 模块的数学表达如下：给定编码器特征 $F^e \in \mathbb{R}^{C \times H \times W \times D}$ 和解码器特征 $F^d \in \mathbb{R}^{C \times H \times W \times D}$ ，首先通过线性变换将它们映射到相同的维度：

$$q = W_q F^d, \quad k = W_k F^e \quad (2.6)$$

其中， q 和 k 分别表示由解码器特征 F^d 与编码器特征 F^e 经过线性变换得到的查询和键表示， W_q 与 W_k 为可学习映射矩阵。然后计算注意力分数并生成空间权重图：

$$\alpha = \sigma(\psi^T \cdot \text{ReLU}(W_q F^d + W_k F^e + b)) \quad (2.7)$$

其中， α 为注意力权重图， ψ 为可学习的参数向量， b 为偏置项， σ 为 sigmoid 激活函数， $\text{ReLU}(\cdot)$ 为线性整流函数，且 $\alpha \in (0, 1)$ 。最终的加权特征为：

$$\tilde{F}^e = \alpha \odot F^e \quad (2.8)$$

其中， $\tilde{F}^e$ 表示经过注意力筛选后的编码器特征， α 为注意力权重图， F^e 为原始编码器特征， $\odot$ 表示逐元素乘法。本质上完成的是空间特征的选择，即当某个位置更有可能是动脉瘤或者邻近血管的时候，该位置的权重就会被提高，而反之则被抑制。用这样一种方式，可以降低背景干扰，同时较好地保持了 U-Net 对于局部边界细节的敏感性^[7]。

2.5 类别不平衡与损失函数设计

颅内动脉瘤在 CTA 体数据中所占比例很小，一般不到 0.1%，而且空间分布不均。如果只用标准交叉熵损失，模型很容易陷入“全部预测为背景”的平凡解，造成整体准确率虚高，但是病灶检出能力差。因此需要引入一种以前景区域重叠程度为标准的损失函数。

在损失函数设计上，一般会用二元交叉熵即 BCE 来作为基础：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (2.9)$$

其中， $\mathcal{L}_{\text{BCE}}$ 表示二元交叉熵损失， N 为样本或体素总数， y_i 为第 i 个样本的真实标签， p_i 为对应预测概率。再加入区域重叠型损失或者难分割病例挖掘型损失^[24-26]。Dice 系数定义为预测区域与真实区域的重叠度：

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|} = \frac{2 \sum_i p_i g_i}{\sum_i p_i + \sum_i g_i + \epsilon} \quad (2.10)$$

其中, P 表示预测前景集合, G 表示真实前景集合, p_i 和 g_i 分别表示第 i 个体素的预测值和真实值, ε 为平滑项。对应的 Dice 损失为:

$$\mathcal{L}_{\text{Dice}} = 1 - \text{Dice} \quad (2.11)$$

其中, $\mathcal{L}_{\text{Dice}}$ 表示 Dice 损失, 用于度量预测区域与真实区域的差异。Tversky 损失是 Dice 损失在假阳性与假阴性惩罚权重上的推广, 在训练过程中对错误类型更加敏感, 定义如下:

$$\mathcal{L}_{\text{Tversky}} = 1 - \frac{TP + \varepsilon}{TP + \alpha FP + \beta FN + \varepsilon} \quad (2.12)$$

其中, $\mathcal{L}_{\text{Tversky}}$ 表示 Tversky 损失, TP 、 FP 、 FN 分别表示软预测意义下的真阳性、假阳性和假阴性, α 、 β 为两类错误的权重系数, ε 为平滑系数防止除零, 通常满足 $\alpha + \beta = 1$ 。当 $\alpha = \beta = 0.5$ 时, Tversky 损失退化为 Dice 损失; 当 $\alpha \neq \beta$ 时, 可以对不同错误类型施加不同的惩罚。

Focal 损失通过降低易分类样本的损失贡献, 使优化过程更加关注难分类体素:

$$\mathcal{L}_{\text{Focal}} = -\frac{1}{N} \sum_{i=1}^N [y_i(1-p_i)^\gamma \log(p_i) + (1-y_i)p_i^\gamma \log(1-p_i)] \quad (2.13)$$

其中, $\mathcal{L}_{\text{Focal}}$ 表示 Focal 损失, $\gamma \geq 0$ 为聚焦参数, y_i 和 p_i 分别表示第 i 个样本的真实标签和预测概率, N 为样本总数。 γ 用来控制难易样本的权重差异, 当 $\gamma = 0$ 时, Focal 损失退化为标准交叉熵损失。

在实际应用中, 常采用组合损失函数如 bce+tversky 或者 bce+focal 以兼顾不同优化目标:

$$\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{BCE}} + \lambda_2 \mathcal{L}_{\text{Tversky}} + \lambda_3 \mathcal{L}_{\text{Focal}} \quad (2.14)$$

其中, $\mathcal{L}_{\text{total}}$ 表示组合损失, λ_1 、 λ_2 、 λ_3 为各损失项的权重系数, 分别对应二元交叉熵损失、Tversky 损失和 Focal 损失。上述损失函数从不同角度缓解前景稀疏问题, 为后续分割模型训练目标设计提供理论依据。

对于动脉瘤破裂风险预测任务来说, 由于正负样本都存在着不平衡的情况, 一般会使用正类加权或者基于验证集的阈值优化策略来提高模型对少数类即破裂组的敏感性。

2.6 表格数据学习与特征表示理论

除了影像数据之外, 临床信息、人口统计学特征、既往病史等一般会用结构化表格的方式存储。传统的机器学习方法, 逻辑回归、随机森林等, 在特征维度低的

时候会有一定的优势，但是当遇到高维混合特征，即数值型和类别型特征同时存在时，模型的表达能力就会受到很大的限制。

近些年来，深度表格学习开始借鉴 NLP 中的 Token 化思想，将每个特征字段映射为统一维度的隐向量。对于数值型特征 $x_i \in \mathbb{R}$ ，通过线性投影得到嵌入表示：

$$h_i = W_i x_i + b_i, \quad h_i \in \mathbb{R}^d \quad (2.15)$$

其中， x_i 表示第 i 个数值型特征， W_i 和 b_i 为可学习参数， h_i 为映射到 d 维空间后的嵌入表示。对于类别型特征，使用查找表嵌入：

$$h_i = \text{Embedding}_i(x_i), \quad x_i \in \{1, 2, \dots, C_i\} \quad (2.16)$$

其中， x_i 表示第 i 个类别型特征的离散取值， C_i 表示该特征的类别总数， $\text{Embedding}_i(\cdot)$ 为查找表嵌入函数， h_i 为对应的连续向量表示。所有特征的嵌入向量拼接后形成输入序列 $H = [h_1; h_2; \dots; h_F] \in \mathbb{R}^{F \times d}$ ，再通过 Transformer 编码器进行上下文文化：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V \quad (2.17)$$

其中， Q 、 K 、 V 分别表示查询、键和值矩阵， d 为特征维度， $\text{softmax}(\cdot)$ 为归一化函数。该式描述了注意力权重对值向量的加权汇聚过程。

$$H' = \text{LayerNorm}(H + \text{MultiHeadAttention}(H)) \quad (2.18)$$

其中， H 表示输入特征序列， H' 为经过多头注意力与残差连接后的表示， $\text{LayerNorm}(\cdot)$ 为层归一化操作， $\text{MultiHeadAttention}(\cdot)$ 为多头注意力模块。

$$H'' = \text{LayerNorm}(H' + \text{MLP}(H')) \quad (2.19)$$

其中， H'' 为经过前馈网络后的输出表示， $\text{MLP}(\cdot)$ 为多层感知机模块。TabTransformer 使用上下文文化嵌入来增强类别变量的表达能力，FT-Transformer 则证明了对数值字段进行 token 化并且使用 Transformer 编码的有效性^[27-29]。不需要人工创建高阶交叉特征，可以统一处理连续变量和离散变量，给多模态融合提供比较灵活的表示方式。

本文风险预测模块就是按照这个思路来搭建的，同时研究中也保留了随机森林和梯度提升树等传统的集成学习方法，作为小样本表格数据上的重要对比基线^[27-29]。

2.7 临床风险评分与深度模型的互补关系

未破裂颅内动脉瘤的管理不是单纯的图像分割问题。PHASES 评分把人群来源、高血压、年龄、动脉瘤大小、既往蛛网膜下腔出血史、部位等作为影响因素来估计未来的破裂风险^[9]。除此之外，大规模自然病程队列研究也表明，不同部位、不同直径、不同形态不规则程度的动脉瘤，具有不同的破裂倾向^[10]。

上述评分体系有解释性强、使用门槛低的优点，但是它的变量项比较固定，很难对三维分割衍生出的体积、表面不规则度、瘤颈宽度、影像组学纹理等高维信息进行充分的提取。深度学习模型可以很好地在数据充足、划分严格的情况下学习非线性交互。因此将注意力表示学习同传统的机器学习方法进行比较或者融合，可以同时考察非线性表征能力以及小样本稳健性，并为风险预测提供更加全面的方法学参照。

2.8 评价指标基础

分割任务常用以下评价指标：

Dice 系数衡量预测区域与真实区域的重叠程度：

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|} \quad (2.20)$$

其中， P 表示预测前景集合， G 表示真实前景集合，Dice 用于衡量二者的重叠程度。

敏感度 (Sensitivity) 和 **特异度 (Specificity)** 分别反映模型对正负样本的识别能力：

$$\text{Sensitivity} = \frac{TP}{TP + FN}, \quad \text{Specificity} = \frac{TN}{TN + FP} \quad (2.21)$$

其中， TP 、 TN 、 FP 、 FN 分别表示真阳性、真阴性、假阳性和假阴性。分类和风险预测任务一般会用到准确率、精确率、召回率、F1 值和 AUC-ROC 等指标。精确率和召回率定义为：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN} \quad (2.22)$$

其中，Precision 表示精确率，Recall 表示召回率， TP 、 FP 、 FN 的含义同上。F1 值为精确率和召回率的调和平均：

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.23)$$

其中， F_1 为精确率与召回率的调和平均值，用于综合衡量模型的查准率和查全率。AUC-ROC 曲线下面积反映模型整体排序能力，计算公式为：

$$\text{AUC} = \int_0^1 \text{TPR}(\tau) d(\text{FPR}(\tau)) \quad (2.24)$$

其中，AUC 表示 ROC 曲线下面积，TPR 为真阳性率，FPR 为假阳性率， τ 为分类阈值。由于医学管理系统中病灶漏诊的代价大于误诊，本文以召回率为模型的重要评价指标，用 AUC 进行模型性能评价。

对于极度稀疏的医学分割任务，仅依靠总体准确率容易产生误导。因此，在实验代码中同时给出 Dice 系数、体素级 F1、多阈值统计结果以及基于直方图近似的 voxel-wise AUC，从而对模型性能进行更加全面的评价；并且在不平衡二分类场景下，PR 曲线和校准分析同样具有重要的参考价值^[30-33]。

2.9 本章小结

本章对本文研究所必须的理论基础进行了系统的概述，内容包括脑动脉瘤的影像学表现、三维医学图像分割基本问题、U-Net 及其注意力变体、类别不平衡条件下损失函数的设计、表格数据深度表征方法、相关评价指标体系等。这些理论内容为后面章节的模型设计、优化策略、实验分析提供理论支持。

3 模型设计

3.1 研究方法总体框架

本文针对颅内动脉瘤智能分析任务，创建了由病灶分割、破裂风险评价两部分构成的研究架构。本架构依照“病灶定位 → 特征生成 → 风险判别”的基本逻辑展开，先用三维分割网络对 CTA 体数据中疑似动脉瘤区域进行体素级识别，得到病灶概率分布以及空间掩膜，再根据分割结果以及病例层面的临床、形态、影像表型信息建立统一的特征表示，输入风险预测模型，完成患者级破裂概率估计。该流程既满足了医学影像任务中病灶分割的需求，又满足了辅助临床决策的需求。

从形式化上来说，设单例 CTA 体数据记为 $X \in \mathbb{R}^{D \times H \times W}$ ，其对应分割标注为 $Y^{(s)} \in \{0, 1\}^{D \times H \times W}$ ，病例级风险标签为 $y^{(r)} \in \{0, 1\}$ 。本文方法可以形式化表示为

$$P = f_{\theta}(X), \quad (3.1)$$

$$\hat{M} = \mathcal{T}(P; \tau_s), \quad (3.2)$$

$$z = \phi(X, \hat{M}, c), \quad (3.3)$$

$$\hat{p} = g_{\omega}(z), \quad (3.4)$$

其中， $f_{\theta}(\cdot)$ 表示分割网络， X 为单例 CTA 体数据， $P \in [0, 1]^{D \times H \times W}$ 为体素级概率图， $\mathcal{T}(\cdot)$ 为基于阈值 τ_s 的二值化映射， $\hat{M}$ 为二值分割掩膜， c 表示病例层面的临床及影像表型变量， $\phi(\cdot)$ 表示多源特征构造过程， z 为病例级特征表示， $g_{\omega}(\cdot)$ 为风险预测模型， $\hat{p} \in [0, 1]$ 为动脉瘤破裂概率估计。由此，本文把像素级结构识别和样本级风险判别纳入到统一的分析链条中，在保证解剖定位能力的基础上提高风险建模的结构依据。

从任务之间关系上来说，分割模块和风险预测模块不是相互独立的两个过程，而是存在明确的信息传递关系。分割模块给出的掩膜可以继续用作风险模型的特征生成部分，使风险模型更注重有效的病灶结构信息，而不是整幅影像中的无关背景，同时也能实现模型之间的解耦。如果把病例级风险判别看作是条件概率建模问题，那么它就可以表示为

$$\hat{p} = \Pr(y^{(r)} = 1 | X, \hat{M}, c), \quad (3.5)$$

其中， $\hat{p}$ 表示病例级破裂风险概率， $y^{(r)}$ 表示病例级风险标签， X 表示输入影像， $\hat{M}$ 提供病灶位置和形态先验， c 提供病例层面的临床和表型信息。风险预测流程中风险预测不是仅仅依靠原始影像或者单一的临床变量，而是在影像结构信息和病例属性共同约束下进行的。

本文按照三个原则进行整体设计。第一，分割阶段应该以小体积病灶的敏感性为重，以减少漏检对之后分析的影响；第二，特征表示阶段应该尽量保持各个来源变量的一致表达，使连续变量、离散变量、分割衍生变量在同一个隐空间中可以比较、交互；第三，风险判别阶段不能只用线性叠加来建模变量之间条件依赖关系。上述原则共同构成了本文方法设计的总体依据。

本文把两阶段任务理解为有条件依赖关系的分层建模问题。分割阶段给出对潜在病灶区域空间估计，风险预测阶段在空间估计的约束下完成病例级判别。如果用 M 表示真实但是无法直接观测的病灶结构变量，那么风险预测就相当于对下面这个后验概率进行近似：

$$\Pr(y^{(r)} = 1 | X, c) = \int \Pr(y^{(r)} = 1 | M, c) \Pr(M | X) dM. \quad (3.6)$$

其中， M 表示真实但不可直接观测的病灶结构变量， X 为输入影像， c 为病例层面信息， $\Pr(M | X)$ 表示由影像估计病灶结构的后验分布， $\Pr(y^{(r)} = 1 | M, c)$ 表示在给定结构和临床信息条件下的破裂风险条件概率。由于真实结构变量 M 只能通过人工标注或者模型估计来获得，本文使用分割网络输出的概率图 P 和二值掩膜 $\hat{M}$ 来表示它的可计算近似。该表达说明，分割模块的意义不仅在于得到可视化结果，而且在于给下游的风险建模提供对病灶空间位置和形态属性的结构性约束。

本文没有将分割标签和风险标签直接合并成一个目标来降低混淆，而是采用阶段化训练和统一评估的方式。该策略可以分别考察体素级结构识别能力和病例级风险判别能力，使各个模块的误差来源更容易被分析。分割输出所形成的形态特征和空间先验又可以进入风险模型，从而保持两类任务之间的信息关联。

3.2 分割任务的理论基础与建模动机

颅内动脉瘤在 CTA 图像上一般会表现为体积小、边界不清、与邻近血管相互黏连的异常膨出区，给分割任务带来明显的弱小目标、强背景干扰以及类别不平衡等难题。

在此种情况下，仅仅依靠局部卷积感受野就会出现两个方面的问题，浅层特征可以保留较多的空间细节，但是语义判别能力较弱，深层特征虽然有很强的抽象表达能力，但是经过多次下采样之后，病灶的边界细节又会丢失。U-Net 类编码器-解码器结构用跳跃连接较好地解决了这两方面的矛盾，因此成为三维医学图像分割常用的框架。

但是标准 U-Net 对于复杂的血管背景仍然会引入很多和病灶无关的高响应区域。因此本文在主干网络中加入注意力门控机制，用来抑制无关背景特征通过跳跃连接的传播，在瓶颈层加入多尺度上下文增强模块和方向敏感注意力，从而更好地捕捉病灶的尺度变化、形态不规则性和复杂的空间走向。本文的设计思想是病

灶分割不能只依靠局部灰度差异，而应该把局部边界、邻域血管拓扑关系、多尺度上下文信息结合起来进行联合判断。

3.3 动脉瘤分割模块设计

3.3.1 输入表示与数据采样机制

CTA 体数据高维、稀疏、病例间差异大，本文首先对输入体数据做统一空间归一化和强度规范化处理，以消除扫描条件、体素间距、成像范围等不同造成的模型学习干扰。归一化后的三维影像，在训练阶段使用基于局部补丁的学习方式，在有限的显存条件下保持较大的空间上下文范围；验证和测试阶段用覆盖式滑窗完成整例数据推理，保证输出结果的完整性、连续性，减小 patch 边缘的影响。

动脉瘤区域在 CTA 的整个体积数据中所占的比例很小。使用完全均匀的采样策略，训练过程中模型容易被大量的背景区域所主导，从而导致对前景病灶的召回率低。本文使用了一种兼顾前景强化和背景约束的补丁采样机制，在构造训练样本的时候，适当提高病灶及其邻域补丁的出现概率，从而增强网络对于少数类（病灶）的感知能力；同时保留一定比例的背景补丁，帮助模型保持对正常解剖结构的判别边界。该策略本质上属于一种面向类别不平衡场景的数据分布重加权方法，可以有效地提高模型对于小体积病灶的学习效率。设从整例体数据中抽取补丁 x_p 的采样分布为 $\pi(x_p)$ ，则经验风险表示为

$$\hat{R}(\theta) = \frac{1}{B} \sum_{b=1}^B \mathcal{L}(f_{\theta}(x_{p_b}), y_{p_b}), \quad x_{p_b} \sim \pi(x_p), \quad (3.7)$$

其中， $\hat{R}(\theta)$ 表示经验风险， B 为批量大小， x_{p_b} 表示第 b 个补丁样本， y_{p_b} 表示对应标签， $\pi(x_p)$ 为补丁采样分布， $f_{\theta}(x_{p_b})$ 为模型对补丁的预测结果， $\mathcal{L}(\cdot)$ 为损失函数。当前景邻域补丁的采样概率被适当提高时，训练过程中梯度估计会包含更多与病灶相关的局部模式，从而缓解由背景样本占比过高造成的优化偏置。同时保留背景补丁可以防止模型只学习到前景邻域的局部统计特征，从而保持对正常血管以及非目标组织的辨别能力。

局部样本的空间覆盖范围也会影响模型可获得的上下文信息。如果补丁尺寸太小，模型虽然可以得到更多的前景样本，但是不能完整地观察到动脉瘤和载瘤血管之间空间关系；如果补丁尺寸太大，那么单个批次中的前景体素比例就会进一步减少，训练计算负担也会增大。因此，补丁采样要达到局部细节、上下文范围、类别之间的平衡。该折中可以理解为对训练分布 $\pi(x_p)$ 的约束优化，即：

$$\pi^* = \arg \min_{\pi} |\mathbb{E}_{x_p \sim \pi}[r(x_p)] - r_0| + \lambda_c C(x_p), \quad (3.8)$$

其中， π^* 表示最优采样分布， $\mathbb{E}_{x_p \sim \pi}[r(x_p)]$ 表示在分布 π 下补丁前景比例的期望， r_0 表示期望的前景可见程度， $C(x_p)$ 表示上下文不足或者计算代价带来的约束项，

λ_c 为权衡系数。该表达不是要求严格求解采样分布，而是说明补丁构造应该考虑病灶可见性和上下文完整性。

3.3.2 三维 Attention U-Net 主干结构

分割主干采用三维 Attention U-Net。编码器由多层三维卷积块和逐级下采样操作组成，用来提取从低层纹理到高层语义的分层特征；解码器则依靠上采样和特征融合逐步恢复空间分辨率，从而完成精细的体素级预测。设第 l 层编码器特征为 E_l ，解码器特征为 D_l ，则主干网络可以抽象为以下形式：

$$\begin{aligned} E_l &= \mathcal{E}_l(E_{l-1}), \quad l = 1, 2, \dots, L, \\ B &= \mathcal{B}(E_L), \\ D_l &= \mathcal{D}_l(D_{l+1}, \tilde{E}_l), \quad l = L-1, \dots, 1, \end{aligned} \quad (3.9)$$

其中， $\mathcal{E}_l(\cdot)$ 表示第 l 层编码映射， $\mathcal{B}(\cdot)$ 表示瓶颈层特征变换， $\mathcal{D}_l(\cdot)$ 表示第 l 层解码映射， $\tilde{E}_l$ 为经过注意力筛选后的跳跃连接特征。经过由粗到细的层级重建过程，网络可以同时利用深层全局语义信息和浅层边界细节信息，从而提高病灶轮廓恢复能力。

从特征尺度的角度来说，编码器逐级压缩空间分辨率，增大有效感受野，使得高层特征可以表示出病灶和邻近血管上下文的关系；解码器则逐级恢复分辨率，使预测结果重新对齐到原始体素网格。记第 l 层特征的空间尺度为 (D_l, H_l, W_l) 、通道数为 C_l ，那么 $E_l \in \mathbb{R}^{C_l \times D_l \times H_l \times W_l}$ 。随着层级加深， (D_l, H_l, W_l) 逐渐减小而 C_l 通常增加，模型在此处形成了空间精度和语义抽象的层次化表示。跳跃连接的作用就是把浅层的空间细节重新输入到解码路径中去，防止小病灶在连续下采样过程中被过度平滑。

更具体地说，三维卷积块可以看作是在局部邻域内对体素上下文进行加权聚合。输入特征为 $U \in \mathbb{R}^{C_{in} \times D \times H \times W}$ ，卷积核为 $K \in \mathbb{R}^{C_{out} \times C_{in} \times r_d \times r_h \times r_w}$ ，则输出特征在位置 (i, j, k) 的第 c 个通道可写成

$$V_{c,i,j,k} = \sigma \left(\sum_{c'=1}^{C_{in}} \sum_{a,b,m} K_{c,c',a,b,m} U_{c',i+a,j+b,k+m} + b_c \right), \quad (3.10)$$

其中 $\sigma(\cdot)$ 是非线性激活函数。该形式表明，网络用层层局部聚合的方式逐渐扩大感受野，在通道维度上形成多级语义表示。对于动脉瘤这样的小目标结构，浅层卷积主要关注边缘和局部灰度变化，深层卷积则更关注病灶与周围血管的空间关系，二者通过跳跃连接来互补。

编码器和解码器之间的特征融合并不是简单的尺度恢复过程，而是一个语义信息和定位信息重新对齐的过程。把上采样后的解码特征记作 U_l ，跳跃连接特征

记作 $\tilde{E}_l$ ，那么融合操作可以表示为

$$D_l = \rho_l \left(\text{Concat}(U_l, \tilde{E}_l) \right), \quad (3.11)$$

其中 $\rho_l(\cdot)$ 是卷积融合映射。该操作使网络可以利用深层语义来判断目标类别，用浅层细节来修正边界位置，提高小体积分割目标的空间一致性。




图 3.2 三维 Attention U-Net 分割模型结构

图3.2展示了本文用于动脉瘤分割的三维编码器-解码器网络结构。该网络以 3D CTA Patch 作为输入，经过 4 个下采样阶段逐级提取特征，在瓶颈层完成深层语义表示，并通过 4 个上采样阶段恢复空间分辨率。编码器与解码器之间通过 skip connection 建立对应尺度的特征传递，并在跳跃连接处引入 Attention Gate 以筛选更有助于分割的编码特征。网络末端输出单通道分割概率图，经 Sigmoid 映射得到前景概率，用于表示动脉瘤区域的体素级预测结果。

3.3.3 注意力门控跳跃连接机制

传统 U-Net 编码器特征一般直接和对应尺度的解码器特征拼接。虽然可以恢复空间分辨率，但是也会把大量的背景响应一并带入到解码过程中，在血管、骨性结构、噪声干扰强的 CTA 场景下更为明显。为了克服这一问题，本文在跳跃连接中使用了注意力门控机制，让网络可以根据当前解码语义状态来选择具有更好判别性的编码特征。

设同尺度跳跃特征为 s ，来自解码端的门控信号为 g ，则注意力门控为

$$\begin{aligned} q &= \text{ReLU}(W_s s + W_g g + b), \\ a &= \sigma(\psi(q)), \\ \hat{s} &= a \odot s, \end{aligned} \quad (3.12)$$

其中 W_s 、 W_g 是线性投影， $\psi(\cdot)$ 是通道压缩映射， $\sigma(\cdot)$ 是 Sigmoid 函数， a 是取值于 $[0, 1]$ 的注意力权重图， $\odot$ 表示逐元素乘法。该结构本质上是在跳跃连接处添加了条件选择机制，即当某个空间位置和当前解码语义越一致时，该位置的权重就会被放大，反之则被抑制。由此可以降低无关背景特征对后续重建的影响，提高分割结果的病灶聚焦能力。

3.3.4 ASPP 多尺度上下文增强模块

动脉瘤的空间形态在不同的病例中存在差异，局部球囊样膨出和载瘤血管边界过渡不清的复杂结构都有。因此，只用固定尺度卷积核不能很好地描述病灶和其相邻血管的多尺度上下文关系。为了使瓶颈层对不同的尺度模式有较好的响应，本文提出三维 ASPP 模块，利用多分支空洞卷积提取不同感受野下的上下文特征。

设瓶颈输入特征为 X_b ，空洞率集合为 $\{d_1, d_2, \dots, d_K\}$ ，则 ASPP 输出可以表示为

$$Y_{\text{ASPP}} = \phi\left(\text{Concat}\left[\mathcal{F}_{d_1}(X_b), \mathcal{F}_{d_2}(X_b), \dots, \mathcal{F}_{d_K}(X_b)\right]\right), \quad (3.13)$$

其中， $\mathcal{F}_{d_k}(\cdot)$ 表示膨胀率为 d_k 的三维空洞卷积分支， $\text{Concat}[\cdot]$ 表示通道维拼接， $\phi(\cdot)$ 表示后续的线性融合与非线性映射。用同一层次聚合不同的感受野信息，可以更好地体现病灶本体、载瘤血管、局部背景三者之间的关系，提高识别复杂形态病灶的鲁棒性。

3.3.5 三维坐标注意力模块

本文在多尺度上下文建模的基础上，又提出三维坐标注意力模块来加强网络对方向性位置信息的编码能力。与仅用通道重加权的注意力形式不同，坐标注意力是沿各个空间轴汇聚上下文信息，在保持位置依赖关系的基础上产生方向敏感权重，因此更擅长于捕捉血管结构细长、走向复杂的空间特征。

设输入特征为 $X \in \mathbb{R}^{C \times D \times H \times W}$ ，那么沿深度、高度和宽度方向的上下文聚合可以分别表示为

$$Z_d = \text{AvgPool}_{H,W}(X), \quad Z_h = \text{AvgPool}_{D,W}(X), \quad Z_w = \text{AvgPool}_{D,H}(X). \quad (3.14)$$

三路聚合特征经过共享映射和分支解码得到三个方向注意力图 A_d 、 A_h 、 A_w ，最终

输出为

$$Y_{CA} = X \odot A_d \odot A_h \odot A_w. \quad (3.15)$$

该模块用显式的建模空间方向依赖关系来使网络在保持通道语义的同时加强关键位置的响应，有利于提高小病灶边界和空间走向敏感结构的识别精度。




图 3.3 融合 ASPP 与三维坐标注意力的增强分割模型结构

图3.3展示了在三维 Attention U-Net 基础上进一步增强的动脉瘤分割网络。该网络以 3D CTA Patch 为输入，编码器部分由 4 个下采样阶段组成，逐层提取并压缩三维特征；在最底部的瓶颈后接入 3D ASPP 模块，通过不同膨胀率的并行卷积分支提取多尺度上下文信息，并经特征拼接与 $1 \times 1 \times 1$ 投影进行融合。随后，网络引入三维 Coordinate Attention 模块，分别沿 depth、height 和 width 三个方向建模空间依赖关系，以增强方向敏感特征表达。解码器部分由 4 个上采样阶段构成，每一级通过 transposed convolution 恢复分辨率，并与对应编码层特征经 skip connection 融合；每条跳跃连接在进入解码器前都经过 Attention Gate 筛选。最终网络通过 $1 \times 1 \times 1$ 卷积和 Sigmoid 输出动脉瘤二分类分割概率图。

3.3.6 输出映射与整例重建

在解码器末端，网络用 $1 \times 1 \times 1$ 卷积把高分辨率特征映射到单通道对数几率空间，再通过 Sigmoid 函数得到体素级前景概率图：

$$P_{i,j,k} = \sigma(h_{i,j,k}), \quad (3.16)$$

其中 $h_{i,j,k}$ 是位置 (i,j,k) 的输出 logit, $P_{i,j,k}$ 是对应体素属于动脉瘤前景的概率。给定阈值 τ_s , 可以得到二值掩膜

$$\hat{M}_{i,j,k} = \mathbb{I}(P_{i,j,k} \geq \tau_s), \quad (3.17)$$

$\mathbb{I}(\cdot)$ 是示性函数。

整例推理阶段由于输入体积大, 本文用滑窗方式对局部补丁逐块预测, 把各个窗口输出重新映射回原始空间。重叠区域可以用平均融合或者中心区域优先的方法来合并, 从而减小窗口边界效应。由此得到的整例概率图和二值分割结果, 可以用于病灶的可视化, 也可以进一步提取体积、尺寸、形态相关的表型, 为风险预测阶段提供结构化的输入。

根据二值掩膜可以得到一组有解剖意义的形态特征。设单个体素的物理体积为 v_{voxel} , 预测前景体素集合为 $\Omega_{\hat{M}}$, 则病灶体积表示为

$$V_{\text{lesion}} = v_{\text{voxel}} \sum_{(i,j,k)} \hat{M}_{i,j,k}. \quad (3.18)$$

若进一步估计病灶表面积 S_{lesion} , 则可构造球形度等形态描述量, 例如

$$\text{Sphericity} = \frac{\pi^{1/3} (6V_{\text{lesion}})^{2/3}}{S_{\text{lesion}}}. \quad (3.19)$$

该类特征可以从几何的角度来描述动脉瘤大小、外形规则性以及局部结构复杂程度, 给后续病例级风险建模提供可解释的结构化输入。

3.3.7 分割损失函数和优化目标

由于动脉瘤分割具有很强的前景稀疏性, 单独使用逐体素交叉熵损失容易造成模型偏向于背景预测, 从而造成小病灶召回不够。为了兼顾像素级分类准确性和病灶区域分割效果, 本文使用由二元交叉熵损失和重叠敏感损失即 Tversky 损失所组成的联合损失函数来得到更稳定模型。

二元交叉熵损失定义为

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{n=1}^N [y_n \log p_n + (1 - y_n) \log(1 - p_n)], \quad (3.20)$$

其中 N 为体素总数, $y_n \in \{0, 1\}$ 为第 n 个体素的真实标签, $p_n \in [0, 1]$ 为对应预测概率。为了提高模型对于前景区域以及漏检错误的敏感度, 本文提出 Tversky 型损失。设真阳性、假阳性和假阴性分别记为 TP、FP、FN, 则 Tversky 系数可以表示为

$$\text{TI} = \frac{\text{TP}}{\text{TP} + \alpha \text{FP} + \beta \text{FN} + \epsilon}, \quad (3.21)$$

其中 α 、 β 为假阳性、假阴性的惩罚权重， ε 为避免分母为零的平滑项。对应损失可定义为

$$\mathcal{L}_T = 1 - \text{TI}. \quad (3.22)$$

因此，分割阶段总体优化目标写为

$$\mathcal{L}_{\text{seg}} = \lambda_1 \mathcal{L}_{\text{BCE}} + \lambda_2 \mathcal{L}_T, \quad (3.23)$$

其中， λ_1 与 λ_2 为权重系数。该联合目标在理论上同时约束局部判别误差和病灶的错误分割，适合小目标医学图像分割场景。

Tversky 损失中的权重设置可以被看作是对错误类型任务偏好建模。对于医学筛查、辅助诊断任务来说，漏检前景的代价比少量误检大很多，所以可以通过提高 β 来增加假阴性项在损失中的影响。将软预测形式下的三类统计量写成

$$\begin{aligned} \text{TP} &= \sum_{n=1}^N p_n y_n, \\ \text{FP} &= \sum_{n=1}^N p_n (1 - y_n), \\ \text{FN} &= \sum_{n=1}^N (1 - p_n) y_n, \end{aligned} \quad (3.24)$$

损失函数可以对前景区域的重叠关系进行优化，而不会仅仅依靠逐体素独立分类误差。重叠型损失对于前景体素整体的连通性、区域一致性比较敏感，同时又可以提高概率输出的数值稳定性。因此，联合损失在本任务中具有更合理的优化性质。

在优化过程中，模型参数用基于梯度下降的自适应优化算法来更新。设第 t 次迭代的参数为 θ_t ，学习率为 η_t ，则其更新形式可以表示为

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \mathcal{L}_{\text{seg}}(\theta_t). \quad (3.25)$$

由于三维医学图像分割的梯度估计受补丁采样、前景稀疏、病例差异等因素的影响较大，所以训练过程中要结合验证集性能来选择模型，在拟合能力与泛化能力之间取得平衡。记验证集指标为 $S_{\text{val}}(\theta)$ ，那么模型选择可以表示为

$$\theta^* = \arg \max_{\theta_t} S_{\text{val}}(\theta_t), \quad (3.26)$$

其中 S_{val} 可以用 Dice、Recall 或两者综合指标来表示。该策略不会因为训练损失下降而选择模型，从而减少了过拟合给最终分割结果带来的影响。

3.4 破裂风险预测模块设计

3.4.1 多源特征表示与问题定义

风险预测任务关注病例级破裂状态判别，与分割任务的体素级预测不同，其核心在于从多源异构变量中学习稳定的判别表示。设单个病例的输入由数值特征集合 $x^{(n)} \in \mathbb{R}^m$ 与类别特征集合 $x^{(c)} \in \mathbb{N}^q$ 构成，数值特征可以是临床指标、形态学统计量和影像表型描述，类别特征是离散化的病例属性。本文用统一的数据清洗、缺失值处理和标准化方法将不同的数据源映射到可以学习的特征空间中，把问题定义成概率形式的二分类任务：

$$\hat{p} = \Pr(y^{(r)} = 1 \mid x^{(n)}, x^{(c)}). \quad (3.27)$$

本文所研究的是变量之间潜在的非线性交互作用，而不是传统上用手工规则或者浅层线性模型来描述的。某一个形态学指标对风险的影响会受到年龄、病灶位置、其他的影像表型变量的影响，所以简单的线性叠加并不能很好地反映高阶关联。为此，本文使用基于 token 表示和交叉注意力机制的表格深度模型来显式地建立异构字段之间的依赖关系。

为使数值特征和类别特征可以相互作用，在数值特征和类别特征之间建立映射关系时，先将它们映射到维度相同的隐空间。对于第 i 个数值特征 $x_i^{(n)}$ ，本文使用可学习线性变换得到它的嵌入表示：

$$e_i^{(n)} = W_i^{(n)} x_i^{(n)} + b_i^{(n)}, \quad i = 1, 2, \dots, m, \quad (3.28)$$

其中 $W_i^{(n)}$ 和 $b_i^{(n)}$ 是可学习参数。对于第 j 个类别特征 $x_j^{(c)}$ ，它的嵌入表示用查表法得到：

$$e_j^{(c)} = \text{Emb}_j(x_j^{(c)}), \quad j = 1, 2, \dots, q. \quad (3.29)$$

由此，所有的字段都表示为同一个维度的向量，共同组成字段级 token 序列

$$E = [e_1, e_2, \dots, e_{m+q}] \in \mathbb{R}^{(m+q) \times d}, \quad (3.30)$$

其中 d 为隐空间维度。该表示方式使模型可以将每个字段看作独立的信息单元，给后面的注意力交互建模打下基础。

表格数据中各个字段量纲、取值范围、语义等存在差异，直接拼接会导致模型偏向数值尺度大的变量。字段嵌入的作用就是把原始变量从观测空间映射到统一的语义空间，使每个字段都以可学习的 token 形式参与交互。对于标准化后的数值变量，线性嵌入不但保留了变量大小的信息，而且用字段特异参数来刻画变量的语义；对于类别变量，嵌入矩阵把离散状态转化为连续向量，使模型可以学习类别之间的潜在相似性。

若把所有的字段嵌入后的表示当作一个随机变量集合 $\{e_i\}_{i=1}^{m+q}$ ，风险模型的目标不是只估计各个字段的边际贡献，而是学习它们的联合条件分布下的判别函数：

$$g_{\omega}(E) \approx \Pr(y^{(r)} = 1 \mid e_1, e_2, \dots, e_{m+q}). \quad (3.31)$$

该建模方式可以表达出“某一变量的风险含义是由其他的变量取值所决定的条件交互关系”，更符合复杂医学风险因素共同作用的特点。

3.4.2 交叉注意力特征交互机制

本文风险模型的核心思想并不是将所有的字段直接拼接起来再输入分类器，而是用注意力机制自适应地学习字段间的相关性权重。输入 token 记作 E ，经过线性映射得到查询、键、值矩阵：

$$Q = EW_Q, \quad K = EW_K, \quad V = EW_V, \quad (3.32)$$

其中 W_Q 、 W_K 与 W_V 是可学习参数。字段间的相关性用注意力自动计算：

$$\text{Att}(Q, K, V) = \text{Softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V. \quad (3.33)$$

对于多头注意力机制，可以将上述过程扩展为多个子空间并行学习，再通过拼接和线性变换进行融合，从而提高对多类型交互关系的表达能力。

如果再把数值字段流和类别字段流区分开来，那么交叉注意力可以体现一个字段对于另一个字段的条件依赖。数值字段用 $E^{(n)}$ 表示，类别字段用 $E^{(c)}$ 表示，一种典型的跨模态交互形式可以表示为

$$\tilde{E}^{(n)} = \text{Att}(E^{(n)}W_Q^{(n)}, E^{(c)}W_K^{(c)}, E^{(c)}W_V^{(c)}), \quad (3.34)$$

它表示用数值字段作为查询，用类别字段作为键和值来完成对数值特征的捕获。用交替或者叠加这两类交互映射，模型就学会了异构字段之间双向的依赖关系，从而得到具有判别性的病例级表示。

3.4.3 全局聚合与风险概率输出

在完成字段级交互之后，模型要将多 token 表示汇聚成病例级全局表征。设交互后的字段表示为 $H = [h_1, h_2, \dots, h_{m+q}]$ ，可以使用平均池化、注意力池化或者引入全局 token 来得到聚合向量 r ：

$$r = \text{Pool}(H). \quad (3.35)$$

之后用多层感知机完成最终的判别，输出破裂风险概率：

$$\hat{p} = \sigma(W_o r + b_o). \quad (3.36)$$

当给定分类阈值 τ_r 时，可以得到病例级决策结果

$$\hat{y}^{(r)} = \begin{cases} 1, & \hat{p} \geq \tau_r, \\ 0, & \hat{p} < \tau_r. \end{cases} \quad (3.37)$$

此过程使模型可以由字段级局部交互过渡到病例级整体判断，符合临床风险评估中“多因素综合判别”的基本思想。

3.4.4 风险预测损失函数

破裂风险预测可以建模为病例级二分类问题。设第 i 个病例的真实标签为 $y_i \in \{0, 1\}$ ，模型输出的破裂概率为 $\hat{p}_i \in [0, 1]$ 。本文直接使用标准二元交叉熵作为风险预测训练目标，

$$\mathcal{L}_{\text{risk}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)], \quad (3.38)$$

其中 N 为训练样本数。二元交叉熵从最大似然估计角度约束模型输出概率，使阳性病例的预测概率趋近于 1，阴性病例的预测概率趋近于 0。该目标形式简洁、稳定，适合作为风险预测模块的基础优化准则。

本文在训练结束后，并没有把 0.5 作为分类的阈值直接使用，而是根据验证集的概率输出来寻找最优的阈值 τ_r^* ，使综合评价指标达到较好的水平：

$$\tau_r^* = \arg \max_{\tau \in [0, 1]} \mathcal{G}(\tau), \quad (3.39)$$

其中， $\mathcal{G}(\tau)$ 可以是 F1 值、Youden 指数或者其他适合不平衡分类的综合准则。该策略可以使得决策边界符合实际数据分布，从而提高风险预测的应用适配性。

除了分类损失外，风险预测模型还应该考虑概率输出的可解释性。理想的危险概率应该在统计上接近真实发生的概率。如果模型输出在验证集中出现普遍性偏高或者偏低的情况，即使 AUC 较高，它的概率值在临床辅助解释中也会产生偏差。因此，阈值选择和概率校准都是风险预测模型后处理中两个重要的、相互补充的部分，前者用来确定二分类决策边界，后者用来提高概率值的可靠性。本文主要用验证集上的阈值搜索来调整决策边界，在结果讨论部分也对概率校准问题进行了分析。

3.5 训练与优化过程

本文整体训练过程采用监督学习范式。分割任务中，网络用最小化体素级联合损失来学习从三维影像到病灶概率图的映射；风险预测任务中，模型用最小化标准二元交叉熵损失来学习从病例级特征表示到破裂概率的映射。两个任务分别在训练集上进行参数更新，在验证集上完成模型选择和超参数调节，在独立测试集上报告最终性能。

从优化的角度来说，训练过程本质上就是参数空间中寻找经验风险最小化的问题：

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(x_i, y_i; \theta), \quad (3.40)$$

其中 $\mathcal{L}(\cdot)$ 分别对应于不同的任务，即 $\mathcal{L}_{\text{seg}}$ 和 $\mathcal{L}_{\text{risk}}$ 。为了提高训练的稳定性，在优化过程中用到了学习率调度、验证监控、最优检查点保留等策略来减小随机波动带来的影响。既保证了模型可以很好地拟合训练分布，又给后面的实验比较提供了一个统一、可以复核的评价基础。

分割任务中训练目标和评价目标并不是完全一致的。联合损失直接作用于体素概率和区域重叠，最终评价还会受到阈值化、连通性、边界偏移的影响。因此训练过程中要同时观察损失下降趋势和验证集空间指标，防止出现损失不断下降但是二值分割质量不再提高的情况。风险预测任务中训练损失反映的是概率拟合程度，F1、Recall 等指标还依赖于分类阈值，因此验证集阈值搜索应该在训练结束后独立完成，不能把测试集信息用于模型选择。

为了减少过拟合的风险，训练过程中还要加入正则化思想进行约束。深度神经网络常见的正则化方法可以概括为在经验风险的基础上加上参数惩罚项：

$$\theta^* = \arg \min_{\theta} \left[\frac{1}{N} \sum_{i=1}^N \mathcal{L}(x_i, y_i; \theta) + \lambda \Omega(\theta) \right], \quad (3.41)$$

其中 $\Omega(\theta)$ 表示模型复杂度约束， λ 控制正则化强度。对于医学小样本任务来说，正则化、验证集监控、阈值独立选择一起成为防止过拟合和信息泄漏的有效手段。

3.6 本章小结

本章对本文所用的研究方法以及模型设计进行了系统的论述。从整体上来说，本章主要对“分割先验驱动风险评估”进行两阶段的分析思路进行阐述。其次，就三维 AttentionU-Net、注意力门控、ASPP 和三维坐标注意力等主要模块，对动脉瘤分割模型的结构组成、输入输出关系和优化目标进行理论上的描述；再次，对风险预测模型中字段嵌入、交叉注意力交互、全局聚合、加权损失和阈值搜索策略进行形式化说明。总体而言，本文的方法把多尺度空间表征和多源特征融合结合起来，为后面的实验验证和结果分析打下了方法学的基础。

4 实验与结果分析

4.1 实验设计概述

本文实验以动脉瘤分割和破裂风险预测两个方面为研究对象，从体素级病灶识别能力、病例级风险判别能力两个方面来对所提出的方法进行系统的评价。分割实验用 CTA 三维体数据作为输入，考查模型输出的概率图和人工标注的掩膜之间的一致性；风险预测实验用临床信息、影像表型信息、分割衍生特征作为输入，考查模型对动脉瘤破裂状态的区分能力。虽然两项任务在输入形式、输出目标和评价粒度上存在不同之处，但是它们共同服务于颅内动脉瘤智能分析这一总体目标，即在影像结构识别的基础上进一步实现风险评估。

本文在实验组织上严格遵守了训练集、验证集、测试集三者互不干扰的基本原则。训练集用来做模型参数的学习，验证集用来做超参数调节、阈值确定和模型选择，测试集只用来做最终性能的评价，以最小化信息泄漏造成的偏差。本文主要从分割任务的角度出发，对模型在训练后期的收敛稳定性、概率判别能力以及病灶检出能力进行了研究。对于风险预测任务，本文主要对比了深度交叉注意力模型和传统的机器学习模型在多项评价指标上的表现，并且对不同模型的判别特点和适用场景进行了分析。

4.2 实验环境及基本设置

实验是在通用 Linux 计算环境下完成的，深度学习模型使用主流张量计算框架进行训练和推理，医学影像读取、空间重采样、数值计算和统计分析都依靠成熟的科学计算工具来完成。为了保证实验过程的可重复性，所有的实验都是在统一的数据划分、统一的评价口径、一致的训练和验证流程下进行记录的。本文在结果分析中主要对模型表现和方法学意义进行探讨，而不涉及具体的工程实现细节。

输入是三维 CTA 体数据。训练阶段使用局部补丁学习方法来解决显存限制问题，提高小目标病灶在训练过程中可见性；验证阶段使用滑窗方式进行整例推理，保证输出结果有空间完整性。风险预测任务输入是病例级表格特征，数值变量做标准化处理，类别变量做离散嵌入表示，模型输出为病例级破裂概率。考虑到风险预测任务中正负样本分布一般存在不平衡情况，本文在训练阶段使用类别加权策略，在验证集上搜索最优判别阈值，提升模型对于少数类样本的识别能力。

保证比较的公平性，所有的对比模型都采用相同的划分方式，测试集不参与训练、调参和阈值选择。分割实验中模型选择主要根据验证集的重叠指标和阳性检出能力来决定；风险预测实验中，阈值选择只根据验证集输出概率完成，之后将该阈值固定在测试集上报告性能。该设计可以减小由于测试集反馈所造成的乐观偏差，

使实验结果更真实地反映出模型对于未见样本的泛化表现。

从统计学习的角度来说，实验设计的主要问题就是把模型选择过程和最终的性能评价过程分开。训练集、验证集、测试集分别记为 $\mathcal{D}_{tr}$ 、 $\mathcal{D}_{val}$ 、 $\mathcal{D}_{te}$ ，模型参数由训练集确定：

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{|\mathcal{D}_{tr}|} \sum_{(x_i, y_i) \in \mathcal{D}_{tr}} \mathcal{L}(x_i, y_i; \theta), \quad (4.1)$$

超参数和阈值由验证集决定：

$$\hat{\gamma} = \arg \max_{\gamma \in \Gamma} S_{val}(\hat{\theta}, \gamma), \quad (4.2)$$

最终性能只在测试集上计算：

$$S_{test} = S(\mathcal{D}_{te}; \hat{\theta}, \hat{\gamma}). \quad (4.3)$$

γ 可以是分类阈值、模型结构选择或者验证集选择等。上述形式化的描述指出，测试集不能被任何模型选择过程所影响，否则会造成性能估计偏乐观。

医学数据一般存在病例间异质性、标注不确定性和类别分布不均等，因此不能用一个指标来全面地表现模型的行为。本文在分割任务中同时考虑区域重叠、阳性检出、概率排序，在风险预测任务中同时考虑总体判别、阳性识别、阈值敏感性，从而减少由于使用单一评价标准而产生的解释偏差。

4.3 评价指标

4.3.1 分割任务评价指标

分割任务评价要从概率判别能力、区域重叠程度和阳性体素检出能力三方面来考虑。设真实前景集合为 Y ，预测前景集合为 $\hat{Y}$ ，Dice 系数定义为

$$\text{Dice} = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|}. \quad (4.4)$$

Dice 系数越大，说明预测区域和真实区域的重叠程度越大。由于动脉瘤一般体积小，边界的微小偏差就会造成 Dice 明显的波动，所以该指标对于分割质量比较敏感。

从体素级二分类的角度出发，真阳性、假阳性、真阴性和假阴性分别记作 TP、FP、TN 和 FN。召回率定义为

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad (4.5)$$

用来衡量真实前景体素被正确识别出来的比例。对于医学筛查场景来说，召回率具有重要的意义，因为漏检病灶会直接导致后续的临床判断失误。精确率定义为

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad (4.6)$$

用来衡量预测为前景的体素中真实属于前景的比例。另外，Precision 和 Recall 的调和平均可以表示为

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (4.7)$$

AUC 用阈值无关的方式描述模型对前景和背景体素的整体排序能力，可以用来刻画概率输出的可分性。如果用真阳性率 $\text{TPR}(\tau)$ 和假阳性率 $\text{FPR}(\tau)$ 分别表示阈值 τ 下敏感度和误报率，那么 ROC-AUC 就可以形式化地表示为

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(u)) du, \quad (4.8)$$

它的含义就是，在所有的可能的阈值下，综合评价模型把前景体素排序在背景体素之前的能力。

对于边界敏感的分割评估，还可以用 Hausdorff 距离等轮廓指标来表示。设预测边界点集和真实边界点集分别为 A 和 B ，那么 Hausdorff 距离定义为

$$H(A, B) = \max \left\{ \sup_{a \in A} \inf_{b \in B} \|a - b\|, \sup_{b \in B} \inf_{a \in A} \|b - a\| \right\}. \quad (4.9)$$

该指标反映两个边界点集之间的最大偏离程度，适合补充评价分割轮廓的局部极端误差。考虑到小目标分割中边界少量偏差会造成较大指标波动，本文主要以 Dice、Recall、F1 与 AUC 为核心指标，并结合可视化结果讨论边界误差。

4.3.2 风险预测评价指标

风险预测属于病例级不平衡二分类问题，因此只用 Accuracy 来评价模型是不够全面的。Accuracy 定义为

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}, \quad (4.10)$$

反映整体分类正确率，但是在正负样本比例失衡时会忽略模型对少数类样本的识别情况。因此本文同时给出 Precision、Recall、F1 和 AUC 等指标来全面反映模型在风险识别任务上的表现。

对于风险预测模型输出的概率 $\hat{p}_i$ ，其二分类结果由阈值 τ 决定：

$$\hat{y}_i = \begin{cases} 1, & \hat{p}_i \geq \tau, \\ 0, & \hat{p}_i < \tau. \end{cases} \quad (4.11)$$

本文在验证集上搜索较优阈值，并将其固定用于测试集评估。该策略可以利用数据分布以及任务目标自动调整决策边界，从而降低默认阈值对于实验结果的影响。以 F1 值作为选择准则时，可以写成

$$\tau^* = \arg \max_{\tau \in [0, 1]} \frac{2\text{Precision}(\tau)\text{Recall}(\tau)}{\text{Precision}(\tau) + \text{Recall}(\tau)}. \quad (4.12)$$

除此之外，医学风险预测还要考虑概率输出的可解释性和校准性。理想情况下，当模型对一组病例给出接近 p 的风险概率时，该组病例中实际阳性比例也应该接近 p 。将样本按照预测概率分成 K 个区间 B_k ，则期望校准误差可以表示为

$$\text{ECE} = \sum_{k=1}^K \frac{|B_k|}{N} |\text{acc}(B_k) - \text{conf}(B_k)|, \quad (4.13)$$

其中 $\text{acc}(B_k)$ 是第 k 个区间内的真实阳性比例， $\text{conf}(B_k)$ 是平均预测概率。虽然本文主要对分类判别指标进行报告，但是校准分析对于后续的临床使用有着非常重要的意义，因为风险概率不仅会改变二分类决策，还会改变临床复核、随访优先级的安排。

为了方便说明各类评价指标在本文中所起的作用，对本章主要指标以及它们的分析侧重点进行了归纳。

表 4.1 主要评价指标及其分析侧重点

任务类型	指标	主要反映内容
分割任务	Dice	预测区域与真实区域的重叠程度
分割任务	Recall	病灶前景体素的检出能力
分割任务	Precision	前景预测结果的可靠性
分割任务	AUC	前景与背景体素的整体可分性
风险预测任务	Accuracy	整体分类正确率
风险预测任务	Precision	高风险预测结果的准确性
风险预测任务	Recall	破裂病例的识别能力
风险预测任务	F1	Precision 与 Recall 的综合平衡
风险预测任务	AUC	破裂与未破裂病例的排序能力

4.4 动脉瘤分割实验

4.4.1 实验目的与训练过程

分割实验的主要目的是检验三维 Attention U-Net 及其改进结构对颅内动脉瘤的定位能力以及轮廓恢复能力。训练时，模型用局部补丁样本学习病灶及其邻域的空间结构，在验证和测试阶段对整例 CTA 体数据进行滑窗推理。由于动脉瘤在空间上非常稀疏，实验不但重视病灶前景的召回率，还重视在复杂的血管背景下的误检控制。从训练过程来看，模型在后期的验证指标逐渐趋于稳定，说明网络已经基本完成从底层纹理到高层病灶语义的表征学习。本文主要统计了该阶段的验证结果，来观察收敛末期的性能表现。在此期间，AUC 和 Recall 均处于相对稳定的区间，说明模型对于前景和背景的概率排序能力较强，而且病灶检出性能没有出现明显的波动。从训练过程上来说，模型在后期的验证指标逐渐趋于稳定，说明网络已经基本完成了从底层纹理到高层病灶语义的表征学习。本文主要对这一阶段的

验证结果进行统计，以观察收敛末期的性能表现。在此期间，AUC 和 Recall 均保持在相对稳定的区间，说明模型对于前景和背景的概率排序能力较强，而且病灶检出性能没有出现明显的波动。除此之外，训练过程还体现出小目标分割中“概率排序”和“空间成形”的区别。前者强调模型是否可以给真实的病灶体素赋予比背景更高的概率，后者则关注在阈值化之后是否可以形成连续、解剖合理的三维区域。如果模型 AUC 高但 Dice 低，一般认为其概率排序能力已经较好，但是阈值化后的分割结果会出现边界收缩、离散假阳性或者局部漏检的情况。因此，在训练后期，除了关注损失函数和 AUC 外，还需要结合固定阈值下的 Dice、Recall 以及可视化结果，综合判断模型是否具备稳定的空间分割能力。

4.4.2 分割结果和阈值分析

以较好的验证轮次为例，在阈值 0.5 的情况下模型得到 AUC 为 0.97、Recall 为 0.56 的结果，说明模型在当前的验证数据上已经具有较好的体素级区分能力。以最终检查点为报告对象，在相同的阈值下 AUC 为 0.96、Recall 为 0.55，和较好的轮次表现接近，说明训练后期模型并没有出现明显的退化，整体的泛化性能并没有出现明显的下降。

需要指出的是，较高的 AUC 并不能说明分割结果在空间上已经达到了完全理想的状态。AUC 主要用来评价不同的阈值下模型对于正负体素整体排序的质量，但是最终二值掩膜的空间一致性还会受到阈值选择、病灶体积、边界清晰度和重建方式等影响。对于小目标病灶来说，虽然模型在概率排序上表现良好，但是不恰当的阈值仍然会造成边界收缩、局部断裂或者离散误检区域。因此对分割模型进行评价的时候应该把 Dice、Recall 以及典型病例的可视化结果结合起来分析，而不是仅仅依靠一个指标来判断。

从阈值扫描结果可知，分割阈值 τ_s 越大，模型预测越保守，误检体素数目会减少，但是 Recall 会同步下降；反之，当阈值减小时，模型会倾向于保留低置信度的疑似前景，Recall 会增加，但是误检风险也会增加。其决策形式可以表示为

$$\hat{M}_{i,j,k}(\tau_s) = \mathbb{I}(P_{i,j,k} \geq \tau_s). \quad (4.14)$$

当 τ_s 增大时，满足条件的前景集合会越来越小，漏检概率也随之增大。对于医学辅助分析场景来说，保持较高的病灶检出能力很重要，但是同时也要控制误检区域的大小，保证后续结构定量分析以及临床展示的可解释性。

4.4.3 可视化分析与误差来源

从典型的病例可视化结果可知，模型对于大部分病灶区域能够较好地覆盖动脉瘤主体，在局部边界上形成比较连续的响应。对于形态比较规则、对比度比较高

的病灶来说，预测掩膜和人工标注的一致性较高；但是当病灶体积小、边缘对比度低、与载瘤血管过渡模糊或者邻近高密度结构干扰明显的时候，模型就会出现局部漏检、边界偏移或者少量误检。

这类误差具有一定的普遍性。一方面，小病灶在多次下采样过程中容易造成空间信息的丢失，即使使用跳跃连接进行细节的补充，也还不能完全恢复极细小结构边界；另一方面，CTA 中血管增强区域和动脉瘤前景在灰度分布上存在相似性，模型需要依靠空间上下文和拓扑关系而不是仅仅依靠强度差异来做出判断。因此，如果后续要提高分割效果，可以就更具针对性的前景采样、边界敏感损失设计、多尺度监督以及稳健的后处理策略等角度进行优化。

从误差分解的角度来说，分割误差可以分为阈值误差、边界误差和结构误差三类。阈值误差主要是由于概率输出和二值决策不一致造成的；边界误差主要是预测轮廓相对于真实轮廓的局部偏移；结构误差就是病灶区域断裂、漏检或者与邻近血管粘连。设预测概率为 P ，真实标签为 Y ，阈值化结果为 $\hat{M}(\tau_s)$ ，则不同阈值下的分割质量可以表示为

$$S(\tau_s) = m(\hat{M}(\tau_s), Y), \quad (4.15)$$

其中 $m(\cdot)$ 表示任一分割评价指标。若 $S(\tau_s)$ 在较宽的阈值区间内保持稳定，则说明模型概率图具有较好的校准性、空间鲁棒性；若指标随着阈值剧烈波动，则说明模型输出中存在大量的低置信度或者边界不确定区域。

对于动脉瘤分割而言，误差分析还要考虑空间位置和解剖背景。病灶与载瘤血管交界处一般是容易发生边界偏移的地方，因为二者在增强影像上灰度分布接近，而且真实标注也受观察者经验的影响。邻近骨性结构、高密度伪影或者血管分叉区域容易产生假阳性响应。以上现象说明，模型性能的提高不能只依靠更复杂的网络结构，还需要从数据表示、监督信号以及评价方式上共同约束。

4.4.4 分割模型消融分析

为了分析模型性能提升的来源，本文从结构设计角度对分割模型进行了消融讨论。可以把基础三维 Attention U-Net、引入 ASPP 的增强模型、进一步加入三维坐标注意力的模型作为逐步增强的结构序列。基础模型主要是依靠编码器—解码器结构和注意力门控来完成病灶的恢复；ASPP 模块用多尺度空洞卷积扩大感受野，有利于增强模型对不同尺度病灶及其邻域上下文的刻画能力；三维坐标注意力又加入了方向感知的位置建模，对边界模糊、形态不规则或者空间走向复杂的病灶有潜在的优势。

从现有的实验结果可以看出，增强模型比基础模型具有更好的综合分割性能。在相同的训练轮次下，ASPP-CA-UNet 的 Recall 为 0.67，AUC 为 0.96，比基础模

型 Dice 系数提高约 20

表 4.2 分割模型消融结果比较

模型	Recall	AUC	Dice（相对变化）	F1（相对变化）
基础三维 Attention U-Net	0.56	0.97	基准水平	基准水平
Attention U-Net + ASPP + CA	0.67	0.96	+20%	+40%

由于动脉瘤分割属于一种高度不平衡的体素级任务，背景体素占的比例远大于病灶体素，所以整体像素一致性会受到很多真阴性体素的主导，其解释力比较小。相比之下，Dice、Recall、F1 等更能反映病灶区域识别能力的指标，可以更真实地反映模型在本任务上的性能差异。因此本文在消融分析时更重视结构对病灶区域识别质量的改善，而不是单纯地关注整体一致性指标。

ASPP 和坐标注意力的作用机制以及增益来源不同。ASPP 用不同的空洞率并行分支来扩大感受野，主要提高模型对于不同尺度病灶以及其周围血管背景上下文的理解能力；坐标注意力则是通过对空间方向信息的建模来加强位置感知，更适合处理走向复杂或者边界模糊的血管结构。只引入多尺度特征而缺少位置约束，模型容易对背景血管做出过大的响应；反之，如果只加入位置注意力而缺少多尺度上下文，那么对于形态变化大的病灶的适应性就会较差。因此这两类模块在理论上是互补的，联合使用可以更好地解决小目标分割中背景抑制和结构保持的问题。

若用 S_0 表示基础模型性能，用 S_A 表示加入 ASPP 后的性能，用 S_{A+C} 表示同时加入 ASPP 与坐标注意力后的性能，则各模块的边际贡献可形式化表示为

$$\Delta_A = S_A - S_0, \quad (4.16)$$

$$\Delta_{C|A} = S_{A+C} - S_A. \quad (4.17)$$

Δ_A 体现的是多尺度上下文增强直接带来的贡献， $\Delta_{C|A}$ 表示的是在已经有了多尺度表示的基础上，方向注意力带来的增量效果。如果两个模块都是正的，说明两个模块对于目标指标有累积的增益；如果单独增益较弱但是联合增益明显，则可能存在互补作用。本文实验结果表明，增强结构在 Dice 和 F1 上相对提高的幅度更大，说明其主要改善的是前景区域重叠的质量和阳性预测可靠性，而不仅仅是概率排序能力。

4.5 破裂风险预测实验

4.5.1 实验目的与模型设置

破裂风险预测实验用以评价多源表格特征对于病例级破裂状态的判别能力，同时比较交叉注意力模型和传统机器学习模型在中小规模医学数据条件下的表现。

所有模型都使用相同的训练集、验证集、测试集划分来评估，验证集上完成阈值选择，保证各个模型之间有共同的比较基础。

本文所包含的比较模型有交叉注意力深度表格模型、随机森林、逻辑回归、支持向量机、 k 近邻以及融合模型。逻辑回归可以看作是线性可解释的基线，随机森林是集成树模型，支持向量机和 k 近邻分别是基于核映射和局部相似性的传统分类方法，而交叉注意力模型是利用字段交互学习高阶依赖关系的深度方法。融合模型把树模型和注意力模型的输出结合起来，用来检验不同模型范式之间的互补性。

4.5.2 对比实验结果

风险预测模型测试集结果见表 4.3。表中 Threshold 表示由验证集确定并固定用于测试集评估的分类阈值。

表 4.3 风险预测模型测试集对比结果

模型	Accuracy	Precision	Recall	F1	AUC	Threshold
Forest-Attention Ensemble	0.7944	0.6931	0.7778	0.7330	0.8568	0.350
Risk Cross-Attention	0.7852	0.6832	0.7667	0.7266	0.8546	0.325
Random Forest	0.7419	0.6182	0.7556	0.6800	0.8284	0.400
Logistic Regression	0.6895	0.5512	0.7778	0.6452	0.7342	0.450
KNN	0.5766	0.4576	0.9000	0.6067	0.6966	0.200
SVM-RBF	0.5565	0.4451	0.9000	0.5956	0.6732	0.300

根据表 4.3 可知，Forest-Attention Ensemble 在测试集上获得最高的 F1 值 0.7330 和 AUC 值 0.8568，说明传统树模型和深度注意力模型在当前任务中具有一定的互补优势。Risk Cross-Attention 模型得到 F1 值为 0.7266、AUC 值为 0.8546，其性能与最优融合模型相差不大，明显优于逻辑回归、支持向量机、 k 近邻等传统单模型基线。基于字段级交互的深度建模方式可以很好地捕捉到临床变量和影像表型变量之间非线性关系。

从随机森林在 Accuracy、F1 和 AUC 等指标上都比很多传统基线好可以看出集成树模型对于中小规模表格数据的稳定性以及适应性。相比之下，KNN 和 SVM-RBF 模型虽然 Recall 达到 0.9000，有较强的阳性病例检出倾向，但是它们的 Precision 分别是 0.4576 和 0.4451，F1 以及 AUC 也都处在较低水平。这说明这两类模型更倾向于把样本判定为高风险类别，虽然可以提高召回能力，但是也明显增加了误报率，整体结果并没有超过随机森林或者随机森林-注意力融合模型。逻辑回归虽然具有很强的可解释性，但是它的 AUC 只有 0.7342，线性决策边界很难很好地刻画当前多源特征中复杂的非线性关系。

从模型假设的角度来说，不同的方法之间的区别可以归结为判别函数空间的

不同。逻辑回归对应线性形式

$$\log \frac{\hat{p}}{1-\hat{p}} = \beta_0 + \sum_j \beta_j x_j, \quad (4.18)$$

它的优点是参数意义明确，但是不能自动表达高阶非线性交互。随机森林用多个决策树的集成形成分段非线性判别函数，可以较好的处理变量之间的条件分裂关系。交叉注意力模型用字段 token 之间注意力权重的学习来得到全局交互，其判别函数可以抽象为

$$\hat{p} = \sigma(F_\omega(e_1, e_2, \dots, e_{m+q})), \quad (4.19)$$

其中 $F_\omega(\cdot)$ 表示由多层注意力和非线性映射构成的可学习函数。该类模型具有更强的表达能力，但是对样本规模、正则化和数据噪声更敏感。因此，实验结果中深度模型与集成树模型表现接近，符合中小规模医学表格数据的一般规律。

4.5.3 阈值选择与不平衡分类讨论

风险预测实验中各个模型的最优阈值都小于或者接近于 0.5，说明默认的判别阈值不能很好地适应医学风险识别任务的实际需要。对于输出概率 $\hat{p}$ 而言，降低阈值会使更多的病例被判定为高风险，从而提高 Recall，但是也会降低 Precision；提高阈值会产生相反的效果。因此，阈值选择本质上是在漏诊风险和误报代价之间做出取舍。

从临床辅助分析的角度来说，破裂风险预测一般会关注高风险病例的检出能力，因此 Recall 比其他的属性更有参考价值，但是当 Precision 较低的时候，就会出现过多的低风险病例被误判为高风险的情况，进而加重后续检查、复核和干预的负担。F1 值是通过综合考虑 Precision 和 Recall 来给动脉瘤破裂风险预测的二分类任务提供一个更平衡的评价方式。AUC 是用全阈值范围来反映模型对于阳性、阴性病例排序的能力，可以用来比较模型之间的总体判别能力。

进一步地，阈值选择可以被看作是代价敏感的决策问题。假阴性代价为 C_{FN} ，假阳性代价为 C_{FP} ，当给定预测概率 $\hat{p}$ 时，病例判定为阳性的期望代价为 $C_{FP}(1-\hat{p})$ ，判定为阴性的期望代价为 $C_{FN}\hat{p}$ 。当 $C_{FP}(1-\hat{p}) < C_{FN}\hat{p}$ 时，选择阳性判定更合理。由此可得理论阈值

$$\tau_c = \frac{C_{FP}}{C_{FP} + C_{FN}}. \quad (4.20)$$

当漏诊代价大于误报代价时， $C_{FN} > C_{FP}$ ，对应的阈值 τ_c 小于 0.5，这与实验中多个模型的最优阈值小于默认阈值的现象相符。由此可知，阈值不是单纯的参数，它反映了具体应用场景中漏诊和误报之间的取舍。

4.5.4 风险模型结果讨论

从各个指标来看，基于交叉注意力的深度表格模型在本次任务中具有较强的竞争力，但是并没有全面超过所有的传统方法。主要是由于交叉注意力机制可以显式地捕捉到异构字段之间复杂的依赖关系，在处理多源医学表格数据的时候有较好的表达能力；另一方面，在样本规模较小的情况下，传统的集成学习模型一般会比其他的模型有较好的稳健性，并且过拟合的风险也较低。

因此，深度模型和传统模型之间不是简单的替代关系，而是根据不同的数据条件和评价目标而各有千秋。融合模型在本实验中取得最优综合性能，该结果又进一步证明了上述的判断。由此可知，使用树模型的分裂规则以及使用注意力机制的表示学习，实际上捕捉到了不同的判别模式，二者结合起来可以一定程度上缓解单一模型的偏差，从而提高整体分类效果。也给后面探索更系统的模型融合策略提供支持，有利于进一步提高风险预测的稳定性以及泛化能力。

从误差类型上看，假阴性、假阳性在风险预测任务中有着不同的临床意义。假阴性是指高风险病例被低估，容易造成复查、干预等时机的延误；假阳性是指低风险病例被高估，容易造成不必要的随访负担和临床资源的浪费。因此，在该任务中不能只追求 Accuracy，而应该根据具体的临床场景来权衡 Recall、Precision 和 F1 等指标的相对重要性。本实验中，部分模型通过降低阈值获得较高的 Recall，但是 Precision 明显下降，说明它对于阳性类别的概率输出比较敏感，但是缺乏足够的可靠性。相比之下，交叉注意力模型和融合模型在 Precision 与 Recall 之间取得更加均衡的表现，综合评价指标也更高。

同时，当前结果也表明要小心地去理解深度表格模型的优势。当样本量小、变量噪声大或者阳性比例小的时候，复杂的模型就很容易学到和训练分布有关但是泛化能力差的模式。因此，较高的测试集指标还需要配合置信区间、重复划分或者外部验证来进一步验证。本文实验结果表明交叉注意力模型有较好的风险判别能力，但是其临床稳定性还需要在更大的规模数据和更严格的验证条件下进一步研究。

4.6 结果综合讨论

根据综合分割、风险预测实验结果可知，本文方法在目前数据集上已经形成了从影像结构识别到病例风险估计的完整分析流程。分割模型在体素级 AUC 和 Recall 上表现稳定，说明它可以把病灶和复杂的血管背景很好地区分开来；风险预测模型在 F1 和 AUC 上接近最优融合模型，说明交叉注意力机制在多源表格特征建模中具有较好的适用性。

从方法构成上讲，分割任务用注意力门控、ASPP、三维坐标注意力分别实现了背景抑制、多尺度上下文聚合、方向位置建模，三者一起提高了模型对于复杂血

管结构的表达能力。在风险预测任务中，字段级嵌入和交叉注意力机制把传统的特征拼接转变成可以学习的交互表示，使模型在病例层面可以捕捉临床变量、影像表型、形态特征之间的潜在依赖关系。

同时也会出现一些值得注意的问题。医学影像数据规模小、标注成本高、单次数据划分结果容易受到样本分布的影响等；风险预测任务中的类别不平衡问题会严重影响到阈值的选择和指标的解读；深度表格模型在中小样本医学任务中并不总是稳定优于传统集成模型，合理的正则化、特征选择、概率校准以及外部验证仍然需要。

4.7 系统展示

为了保证整个方法流程的完整性，本文把分割推理、特征提取和风险预测组织成一个端到端的演示系统。该系统可以从输入 CTA 影像开始，依次完成病灶概率图生成、二值掩膜输出、形态特征提取以及破裂风险概率估计，最后以可视化的方式呈现关键结果。




图 4.4 系统展示界面

如图 4.4 所示，系统界面主要包含以下几个功能模块：影像上传模块用于接收用户上传的 CTA 体数据，并展示在用户界面中，位于界面右上角部分；分割推理模块调用训练好的三维 Attention U-Net 模型对输入影像进行动脉瘤区域识别，在此过程中会流式分割 CTA 的三维体数据，之后进行单独 patch 预测并拼装后返回给用户界面展示；风险预测模块将形态特征与临床信息结合，通过交叉注意力模型输出病例级破裂风险概率。

4.8 本章小结

本章从实验设计、评价指标、分割实验、风险预测对比、消融分析以及结果讨论等几个方面对本文的方法进行了比较系统的实验性评价。结果表明，分割模型在当前的验证数据上具有较好的体素级判别能力以及病灶检出能力；风险预测模型可以有效地利用多源表格特征，在测试集上取得接近最优融合模型的综合表现。本文方法在病灶识别和风险评估两个方面基本达到了预期目标，但是稳健性、泛化性等的检测和提升还需要通过大规模、多中心的多轮重复实验来进一步验证和完善。

5 总结与展望

5.1 研究工作总结

本文围绕颅内动脉瘤智能分析问题，建立由病灶分割、破裂风险预测两部分组成的框架，统一实验流程下完成方法设计、模型训练、结果评估、原型验证。本文工作主要目的有两点，一是利用三维医学影像分割方法对动脉瘤区域进行精细识别以及结构刻画，二是用病例层面的临床信息、影像表型信息和分割衍生结构特征来建立面向破裂风险评估的分类模型，从而形成从解剖结构分析到病例级风险判断的技术链条。

从方法上来说，对于 CTA 图像中动脉瘤体积小、背景复杂、类别不平衡等各方面的问題，本文建立了一个以三维注意力 U-Net 为主干，再加上 ASPP 以及坐标注意力的分割模型，来提高病灶区域的表征能力。对于风险预测任务中多维表格特征存在复杂的非线性关系的问题，本文又提出了一种基于字段嵌入和交叉注意力的风险模型，用来更好地刻画变量间高阶依赖关系。通过上述的设计，影像空间表征和病例级决策建模可以衔接起来，从而形成一个比较完整的研究流程。本文不只关注单个模型的性能提升，而且重视输入影像、病灶结构、病例特征到风险输出之间信息流动、变换的关系，使分割结果可以服务于后续的风险分析，在工程上保证模型解耦，提高项目的可用性、可靠性。

5.2 主要研究结论

基于实验结果，可以得到以下几点主要结论。

第一，在动脉瘤分割任务中，所建立的三维分割模型在验证阶段具有较好的体素级判别能力以及稳定的阳性检出能力，说明该模型可以较好地从复杂的 CTA 背景中识别出目标病灶区域。注意力门控机制可以抑制无关背景响应，多尺度上下文聚合和方向敏感注意力又进一步提高了模型对于小目标、复杂形态、空间走向等特征的表达能力。

第二，在破裂风险预测任务中，基于交叉注意力的深度表格模型可以很好地学习临床变量、影像表型变量和结构化形态特征之间的交互关系。测试结果表明，该模型在 F1、AUC 等主要指标上接近最优融合模型，比很多传统单模型基线好，说明使用字段级表示学习和注意力交互机制可以提高多源医学表格数据的风险判别能力。

第三，融合模型具有最好的综合性能，说明深度注意力模型和传统集成学习模型在当前任务上是互补的。前者更擅长挖掘连续隐空间中的复杂关联模式，后者则在中小样本场景下具有较好的稳健性。因此，在医学风险预测问题中，单一模型

范式不能完全占优，合理地结合各种方法的优势，可能是提高性能的一个方向。

从整体流程上看，本文实现了由病灶分割到风险评估的闭环验证，说明基于影像结构识别结果建立病例级风险表征是可行的。由此可知，分割任务不仅可以作为独立的病灶检测工具，也可以为后续风险判别提供具有解剖学意义的数据表征，从而提高模型的医学使用价值。

第五，从方法论上讲，本文的实验又进一步证明医学人工智能的研究应该同时考虑模型性能、评价标准、任务目标三者之间的相互一致性。分割任务中体素级 AUC 高不一定意味着二值掩膜在边界和结构上都可靠；风险预测任务中 Accuracy 高也不一定说明高风险病例可以被完全检出。因此本文使用多指标联合评价的方式，对模型概率排序能力、阳性识别能力和综合分类能力分别进行讨论。该种分析方式可以防止由于单一指标解释造成的片面性。

第六，本文认为分割结果向风险预测阶段传递的不只是病灶位置，还有体积、形态、边界规则性等具有医学意义的结构信息。该类信息可以作为临床和影像表型变量的补充，使风险模型在病例级判别中获得更明确的解剖依据。因此，影像分割和风险预测之间有着很强的任务联系，合理组织二者输入输出关系是形成完整智能分析流程的基础。

5.3 研究不足

虽然本文在方法的建立以及实验的验证上取得了一定的成果，但是还存在着一些不足，主要体现在以下几个方面。

数据规模、来源范围仍然有限。医学影像和临床数据采集、标注的成本较高，所以目前的研究大多是在样本数量较少、数据特征即灰度、对比度等相对单一的情况下进行的。样本量小、来源单一，不但会限制深度模型对复杂模式的充分学习，也会使实验结果对特定数据划分比较敏感，从而影响统计的稳健性以及泛化能力。

外部验证还需要进一步改善。本文实验主要是根据已经确定的数据划分来进行的，虽然可以反映模型在当前数据分布下是否有效，但是不能很好地说明模型在不同的扫描条件、不同的设备、不同的人群临床信息、不同的标注标准下是否具有稳定的泛化能力。外部独立验证对于医学人工智能模型来说，是检验真实应用价值的重要部分。

再次，风险预测任务仍然存在着类别不平衡所带来的问题。本文使用类别加权、阈值搜索、注意力交互等方法来一定程度上缓解相关问题，但是小样本情况下，深度表格模型对于特征噪声、超参数设置、初始化随机性等仍然比较敏感。这也是传统树模型在当前实验中仍然具有较强竞争力的一个原因。

最后，本文的结果解释仍然以性能指标为重心，对于模型内部决策依据的临床

可解释分析还很薄弱。不同的临床变量、形态变量、影像表型变量在风险预测中相对贡献的量化还待用更系统的可解释性方法来完成；分割结果局部误差怎样才对后续风险建模产生影响，也需做进一步研究。

本文使用了两阶段的流程，虽然可以提高项目工程化水平和训练效率，但是分割误差会传递到后续风险预测环节中去，从而影响风险模型输出的准确性。当分割掩膜出现边界收缩、局部漏检或者误检的时候，体积、形态规则性等特征变量也会随之发生偏移，从而对风险估计造成影响。目前还没有对这类误差传播进行系统的建模，也没有对不同的分割质量水平对于风险预测的稳定性进行充分的评估。因此，怎样量化上游结构识别的不确定性，怎样减少它对下游风险预测任务的影响，依然是后续需要解决的问题。

5.4 未来工作展望

针对上述不足，未来研究可以从以下几个方面继续深入。

第一，扩大数据规模并开展多中心验证。后续工作可以引入来自不同的中心、不同的设备、不同的扫描协议的数据，从而增加样本的多样性，用外部测试集、交叉验证、置信区间分析等更严格的方式去检验模型的稳定性以及泛化能力。这不仅有利于提高方法的可信度，而且更符合医学人工智能由学术研究向临床应用推广转化的基本要求。

第二，进一步改进分割模型的结构表达方式以及监督机制。可以尝试使用更强的三维上下文建模策略、边界敏感损失函数、层级监督机制和面向小目标的困难样本挖掘方法来提高病灶边界恢复能力并增强对复杂的解剖背景的鲁棒性。此外，还可以研究将血管拓扑先验或者形态约束显式地加入到模型训练中去，从而改善分割结果的结构合理性。

第三，加强风险预测中特征融合、可解释性建模。可以采用更多的形态学定量指标、时序随访信息或者多模态影像表征来构建病例级特征空间，也可以使用注意力可视化、特征归因、概率校准、不确定性估计等方法来提高风险预测结果的可解释性、可信度和临床可读性。

第四，探究分割和风险预测的联合优化机制。本文使用的是两阶段分析框架，结构清晰、实现简单，但是分割和风险建模之间还存在着更深层次的协同关系。可以建立端到端联合学习框架，使影像空间特征、病灶结构表征和风险标签在部分统一模型中协同优化，从而进一步提高任务间的信息传递效率和特征捕捉能力，提高模型整体性能。

第五，做误差传播和不确定性分析。后续研究可以建立分割概率图、形态特征、风险预测概率三者之间的更明确的统计联系，评价分割阈值、病灶边界扰动、

特征测量误差对最终风险输出的影响。可以利用贝叶斯近似、模型集成、置信区间估计等方法来刻画预测的不确定性，使模型输出风险结果的时候可以同步给出可信度信息。

第六，使方法由实验验证转向更规范的应用研究。今后的工作可以继续完善推理效率的评价、结果一致性分析、临床工作流程的适配以及人机协同机制的设计，同时结合前瞻性研究验证模型在真实场景中的辅助价值。只有在算法性能、可解释性、稳定性、使用流程等各方面都得到充分论证时，相关研究才能有更高的临床转化潜力。

5.5 结束语

本文以颅内动脉瘤智能分析任务为研究对象，从三维病灶分割到破裂风险预测进行了系统的研究，取得了阶段性成果。研究表明，把多尺度医学影像特征同多源临床信息融合起来，可以给动脉瘤自动识别及风险评估提供一条有实证支撑的技术途径。虽然本研究的数据规模、外部验证、可解释性还有待改进，但是所提出的框架和实验结果给之后的深入研究打下了基础，也可以给医学人工智能在该领域的发展提供借鉴。

参 考 文 献

- [1] Li Y, Cui F, Xue X, et al. Coarse-to-fine salient object detection based on deep convolutional neural networks[J]. Signal Processing: Image Communication, 2018, 64: 21-32.
- [2] Chen M, Geng C, Wang D, et al. A coarse-to-fine cascade deep learning neural network for segmenting cerebral aneurysms in time-of-flight magnetic resonance angiography[J]. Biomedical Engineering Online, 2022, 21(1): 71.
- [3] Litjens G, Kooi T, Bejnordi B E, et al. A survey on deep learning in medical image analysis[J]. Medical Image Analysis, 2017, 42: 60-88.
- [4] Shen D, Wu G, Suk H I. Deep learning in medical image analysis[J]. Annual Review of Biomedical Engineering, 2017, 19: 221-248.
- [5] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer International Publishing, 2015: 234-241.
- [6] Cicek O, Abdulkadir A, Lienkamp S S, et al. 3D u-net: Learning dense volumetric segmentation from sparse annotation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer International Publishing, 2016: 424-432.
- [7] Oktay O, Schlemper J, Folgoc L L, et al. Attention u-net: Learning where to look for the pancreas [A]. 2018.
- [8] Isensee F, Jaeger P F, Kohl S A A, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature Methods, 2021, 18(2): 203-211.
- [9] Greving J P, Wermer M J H, Brown R D, et al. Development of the PHASES score for prediction of risk of rupture of intracranial aneurysms: A pooled analysis of six prospective cohort studies [J]. The Lancet Neurology, 2014, 13(1): 59-66.
- [10] UCAS Japan Investigators. The natural course of unruptured cerebral aneurysms in a japanese cohort[J]. New England Journal of Medicine, 2012, 366(26): 2474-2482.
- [11] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston, MA, 2015: 3431-3440.
- [12] Milletari F, Navab N, Ahmadi S A. V-net: Fully convolutional neural networks for volumetric medical image segmentation[C]//2016 Fourth International Conference on 3D Vision (3DV). Stanford, CA: IEEE, 2016: 565-571.
- [13] Kamnitsas K, Ledig C, Newcombe V F J, et al. Efficient multi-scale 3D CNN with fully connected

- CRF for accurate brain lesion segmentation[J]. *Medical Image Analysis*, 2017, 36: 61-78.
- [14] Chen J, Zhuang J, Shen Y, et al. StrokeNet: A multi-task neural network for stroke outcome prediction[J]. *NeuroImage: Clinical*, 2022, 33: 102927.
- [15] Xiong L, Wang Y, Chen H, et al. Multimodal deep learning for predicting ischemic stroke outcome [J]. *IEEE Transactions on Medical Imaging*, 2025, 44(2): 523-534.
- [16] He N, Lyu H, Zhang Y, et al. Increased diagnostic accuracy and better morphology characterization of unruptured intracranial aneurysm by ultra-high-resolution photon-counting detector ct angiography[J/OL]. *Journal of NeuroInterventional Surgery*, 2026, 18(3): 835-841. DOI: 10.1136/jnis-2026-xxxxxx.
- [17] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//*Advances in Neural Information Processing Systems*. Long Beach, CA, 2017: 5998-6008.
- [18] Zeng L, Zhang X, Li W, et al. Ai-based detection and sizing of saccular intracranial aneurysms: a single-center retrospective validation study using computed tomography angiography[J/OL]. *PeerJ*, 2026, 14: e20712. DOI: 10.7717/peerj.20712.
- [19] Ishikawa T. Detection and treatment of unruptured intracranial aneurysms[J/OL]. *Brain and Nerve= Shinkei Kenkyu no Shinpo*, 2026, 78(3): 211-216. DOI: 10.11477/mf.1416202154.
- [20] Ali N H, Ibrahim N J. A hybrid multi-stage framework for intracranial aneurysm detection from cta images: A comparative study with end-to-end deep learning[J/OL]. *International Journal of Advances in Signal and Image Sciences*, 2026, 12(2s): 166-182. DOI: 10.29284/cpt60r37.
- [21] Maier A, Syben C, Lasser T, et al. A gentle introduction to deep learning in medical image processing[J]. *Zeitschrift f'ur Medizinische Physik*, 2019, 29(2): 86-101.
- [22] Cicek O, Abdulkadir A, Lienkamp S, et al. 3d u-net: Learning dense volumetric segmentation from sparse annotation[C]//*MICCAI*. Cham, 2016: 424-432.
- [23] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. Unet++: A nested u-net architecture for medical image segmentation[C]//*International Workshop on Deep Learning in Medical Image Analysis*. Cham: Springer International Publishing, 2018: 3-11.
- [24] Sudre C H, Li W, Vercauteren T, et al. Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations[C]//*International Workshop on Deep Learning in Medical Image Analysis*. Cham: Springer International Publishing, 2017: 240-248.
- [25] Salehi S S M, Erdogmus D, Gholipour A. Tversky loss function for image segmentation using 3d fully convolutional deep networks[C]//*International Workshop on Machine Learning in Medical Imaging*. Cham: Springer International Publishing, 2017: 379-387.
- [26] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//*Proceedings of the IEEE International Conference on Computer Vision*. Venice, 2017: 2980-2988.

- [27] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [28] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco, CA, 2016: 785-794.
- [29] Hastie T, Tibshirani R, Friedman J. The elements of statistical learning[M]. New York: Springer, 2009.
- [30] Saito T, Rehmsmeier M. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets[J]. PLOS ONE, 2015, 10(3): e0118432.
- [31] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[C]//International Conference on Machine Learning. Sydney: PMLR, 2017: 1321-1330.
- [32] Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning[C]//Proceedings of the 22nd International Conference on Machine Learning. Bonn, 2005: 625-632.
- [33] Chicco D, Jurman G. The advantages of the matthews correlation coefficient (MCC) over f1 score and accuracy in binary classification evaluation[J]. BMC Genomics, 2020, 21(1): 6.

附录 A：关键配置与复现实验步骤

A.1 项目结构说明

本项目采用模块化目录布局，便于维护、扩展与复现实验：

- core/：配置数据结构、YAML 加载与随机种子管理；
- data/：医学影像补丁数据管线与风险表格数据处理；
- model/：分割模型（aneurysm）与风险模型（risk）；
- script/：训练、评估与对比实验入口脚本；
- ui/：FastAPI 服务与推理接口封装；
- utils/：日志、路径与通用工具函数。

A.2 环境配置建议

Python ≥ 3.8

torch $\geq 1.9.0$

monai $\geq 0.7.0$

numpy $\geq 1.21.0$

pandas $\geq 1.3.0$

scikit-learn $\geq 1.0.0$

SimpleITK $\geq 2.1.0$

tensorboard

tqdm

fastapi

uvicorn

建议安装后执行 `python -c "import torch; print(torch.cuda.is_available())"` 验证 GPU 可用性。

A.3 分割任务复现实验步骤

1. 准备 NIfTI 影像与标签数据，确保命名规则与配置文件一致；
2. 复制并修改配置文件（如 config/host.yaml），填写训练/验证路径；
3. 运行训练命令：`python script/train_split.py -config path/to/your.yaml`；
4. 通过 TensorBoard 观察收敛曲线并记录最优检查点；
5. 运行评估脚本导出指标与可视化结果。

A.4 风险预测复现实验步骤

1. 准备包含标签列与病例 ID 的表格数据（Excel/CSV）；
2. 在配置中启用风险模块并设置特征与训练参数；
3. 运行训练命令：`python script/train_risk.py --config path/to/your.yaml`；
4. 查看输出 `risk_report.json` 并记录 F1、AUC 与最优阈值；
5. 可选运行 `compare_risk_models.py` 与传统模型进行统一对比。

A.5 关键参数说明

- 分割参数：`train.epochs`、`train.patch_size`、`train.learning_rate`、`eval_interval`；
- 风险参数：`risk.hidden_dim`、`risk.num_heads`、`risk.num_layers`、`risk.threshold_search_steps`；
- 数据参数：`data.patch_sampling_mode`、`risk.feature_select_method`。

A.6 常见问题与排查建议

- **显存不足**：减小 `patch_size` 或减少每例补丁数量；
- **训练不收敛**：检查学习率、标签映射及数据归一化流程；
- **指标异常波动**：固定随机种子并核查数据划分一致性；
- **LaTeX 目录报错**：清理 `.aux/.toc/.out` 后重新编译。

致 谢

本论文的完成离不开各位老师、同学和家人的支持与帮助。

首先，我要感谢我的指导教师，感谢您在论文选题、研究方法和实验设计等方面的悉心指导，您的严谨治学态度和渊博的专业知识使我受益匪浅。

其次，我要感谢实验室的各位同学，在项目开发过程中，大家互相交流、共同探讨，营造了良好的学术氛围。特别感谢师兄师姐们在技术实现方面给予的宝贵经验和建议。

再次，我要感谢我的家人，感谢你们一直以来的理解、支持和鼓励，让我能够安心完成学业。

最后，感谢所有为本研究提供数据和技术支持的机构和个人。正是有了各方的支持与帮助，本研究才能够顺利完成。

原创性声明

郑重声明：所呈交的论文（设计）《_____》，是本人在导师的指导下，独立进行研究取得的成果。除论文（设计）中已经标注引用的内容外，本论文（设计）不包含其他人或集体已经发表或撰写过的作品成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

论文（设计）作者签名：_____

日期：_____

使用授权书

本论文（设计）作者完全了解学校有关保留、使用论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）复印件和电子版，允许论文（设计）被查阅和借阅。本人授权重庆大学将本论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制方式保存和汇编本论文（设计）。

本论文（设计）属于：

保 密 ☐ 在_____年解密后适用本授权书

不保密 ☐

论文（设计）作者签名：_____

指导教师签名：_____

日期：_____

日期：_____