

重庆大学本科生毕业论文（设计）

# 基于深度学习的颅内动脉瘤检测与破裂风险 预测系统



学    生： 申建松

学    号： 20221556

指导教师： 文静

专    业： 计算机科学与技术

重庆大学计算机学院

2026 年 6 月

**Undergraduate Thesis (Design) of Chongqing University**

**Deep Learning-Based Intracranial  
Aneurysm Detection and Rupture Risk  
Prediction System**



**By**

**SHEN Jiansong**

**Supervised by**

**Assoc. Prof. WEN Jing**

**and**

**Computer Science and Technology**

**College of Computer Science, Chongqing University**

**Chongqing University**

**June, 2026**

## 摘 要

颅内动脉瘤是一种常见的脑血管异常，破裂后可引起蛛网膜下腔出血，危险性较高。CTA 能较清楚地显示载瘤血管和瘤体形态，但由于切片多、分叉复杂且存在骨伪影，人工阅片仍可能出现漏检或判断不一致。动脉瘤破裂风险又同时受到年龄、基础病、瘤体形态和位置等多种因素影响，单纯依靠传统量表或统计模型，往往难以全面刻画这些变量之间的非线性关系。因此，研究一种能够从影像中稳定分割动脉瘤，并结合临床信息进行风险分层的辅助方法，具有实际应用价值。

针对这一需求，本文在毕业设计阶段实现了两条可复现的技术路线。首先，在分割任务中采用三维 Attention U-Net，并在基础结构上进一步集成 ASPP 多尺度上下文模块与三维坐标注意力模块。基础模型保留了 U-Net 的多尺度跳跃连接，并在解码端加入注意力门控，对来自编码器的特征进行筛选，使网络在大量背景体素中更关注疑似瘤体区域；增强模型则在瓶颈层通过 ASPP 扩大感受野，并利用坐标注意力沿深度、高度和宽度方向重标定特征，以提升对细小动脉瘤及复杂血管走向的表达能力。训练时采用病例级流式加载和三维补丁采样，并结合重采样与强度归一化，以便在有限显存下处理大体积 CTA 数据；损失函数由二元交叉熵和 Dice 损失组合而成，用于同时兼顾分类准确性和区域重叠度。推理时，模型对整例数据分块预测，再将结果拼接回原始空间，便于后续使用。

其次，在破裂风险预测任务中，本文面向表格型临床和影像衍生特征，构建基于交叉注意力的深度表格模型：数值与类别字段分别映射到统一隐空间，经多层交叉注意力融合后由多层感知机输出破裂概率。数据处理包括缺失值填补、低频类别合并、特征筛选，以及面向类别不平衡的加权损失与验证集阈值优选。

在固定训练/验证/测试划分下，本文进一步将所提模型与随机森林、逻辑回归、支持向量机、 $k$  近邻及融合模型进行离线比较。结果表明，融合模型在测试集上取得最高 F1 值 0.7330 和 AUC 0.8568；本文的交叉注意力模型取得 F1 值 0.7266 和 AUC 0.8546，整体性能接近最优结果，并优于单独的逻辑回归、支持向量机和  $k$  近邻方法。这说明基于注意力的特征交互机制能够有效建模异构风险因素之间的非线性关系，但在当前小样本条件下，传统机器学习模型仍然保持较好效果。

整体实现以配置驱动方式串联分割与风险两条流程，并提供简易交互界面，支撑从体数据读入到辅助分析演示的闭环。受数据脱敏与伦理审批进度限制，分割定量指标需结合具体实验设置解读；风险预测结果目前仍基于固定划分下的一次离线对比，尚不构成多中心外部验证结论。

**关键词：**颅内动脉瘤；CTA；三维分割；Attention U-Net；表格学习；交叉注

意力；破裂风险预测

## ABSTRACT

Intracranial aneurysms are a common cerebrovascular abnormality. If they rupture, they can cause subarachnoid hemorrhage and lead to serious outcomes. CTA can show the parent vessel and aneurysm shape clearly before treatment, but the full image series is large, and vessel bifurcations and bone artifacts make manual reading difficult. Rupture risk is also influenced by multiple factors such as age, comorbidities, aneurysm shape, and location, so traditional scores or simple statistical models often fail to capture the nonlinear relations among mixed data types. For this reason, a computer-aided method that can segment aneurysms from vascular images and stratify risk using clinical features is practically valuable.

To address this problem, this thesis implements two reproducible pipelines. First, for segmentation, a 3D Attention U-Net is adopted and further enhanced with an ASPP module and a 3D coordinate-attention module. The base model keeps the multi-scale skip connections of U-Net and adds attention gates in the decoder to filter encoder features, helping the network focus on likely aneurysm regions in CTA volumes dominated by background voxels. The enhanced model inserts ASPP at the bottleneck to enlarge the receptive field and aggregate multi-scale vascular context, and then applies coordinate attention along the depth, height, and width axes to recalibrate position-sensitive features, thereby improving the representation of small aneurysms and tortuous vessel structures. Training uses case-wise streaming and 3D patch sampling, together with spacing resampling and intensity normalization, so that large CTA volumes can be processed with limited GPU memory. The loss combines binary cross-entropy and Dice loss to balance classification accuracy and region overlap. During inference, the full volume is predicted patch by patch and then stitched back into the original space for later use.

Second, for rupture-risk prediction, this thesis builds a cross-attention-based deep tabular model for clinical and imaging-derived features. Numeric and categorical fields are mapped into a shared latent space, fused through stacked cross-attention blocks, and passed to an MLP head for rupture probability. The pipeline includes missing-value imputation, rare-category grouping, feature selection, class-frequency-weighted loss, and validation-set threshold tuning to mitigate imbalance.

Under a fixed train/validation/test split, the proposed model is further compared with random forest, logistic regression, SVM, KNN, and an ensemble model. The ensemble achieves the best test performance with an F1 score of 0.7330 and an AUC of 0.8568, while

the proposed cross-attention model reaches an F1 score of 0.7266 and an AUC of 0.8546. These results show that attention-based feature interaction is effective for heterogeneous risk factors, although traditional ensemble methods remain highly competitive under the current small-sample setting.

The implementation is configuration-driven for both branches and includes a lightweight web interface for volume upload and an end-to-end auxiliary-analysis demonstration. The data are de-identified and ethics review is ongoing, so quantitative segmentation should be read with the experimental setup in mind; the risk-prediction results are still based on a single offline comparison under a fixed split rather than a multi-center external validation.

**Key words:** intracranial aneurysm; CTA; 3D segmentation; Attention U-Net; tabular learning; cross-attention; rupture risk prediction

# 目 录

|                                     |     |
|-------------------------------------|-----|
| 摘要.....                             | I   |
| ABSTRACT.....                       | III |
| 1 绪论.....                           | 1   |
| 1.1 研究背景与意义 .....                   | 1   |
| 1.2 国内外研究现状 .....                   | 2   |
| 1.2.1 动脉瘤与脑血管影像分析的传统途径 .....        | 2   |
| 1.2.2 基于深度学习的分割与多模态预测 .....         | 2   |
| 1.3 本文面临的问题与主要思路 .....              | 2   |
| 1.4 课题来源与研究内容 .....                 | 3   |
| 1.5 论文结构安排 .....                    | 3   |
| 1.6 本章小结 .....                      | 3   |
| 2 相关理论基础.....                       | 5   |
| 2.1 脑动脉瘤及分割基本原理 .....               | 5   |
| 2.2 医学图像分割基本理论 .....                | 5   |
| 2.3 卷积神经网络与 U-Net 结构 .....          | 6   |
| 2.4 注意力机制与 Attention U-Net .....    | 6   |
| 2.5 类别不平衡与损失函数设计 .....              | 6   |
| 2.6 表格数据学习与特征表示理论 .....             | 7   |
| 2.7 临床风险评分与深度模型的互补关系 .....          | 7   |
| 2.8 评价指标基础 .....                    | 8   |
| 2.9 本章小结 .....                      | 8   |
| 3 模型设计.....                         | 9   |
| 3.1 研究方法总体框架 .....                  | 9   |
| 3.2 分割任务的理论基础与建模动机 .....            | 9   |
| 3.3 动脉瘤分割模块设计 .....                 | 10  |
| 3.3.1 输入表示与数据采样机制 .....             | 10  |
| 3.3.2 三维 Attention U-Net 主干结构 ..... | 10  |
| 3.3.3 注意力门控跳跃连接机制 .....             | 10  |
| 3.3.4 ASPP 多尺度上下文增强模块 .....         | 11  |
| 3.3.5 三维坐标注意力模块 .....               | 12  |
| 3.3.6 输出映射与整例重建 .....               | 12  |
| 3.3.7 分割损失函数与优化目标 .....             | 13  |

|                              |    |
|------------------------------|----|
| 3.4 破裂风险预测模块设计 .....         | 14 |
| 3.4.1 多源特征表示与问题定义 .....      | 14 |
| 3.4.2 字段嵌入与统一隐空间映射 .....     | 14 |
| 3.4.3 交叉注意力特征交互机制 .....      | 15 |
| 3.4.4 全局聚合与风险概率输出 .....      | 15 |
| 3.4.5 风险预测损失函数与类别不平衡处理 ..... | 16 |
| 3.5 训练与优化过程 .....            | 16 |
| 3.6 本章小结 .....               | 17 |
| 4 实验与结果分析 .....              | 18 |
| 4.1 实验设计概述 .....             | 18 |
| 4.2 实验环境与基本设置 .....          | 18 |
| 4.3 评价指标 .....               | 18 |
| 4.3.1 分割任务评价指标 .....         | 18 |
| 4.3.2 风险预测评价指标 .....         | 19 |
| 4.4 动脉瘤分割实验 .....            | 20 |
| 4.4.1 实验目的与训练过程 .....        | 20 |
| 4.4.2 分割结果与阈值分析 .....        | 20 |
| 4.4.3 可视化分析与误差来源 .....       | 21 |
| 4.4.4 分割模型消融分析 .....         | 21 |
| 4.5 破裂风险预测实验 .....           | 22 |
| 4.5.1 实验目的与模型设置 .....        | 22 |
| 4.5.2 对比实验结果 .....           | 22 |
| 4.5.3 阈值选择与不平衡分类讨论 .....     | 23 |
| 4.5.4 风险模型结果讨论 .....         | 23 |
| 4.6 结果综合讨论 .....             | 24 |
| 4.7 系统闭环验证 .....             | 24 |
| 4.8 本章小结 .....               | 25 |
| 5 总结与展望 .....                | 26 |
| 5.1 研究工作总结 .....             | 26 |
| 5.2 主要研究结论 .....             | 26 |
| 5.3 研究不足 .....               | 27 |
| 5.4 未来工作展望 .....             | 27 |
| 5.5 结束语 .....                | 28 |
| 参考文献 .....                   | 29 |



|                       |    |
|-----------------------|----|
| 附录 A：关键配置与复现实验步骤..... | 32 |
| 致谢.....               | 34 |
| 原创性声明和使用授权书.....      | 35 |

## 1 绪论

### 1.1 研究背景与意义

脑血管疾病在我国居民死因构成中长期居于前列，其中颅内动脉瘤（Intracranial Aneurysm, IA）可在无症状阶段经影像学检查偶然发现；一旦瘤壁完整性被破坏导致蛛网膜下腔出血（Subarachnoid Hemorrhage, SAH），病情往往凶险，遗留神经功能障碍的比例亦不容忽视。数字减影血管造影（DSA）被视为诊断“金标准”，但其有创性与费用限制了大规模筛查场景的普及。CT 血管成像（CT Angiography, CTA）无创、可及性高，已成为门诊与急诊情境下动脉瘤检出与术前评估的重要工具<sup>[1,2]</sup>。

然而，临床实际工作中仍存在三方面痛点。其一，单次检查所产生的轴位切片可达数百层，医生需在三维空间中追踪迂曲血管并辨别微小隆起，长时间阅片易引起视觉疲劳与漏诊。其二，不同扫描协议、重建层厚与对比剂充盈程度会造成图像对比度、颜色与间隔等的差异，同一算法在不同数据条件下难以保证足够的稳定性与可靠的繁华能力。其三，是否建议干预不仅取决于“有没有瘤”，还与瘤体大小、形态不规则度、位置、患者年龄及合并症等因素耦合；现有临床管理往往还需参考 PHASES、ELAPSS 以及日本 UCAS 等研究所揭示的自然病程与增长风险规律<sup>[3-6]</sup>。因此，若仅依赖分割掩膜而缺少风险预测，仍难以直接支撑完整的临床规划。

近年来，深度学习在医学影像分割任务上取得了令人瞩目的进展。全卷积网络与 U-Net 族结构能够在像素级输出病灶概率图，显著缩短标注辅助时间<sup>[7,8]</sup>；三维卷积网络可直接建模沿血管走向的上下文信息，有利于保持瘤体在层间的连续性<sup>[9,10]</sup>。Attention U-Net 在解码路径上对跳跃连接施加门控，使网络更关注与任务相关的空间区域，已在腹部脏器、胰腺等分割中得到验证<sup>[11]</sup>。nnU-Net 的成功进一步说明，在医学分割中，网络骨架之外的数据预处理、补丁采样与后处理同样是性能的重要决定因素<sup>[12]</sup>。在脑血管领域，已有工作尝试将粗定位与细分割结合，或利用多尺度三维卷积提升细小病灶检出率<sup>[1,2,13]</sup>。与此同时，面向动脉瘤临床信息与动脉瘤本体属性的多任务网络也开始出现，提示“影像 + 临床”联合建模的重要性<sup>[14,15]</sup>。在表格学习方向，TabTransformer 与 FT-Transformer 等模型证明了注意力机制不仅适用于视觉特征建模，也适用于异构临床字段之间的上下文交互建模，为风险预测模块的设计提供了宝贵参考<sup>[16,17]</sup>。

在此背景下，本文依托课程设计任务，围绕“动脉瘤的自动分割定位”与“破裂风险的概率预测”两个相互衔接的子问题，实现一套以配置文件驱动、脚本可复现为特征的软件系统。该系统一方面减轻医师在体数据层面的重复勾画负担，另一方面为后续将影像组学特征或形态学参数与表型数据融合提供工程接口，具有

明确的辅助诊疗价值，为医学影像与临床信息结合的医学软件系统提供了完整解决方案。

## 1.2 国内外研究现状

### 1.2.1 动脉瘤与脑血管影像分析的传统途径

在深度学习普及之前，血管分割与病灶提取多采用基于强度的阈值分割、区域生长、水平集或基于几何先验的滤波器响应等方法。此类流程往往需要人工调节种子点、平滑核大小或曲率约束，且对低对比度瘤颈、邻近骨质高密度灶等干扰敏感，跨中心推广时常需重新调参。面向风险评估，临床多采用 Hunt-Hess 分级、WFNS 评分、PHASES 评分或 ELAPSS 评分等规则体系，其中 PHASES 侧重未破裂动脉瘤未来破裂风险，ELAPSS 更强调增长风险预测<sup>[3,4]</sup>。这些评分简洁、可解释，便于临床沟通，但对瘤体形态不规则、局部血流动力学、影像纹理和多字段非线性特征的刻画能力有限。统计学习阶段则常使用逻辑回归、随机森林等传统机器学习模型；它们在变量个数较少、线性可分性较强的回顾性队列上可给出可解释结果，但对多维具有关联性特征的自适应建模能力有限。

### 1.2.2 基于深度学习的分割与多模态预测

随着公开数据集与算力条件改善，U-Net 及其三维变体逐渐成为血管与病灶分割的主流骨架<sup>[7,9]</sup>。nnU-Net 等工作进一步强调预处理、网络拓扑与后处理的自动化配置，提升了跨任务迁移的效率<sup>[12]</sup>。针对颅内动脉瘤，研究者探索了从血管分割到瘤体检测的多阶段流程，或引入注意力与多尺度模块以强调细小结构<sup>[1,2]</sup>。在预测层面，Transformer 与注意力机制为序列化或多模态特征融合提供了标准实现<sup>[18]</sup>；StrokeNet 等多任务结构尝试同时编码影像与临床信息以预测卒中结局<sup>[14]</sup>。这些工作表明：分割精度与下游临床推理并非割裂——高质量掩膜既可直接用于手术规划，也可作为形态学等衍生特征的载体。

## 1.3 本文面临的问题与主要思路

综合文献与工程经验，本文将任务难点概括为三点。（1）**体数据占用与显存矛盾**：完整 CTA 体积可达数百兆字节以上，若一次性加载多病例批次，普通 GPU 难以承受；需要在“流式 IO—补丁采样—梯度更新”之间取得平衡。（2）**前景极度稀疏**：动脉瘤体素在整幅体积中占比极低，单纯交叉熵易使模型偏向预测背景；需要区域重叠型损失与采样策略共同约束。（3）**风险标签与特征异质性**：破裂与未破裂病例分布不均衡，类别字段存在长尾取值；需要合理的加权损失、阈值搜索与特征筛选，避免仅学习到训练集导致过拟合。

针对上述难点，本文采用“分割骨干+表格风险头”的系统级方案：分割侧选用三维 Attention U-Net，配合病例级流式训练与前景优先补丁采样；风险侧使用基于交叉注意力的表格模型，统一处理数值与类别特征，并在验证集上搜索决策阈值。

## 1.4 课题来源与研究内容

本课题来源于指导教师下达的毕业设计任务书，目标是对颅内动脉瘤 CTA 数据进行计算机辅助检测，并在临床表型与影像衍生特征基础上完成破裂风险的二分类预测。本文工作具体包括：

1. 基于 AttentionUnet 实现三维分割网络，完成编码器—解码器通道配置、注意力门控与 sigmoid 输出的端到端前向传播；
2. 在 MedicalPatchDataset 上实现多目录数据扫描、重采样、标准化及前景优先/顺序采样策略，支撑低显存条件下的长时间训练；
3. 基于 Dice/Tversky/Focal 与 BCE 的组合损失、Adam/AdamW/SGD 与余弦退火等配置化优化流程，训练过程写入 TensorBoard，并按间隔保存最新模型与验证集最优模型；
4. 推理阶段将补丁结果拼接为完整体积，恢复 spacing、origin、direction，输出概率体与二值掩膜供可视化或形态学特征提取；
5. 构建表格风险数据的清洗、互信息特征筛选、加权 BCE 训练、验证集 F1 最优阈值搜索及测试集报告导出；
6. 提供 FastAPI 交互界面，提供文件上传、分割与风险预测流程。

## 1.5 论文结构安排

全文共分五章。第一章介绍研究背景、国内外现状、问题难点与研究内容。第二章梳理医学图像分割、三维卷积网络、注意力机制、类别不平衡学习及表格建模等相关理论基础。第三章从系统架构出发，分述分割模块、风险模块的模型设计与实现要点，并简要说明 Web 服务接口。第四章介绍实验环境、数据集与预处理约定、评价指标与结果分析框架，说明如何根据日志与配置文件复现指标。第五章总结全文并展望未来改进方向。

## 1.6 本章小结

本章从临床需求与技术趋势两方面阐述了颅内动脉瘤辅助分析的研究动机，综述了传统方法与深度学习方法的优劣，归纳了本文面向的三个核心难点及对应思路，并列出了与源代码模块对应的研究内容。后续章节将展开算法与系统实现的细节。

## 2 相关理论基础

### 2.1 脑动脉瘤及分割基本原理

脑动脉瘤是指脑血管壁局部异常膨出所形成的囊状或梭形结构，最常发生于脑底部的 Willis 环及其主要分支。在 CTA 图像中，脑动脉瘤的主要表现为血管壁的局部囊状突出，呈现为“气球样”或“浆果样”的异常膨出结构。

其中，瘤颈（neck）是指动脉瘤与载瘤动脉之间的连接部位，其宽度和形态对临床诊断具有重要意义。




图 2.1 实际脑动脉瘤 CTA 影像示例

如图所示，红色箭头指示区域中，上方血管轮廓相对正常，而下方箭头所指位置可见血管突然异常膨大，呈现典型的脑动脉瘤病灶特征。

### 2.2 医学图像分割基本理论

医学图像分割旨在像素或体素层面实现对目标解剖结构的精确定位，本质上属于密集预测（dense prediction）任务。与自然图像分割不同，CTA 体数据具有三维空间连续性、前景占比极低以及病灶形态变异大等特点。因此，模型不仅需要捕捉局部边缘与纹理信息，还必须维持跨层面的空间一致性。该研究范式已在医学影像深度学习综述中得到明确论证<sup>[19-21]</sup>。

对于颅内动脉瘤分割任务而言，精确的分割结果既能为临床提供直观的可视化依据，也可进一步计算瘤体体积、最大径、形态不规则度等量化指标，成为后续破裂风险评估的重要基础。

在经典监督学习框架下，训练样本由输入图像  $X$  和金标准标签  $Y$  构成，模型的目标是学习从  $X$  到  $Y$  的映射函数  $f_{\theta}(X)$ 。由于医学图像标注成本高、类别分布极度不平衡以及成像条件复杂，实际训练中需在网络结构、损失函数和采样策略上进行权衡，以平衡模型的表达能力和训练稳定性。

## 2.3 卷积神经网络与 U-Net 结构

卷积神经网络（CNN）通过局部感受野、权值共享和层次化特征提取，在医学图像分析中得到广泛应用。对于分割任务，Fully Convolutional Network（FCN）首次将分类网络扩展至像素级预测，实现端到端的密集输出<sup>[8]</sup>。U-Net 则在此基础上引入对称的编码器—解码器结构和跳跃连接（skip connection），有效融合浅层细节信息与深层语义信息，显著提升了医学图像分割性能<sup>[7]</sup>。

鉴于三维医学图像具有较强的层间连续性，3D U-Net 将二维卷积替换为三维卷积和三维上采样，能够同时建模切片内与切片间的空间上下文关系<sup>[9,22]</sup>。在后续工作中，V-Net、UNet++ 与 nnU-Net 分别从体素级残差建模、跳跃连接重设计和自动化配置等角度进一步提升了医学分割性能<sup>[10,12,23]</sup>。然而，三维卷积也带来了更高的计算和显存开销，因此实际应用中常采用补丁训练（patch-based training）、流式加载及混合精度训练等策略进行优化。

## 2.4 注意力机制与 Attention U-Net

注意力机制的核心在于使模型能够自适应地聚焦于与当前任务最相关的特征区域。对于体积小、背景血管复杂的颅内动脉瘤分割任务，若直接拼接所有跳跃连接特征，易将大量无关背景响应传递至解码器，增加误分割风险。Attention U-Net 在跳跃连接处引入注意力门控（Attention Gate）模块，对编码器特征进行筛选，使解码器更关注目标相关区域<sup>[11]</sup>。

从实现机制来看，注意力门控通过将解码器特征与同尺度编码器特征进行联合映射，生成空间权重图，再对编码器特征进行加权。这一过程可视为空间相关性筛选：当某位置更可能属于动脉瘤或邻近血管时，权重被提升；反之则被抑制。该机制在减少背景干扰的同时，较好地保留了 U-Net 对局部边界细节的敏感性。

## 2.5 类别不平衡与损失函数设计

颅内动脉瘤在 CTA 体数据中通常仅占极小比例，属于典型的极度类别不平衡问题。若仅采用标准交叉熵损失，模型容易陷入“全部预测为背景”的平凡解，导致整体准确率虚高而病灶检出能力不足。因此，需要引入侧重前景区域重叠的损失函数。

本项目当前实现并未直接采用 Dice+BCE 作为训练损失，而是在二元交叉熵（BCE）的基础上，根据配置选择 Tversky 损失或 Focal 损失作为形状/难例约束项<sup>[24-26]</sup>。Tversky 损失可视为 Dice 损失在假阳性与假阴性惩罚权重上的推广，其定义如下：

$$\mathcal{L}_{\text{Tversky}} = 1 - \frac{TP + \varepsilon}{TP + \alpha FP + \beta FN + \varepsilon}, \quad (2.1)$$

其中  $TP$ 、 $FP$ 、 $FN$  分别表示软预测意义下的真阳性、假阳性和假阴性， $\alpha$  与  $\beta$  控制两类错误的权重， $\varepsilon$  为平滑系数。配置默认采用 `tversky + bce`，即  $\mathcal{L} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Tversky}}$ ；若选择 `focal + bce`，则使用 Focal 项替代 Tversky 项，以强化难分类像素对梯度的贡献。验证阶段仍计算 Dice 系数作为主要分割重叠指标。

对于后续的动脉瘤破裂风险预测任务，由于正负样本同样存在不平衡，通常需采用正类加权或基于验证集的阈值优化策略，以提升模型对少数类（破裂组）的敏感性。

## 2.6 表格数据学习与特征表示理论

除影像数据外，临床信息、人口统计学特征及既往病史等多以结构化表格形式存在。传统机器学习方法（如逻辑回归、随机森林）在特征维度较低时表现良好，但在高维混合特征（数值型 + 类别型）且存在复杂非线性交互时，表达能力受限。

近年来，深度表格学习借鉴 NLP 中的 Token 化思想，将每个特征字段映射为统一维度的隐向量，再通过注意力机制建模字段间的交互关系。TabTransformer 利用上下文嵌入增强类别变量表达，FT-Transformer 则进一步验证了对数值字段进行 token 化并使用 Transformer 编码的有效性<sup>[16,17]</sup>。该类方法无需人工构造高阶交叉特征，且能统一处理连续与离散变量，为多模态融合提供了灵活高效的特征表示空间。本文的风险预测模块即基于这一思路构建；同时，传统集成学习方法如随机森林和梯度提升树仍是小样本表格任务中的重要比较基线<sup>[27-29]</sup>。

## 2.7 临床风险评分与深度模型的互补关系

未破裂颅内动脉瘤的管理并非单纯的图像分割问题。PHASES 评分综合人群来源、高血压、年龄、动脉瘤大小、既往蛛网膜下腔出血史和部位等因素，用于估计未来破裂风险<sup>[3]</sup>；ELAPSS 评分则将年龄、部位、大小、形态和既往蛛网膜下腔出血等因素纳入未破裂动脉瘤增长风险预测<sup>[4]</sup>。此外，大规模自然病程队列研究也提示，不同部位、不同直径和形态不规则程度的动脉瘤具有不同的破裂倾向<sup>[5,6]</sup>。

上述评分体系具有解释性强、使用门槛低的优点，但其变量项相对固定，难以充分吸收三维分割衍生出的体积、表面不规则度、瘤颈宽度、影像组学纹理等高维



信息。深度学习模型则可在数据充分且划分严格的前提下学习非线性交互。因此，选用交叉注意力神经网络 + 传统机器学习模型作为实际方案，有效结合了两者的优势，并利用这些信息进行更加有效的风险预测。

## 2.8 评价指标基础

分割任务常用 Dice 系数、敏感度 (Sensitivity)、特异度 (Specificity)、Hausdorff 距离等指标，其中 Dice 系数重点衡量预测区域与真实区域的重叠程度。分类与风险预测任务则常用准确率、精确率、召回率、F1 值以及 AUC-ROC 等指标。AUC 反映模型整体排序能力，F1 值则在不平衡场景下更能综合体现精确率与召回率的平衡。鉴于医学管理系统中，对病灶的漏诊远远严重于误诊，因此，本文选择使用召回率来进行模型的首要评判标准，兼用 AUC 进行模型性能评估。

针对极度稀疏的医学分割任务，单纯依赖总体准确率易产生误导。因此，本文在实验中同时报告 Dice 系数、体素级 F1、多阈值统计结果及基于直方图近似的 voxel-wise AUC，以实现模型性能的全面评估；对于不平衡二分类场景，PR 曲线与校准分析同样具有重要参考价值<sup>[30-33]</sup>。

## 2.9 本章小结

本章系统概述了本文研究所需的核心理论基础，包括脑动脉瘤的影像学表现、三维医学图像分割基本问题、U-Net 及其注意力变体、类别不平衡下的损失函数设计、表格数据深度表征方法，以及相关评价指标体系。这些理论为后续章节的模型设计、优化策略与实验分析提供了坚实的理论支撑。

### 3 模型设计

#### 3.1 研究方法总体框架

本文面向颅内动脉瘤智能分析任务，构建了由病灶分割与破裂风险评估组成的两阶段研究框架。该框架遵循“病灶定位—特征生成—风险判别”的基本逻辑：首先利用三维分割网络对 CTA 体数据中的疑似动脉瘤区域进行体素级识别，获得病灶概率分布与空间掩膜；随后基于分割结果与病例层面的临床、形态及影像表型信息构建统一的特征表示，并输入风险预测模型完成患者级破裂概率估计。该流程兼顾了医学影像任务中病灶分割与辅助临床决策的双重需求。

从形式化角度看，设单例 CTA 体数据记为  $X \in \mathbb{R}^{D \times H \times W}$ ，其对应分割标注为  $Y^{(s)} \in \{0,1\}^{D \times H \times W}$ ，病例级风险标签为  $y^{(r)} \in \{0,1\}$ 。本文方法可表示为

$$P = f_{\theta}(X), \quad (3.1)$$

$$\hat{M} = \mathcal{T}(P; \tau_s), \quad (3.2)$$

$$z = \phi(X, \hat{M}, c), \quad (3.3)$$

$$\hat{p} = g_{\omega}(z), \quad (3.4)$$

其中， $f_{\theta}(\cdot)$  表示分割网络， $P \in [0,1]^{D \times H \times W}$  为体素级概率图， $\mathcal{T}(\cdot)$  为基于阈值  $\tau_s$  的二值化映射， $c$  表示病例层面的临床及影像表型变量， $\phi(\cdot)$  表示多源特征构造过程， $g_{\omega}(\cdot)$  为风险预测模型， $\hat{p} \in [0,1]$  为动脉瘤破裂概率估计。由此，本文实际上将像素级结构识别与样本级风险判别纳入统一分析链条，在保证解剖定位能力的同时增强风险建模的结构依据。

#### 3.2 分割任务的理论基础与建模动机

颅内动脉瘤在 CTA 图像中通常表现为体积较小、边界复杂、与邻近血管结构相互黏连的异常膨出区域，因此分割任务具有显著的小目标、强背景干扰与类别不平衡特征。在此类场景下，单纯依赖局部卷积感受野容易产生两类问题：其一，浅层特征虽然保留空间细节，但缺乏足够语义判别能力；其二，深层特征具有较强抽象表示能力，却可能在多次下采样后损失病灶边界信息。U-Net 类结构通过编码器—解码器及跳跃连接机制较好地协调了上述矛盾，因此适合作为三维医学图像分割的基础框架。

然而，标准 U-Net 在复杂血管背景中仍可能引入大量与病灶识别无关的高响应区域。为此，本文在主干结构中引入注意力门控机制，以抑制无关背景特征在跳跃连接中的传播；同时在瓶颈层引入多尺度上下文增强与方向敏感注意力建模，以提升模型对病灶尺度变化、形态不规则性及空间走向复杂性的表达能力。该设计

的理论动机在于：病灶分割并非仅依赖局部灰度差异，而是依赖于局部边界、邻域血管拓扑及多尺度上下文之间的联合判别。

### 3.3 动脉瘤分割模块设计

#### 3.3.1 输入表示与数据采样机制

由于 CTA 体数据具有高维、稀疏和病例间差异较大的特点，本文首先对输入体数据进行统一空间归一化与强度规范化，以减弱扫描条件、体素间距与成像范围差异对模型学习带来的干扰。对于归一化后的三维影像，训练阶段采用基于局部补丁的学习方式，以在有限显存约束下维持足够的空间上下文范围；验证与测试阶段则通过覆盖式滑窗实现覆盖整个数据的推理，保证输出结果的完整性与连续性，减小 patch 边缘的影响。

考虑到动脉瘤区域在整幅体积中的占比通常远低于背景，若采用完全均匀采样策略，模型在训练过程中容易受到背景主导，进而导致前景召回不足。为此，本文采用兼顾前景强化与背景约束的补丁采样机制，即在训练样本构造时适当提高病灶邻域补丁的出现概率，以增强网络对少数类模式的感知能力，同时保留一定比例的背景补丁以维持正常解剖结构判别边界。该策略本质上是一种面向类别不平衡场景的数据分布重加权方法，有助于提高模型对小体积病灶的学习效率。

#### 3.3.2 三维 Attention U-Net 主干结构

分割主干采用三维 Attention U-Net。编码器由多层三维卷积块和逐级下采样操作构成，用于提取从低层纹理到高层语义的分层特征；解码器则通过上采样和特征融合逐步恢复空间分辨率，实现精细的体素级预测。设第  $l$  层编码器特征为  $E_l$ ，解码器特征为  $D_l$ ，则主干网络可抽象为

$$E_l = \mathcal{E}_l(E_{l-1}), \quad l = 1, 2, \dots, L, \quad (3.5)$$

$$B = \mathcal{B}(E_L), \quad (3.6)$$

$$D_l = \mathcal{D}_l(D_{l+1}, \tilde{E}_l), \quad l = L-1, \dots, 1, \quad (3.7)$$

其中， $\mathcal{E}_l(\cdot)$  表示第  $l$  层编码映射， $\mathcal{B}(\cdot)$  表示瓶颈层特征变换， $\mathcal{D}_l(\cdot)$  表示第  $l$  层解码映射， $\tilde{E}_l$  为经注意力筛选后的跳跃连接特征。通过这种由粗到细的层级重建过程，网络能够同时利用深层全局语义信息与浅层边界细节信息，从而提高病灶轮廓恢复能力。

#### 3.3.3 注意力门控跳跃连接机制

在传统 U-Net 中，编码器特征通常直接与对应尺度的解码器特征拼接。这种做法虽然有助于恢复空间分辨率，但也可能将大量背景响应一并引入解码过程，尤




图 3.2 三维 Attention U-Net 分割模型结构

其是在血管、骨性结构及噪声干扰较强的 CTA 场景下更为明显。为缓解这一问题，本文在跳跃连接中采用注意力门控机制，使网络能够依据当前解码语义状态自适应选择更具判别力的编码特征。

设同尺度跳跃特征为  $s$ ，来自解码端的门控信号为  $g$ ，则注意力门控可写为

$$q = \text{ReLU}(W_s s + W_g g + b), \quad (3.8)$$

$$a = \sigma(\psi(q)), \quad (3.9)$$

$$\hat{s} = a \odot s, \quad (3.10)$$

其中， $W_s$  与  $W_g$  为线性投影， $\psi(\cdot)$  为通道压缩映射， $\sigma(\cdot)$  为 Sigmoid 函数， $a$  为取值于  $[0, 1]$  的注意力权重图， $\odot$  表示逐元素乘法。该结构的本质是在跳跃连接处引入条件选择机制：当某些空间位置与当前解码语义更加一致时，对应权重被放大；反之，则被抑制。由此可降低无关背景特征对后续重建的干扰，提高分割结果的病灶聚焦能力。

### 3.3.4 ASPP 多尺度上下文增强模块

动脉瘤的空间形态在不同病例之间可能表现出明显差异，既包括局部球囊样膨出，也包括与载瘤血管边界过渡不清的复杂结构。因此，仅依赖固定尺度卷积核难以充分描述病灶及其邻近血管的多尺度上下文关系。为增强瓶颈层对不同尺度模式的响应能力，本文引入三维 ASPP 模块，通过多分支空洞卷积并行提取不同感受野下的上下文特征。

设瓶颈输入特征为  $X_b$ ，空洞率集合为  $\{d_1, d_2, \dots, d_K\}$ ，则 ASPP 输出可表示为

$$Y_{\text{ASPP}} = \phi \left( \text{Concat} [\mathcal{F}_{d_1}(X_b), \mathcal{F}_{d_2}(X_b), \dots, \mathcal{F}_{d_K}(X_b)] \right), \quad (3.11)$$

其中， $\mathcal{F}_{d_k}(\cdot)$  表示膨胀率为  $d_k$  的三维空洞卷积分支， $\text{Concat}[\cdot]$  表示通道维拼接， $\phi(\cdot)$  表示后续的线性融合与非线性映射。通过在同一层级聚合不同感受野的信息，模型能够更有效地刻画病灶本体、载瘤血管及局部背景之间的关系，从而增强对复杂形态病灶的识别鲁棒性。

### 3.3.5 三维坐标注意力模块

在多尺度上下文建模基础上，本文进一步引入三维坐标注意力模块，以增强网络对方向性位置信息的编码能力。与仅基于通道重加权的注意力形式不同，坐标注意力通过沿不同空间轴汇聚上下文信息，在保留位置依赖关系的同时生成方向敏感权重，因此更适合捕捉血管结构细长、走向复杂的空间特征。

设输入特征为  $X \in \mathbb{R}^{C \times D \times H \times W}$ ，则沿深度、高度与宽度方向的上下文聚合可分别表示为

$$Z_d = \text{AvgPool}_{H,W}(X), \quad Z_h = \text{AvgPool}_{D,W}(X), \quad Z_w = \text{AvgPool}_{D,H}(X). \quad (3.12)$$

三路聚合特征经共享映射与分支解码后得到三个方向注意力图  $A_d$ 、 $A_h$  与  $A_w$ ，最终输出为

$$Y_{\text{CA}} = X \odot A_d \odot A_h \odot A_w. \quad (3.13)$$

该模块通过显式建模空间方向依赖关系，使网络能够在保留通道语义的同时强化对关键位置的响应，有利于提升小病灶边界及空间走向敏感结构的识别精度。

### 3.3.6 输出映射与整例重建

在解码器末端，网络通过  $1 \times 1 \times 1$  卷积将高分辨率特征映射到单通道对数几率空间，并经 Sigmoid 函数获得体素级前景概率图：

$$P_{i,j,k} = \sigma(h_{i,j,k}), \quad (3.14)$$

其中， $h_{i,j,k}$  表示位置  $(i, j, k)$  处的输出 logit， $P_{i,j,k}$  表示对应体素属于动脉瘤前景的概率。基于给定阈值  $\tau_s$ ，可得到二值掩膜

$$\hat{M}_{i,j,k} = \mathbb{I}(P_{i,j,k} \geq \tau_s), \quad (3.15)$$

其中， $\mathbb{I}(\cdot)$  为示性函数。

在整例推理阶段，由于输入体积较大，本文采用滑窗方式对局部补丁逐块预测，并将各窗口输出重新映射回原空间。对于重叠区域，可通过平均融合或中心区




图 3.3 融合 ASPP 与三维坐标注意力的增强分割模型结构

域优先策略进行整合，以减弱窗口边界效应。由此获得的整例概率图与二值分割结果，不仅可用于病灶可视化，也可进一步提取体积、尺寸及形态相关表型，为风险预测阶段提供结构性输入依据。

### 3.3.7 分割损失函数与优化目标

考虑到动脉瘤分割具有显著的前景稀疏特征，单独使用逐体素交叉熵损失容易使模型偏向背景预测，导致小病灶召回不足。为兼顾像素级分类准确性与病灶的准确分割，本文采用由二元交叉熵损失与重叠型损失组成的联合目标函数。

二元交叉熵损失定义为

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{n=1}^N [y_n \log p_n + (1 - y_n) \log(1 - p_n)], \quad (3.16)$$

其中， $N$  为体素总数， $y_n \in \{0, 1\}$  为第  $n$  个体素的真实标签， $p_n \in [0, 1]$  为对应预测概率。为进一步提高模型对前景区域及漏检错误的敏感性，本文引入 Tversky 型损失。设真阳性、假阳性和假阴性分别记为 TP、FP 和 FN，则 Tversky 系数可写为

$$\text{TI} = \frac{\text{TP}}{\text{TP} + \alpha \text{FP} + \beta \text{FN} + \varepsilon}, \quad (3.17)$$

其中， $\alpha$  与  $\beta$  用于平衡假阳性与假阴性的惩罚权重， $\varepsilon$  为避免分母为零的平滑项。对应损失可定义为

$$\mathcal{L}_{\text{T}} = 1 - \text{TI}. \quad (3.18)$$

因此，分割阶段总体优化目标写为

$$\mathcal{L}_{\text{seg}} = \lambda_1 \mathcal{L}_{\text{BCE}} + \lambda_2 \mathcal{L}_{\text{T}}, \quad (3.19)$$

其中， $\lambda_1$  与  $\lambda_2$  为权重系数。该联合目标在理论上同时约束局部判别误差与病灶的错误分割，适合小目标医学图像分割场景。

在优化过程中，模型参数通过基于梯度下降的自适应优化算法进行更新。设第  $t$  次迭代的参数为  $\theta_t$ ，学习率为  $\eta_t$ ，则其更新形式可概括为

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \mathcal{L}_{\text{seg}}(\theta_t). \quad (3.20)$$

训练期间结合验证集性能对模型进行选择，从而在拟合能力与泛化能力之间取得平衡。

### 3.4 破裂风险预测模块设计

#### 3.4.1 多源特征表示与问题定义

风险预测任务关注病例级破裂状态判别，与分割任务的体素级预测不同，其核心在于从多源异构变量中学习稳定的判别表示。设单个病例的输入由数值特征集合  $x^{(n)} \in \mathbb{R}^m$  与类别特征集合  $x^{(c)} \in \mathbb{N}^q$  构成，其中数值特征可包括临床指标、形态学统计量及影像表型描述，类别特征则对应离散化的病例属性。本文通过统一的数据清洗、缺失值处理与标准化策略将不同来源变量映射到可学习特征空间，并将问题定义为概率形式的二分类任务：

$$\hat{p} = \Pr(y^{(r)} = 1 \mid x^{(n)}, x^{(c)}). \quad (3.21)$$

与传统基于手工规则或浅层线性模型的方法相比，本文更关注变量之间潜在的非线性交互作用。例如，某一形态学指标对风险的影响可能依赖于年龄、病灶位置或其他影像表型变量，因此简单线性叠加往往难以充分表达这类高阶关联。为此，本文采用基于 token 表示与交叉注意力机制的表格深度模型，对异构字段之间的依赖关系进行显式建模。

#### 3.4.2 字段嵌入与统一隐空间映射

为使数值特征与类别特征能够在同一模型中进行交互，需先将其映射到维度一致的隐空间。对于第  $i$  个数值特征  $x_i^{(n)}$ ，本文通过可学习线性变换获得其嵌入表示：

$$e_i^{(n)} = W_i^{(n)} x_i^{(n)} + b_i^{(n)}, \quad i = 1, 2, \dots, m, \quad (3.22)$$

其中， $W_i^{(n)}$  与  $b_i^{(n)}$  为可学习参数。对于第  $j$  个类别特征  $x_j^{(c)}$ ，其嵌入表示由查表方式获得：

$$e_j^{(c)} = \text{Emb}_j(x_j^{(c)}), \quad j = 1, 2, \dots, q. \quad (3.23)$$

由此，所有字段均被表示为同维度向量，并共同组成字段级 token 序列

$$E = [e_1, e_2, \dots, e_{m+q}] \in \mathbb{R}^{(m+q) \times d}, \quad (3.24)$$

其中， $d$  为隐空间维度。该表示方式使模型能够将每个字段视为独立信息单元，从而为后续的注意力交互建模提供基础。

### 3.4.3 交叉注意力特征交互机制

本文风险模型的核心思想并非将全部字段直接拼接后输入分类器，而是通过注意力机制自适应学习字段间的相关性权重。设输入 token 表示为  $E$ ，经过线性映射得到查询、键和值矩阵：

$$Q = EW_Q, \quad K = EW_K, \quad V = EW_V, \quad (3.25)$$

其中， $W_Q$ 、 $W_K$  与  $W_V$  为可学习参数。字段间的相关性通过注意力自动计算：

$$\text{Att}(Q, K, V) = \text{Softmax} \left( \frac{QK^\top}{\sqrt{d}} \right) V. \quad (3.26)$$

对于多头注意力机制，可将上述过程扩展为多个子空间并行学习，再通过拼接与线性变换进行融合，从而提高对多类型交互关系的表达能力。

若进一步区分数值字段流与类别字段流，则交叉注意力可以刻画一类字段对另一类字段的条件依赖。例如，设数值字段表示为  $E^{(n)}$ ，类别字段表示为  $E^{(c)}$ ，则一种典型的跨模态交互形式可写为

$$\tilde{E}^{(n)} = \text{Att}(E^{(n)}W_Q^{(n)}, E^{(c)}W_K^{(c)}, E^{(c)}W_V^{(c)}), \quad (3.27)$$

其含义是使用数值字段作为查询，以类别字段提供键和值，从而实现基于类别上下文的数值特征捕捉。通过交替或叠加这两类交互映射，模型得以学习异构字段之间的双向依赖关系，从而形成更具判别力的病例级表示。

### 3.4.4 全局聚合与风险概率输出

在完成字段级交互后，模型需要将多 token 表示汇聚为病例级全局表征。设交互后的字段表示为  $H = [h_1, h_2, \dots, h_{m+q}]$ ，则可采用平均池化、注意力池化或引入全局 token 的方式获得聚合向量  $r$ ：

$$r = \text{Pool}(H). \quad (3.28)$$

随后通过多层感知机完成最终判别，输出破裂风险概率：

$$\hat{p} = \sigma(W_o r + b_o). \quad (3.29)$$



当给定分类阈值  $\tau_r$  时，可得到病例级决策结果

$$\hat{y}^{(r)} = \begin{cases} 1, & \hat{p} \geq \tau_r, \\ 0, & \hat{p} < \tau_r. \end{cases} \quad (3.30)$$

这一过程使模型能够从字段级局部交互过渡到病例级整体判断，符合临床风险评估中“多因素综合判别”的基本思想。

### 3.4.5 风险预测损失函数与类别不平衡处理

破裂风险预测同样面临类别不平衡问题，即阳性样本数量通常少于阴性样本。若直接采用未加权的标准二元交叉熵，模型可能倾向于优先优化多数类准确率，从而削弱对少数类破裂病例的识别能力。为此，本文采用类别加权的二元交叉熵作为训练目标：

$$\mathcal{L}_{\text{risk}} = -\frac{1}{N} \sum_{i=1}^N [w_1 y_i \log \hat{p}_i + w_0 (1 - y_i) \log (1 - \hat{p}_i)], \quad (3.31)$$

其中， $N$  为样本数， $y_i$  为第  $i$  个病例的真实标签， $\hat{p}_i$  为预测破裂概率， $w_1$  与  $w_0$  分别为阳性类与阴性类权重。通过增大少数类样本在损失函数中的贡献，可在一定程度上改善模型对高风险病例的敏感性。

在训练完成后，本文不直接固定使用 0.5 作为分类阈值，而是基于验证集概率输出搜索最优阈值  $\tau_r^*$ ，使综合评价指标达到较优水平：

$$\tau_r^* = \arg \max_{\tau \in [0,1]} \mathcal{J}(\tau), \quad (3.32)$$

其中， $\mathcal{J}(\tau)$  可选取 F1 值、Youden 指数或其他适用于不平衡分类的综合准则。该策略有助于根据实际数据分布确定更合理的决策边界，提高风险预测的应用适配性。

## 3.5 训练与优化过程

本文整体训练过程遵循监督学习范式。对于分割任务，网络通过最小化体素级联合损失学习从三维影像到病灶概率图的映射；对于风险预测任务，模型通过最小化加权分类损失学习从病例级特征表示到破裂概率的映射。两个任务分别在训练集上进行参数更新，在验证集上完成模型选择与超参数调节，并在独立测试集上报告最终性能。

从优化角度看，训练过程本质上是在参数空间中求解经验风险最小化问题：

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(x_i, y_i; \theta), \quad (3.33)$$

其中， $\mathcal{L}(\cdot)$  对于不同任务分别对应  $\mathcal{L}_{\text{seg}}$  与  $\mathcal{L}_{\text{risk}}$ 。为提高训练稳定性，优化过程中结合学习率调度、验证监控及最优检查点保留策略，以降低随机波动对最终结果

的影响。该过程既保证了模型能够充分拟合训练分布，又为后续实验比较提供了统一且可复核的评价基础。

### 3.6 本章小结

本章系统阐述了本文所采用的研究方法与模型设计。首先，从整体框架层面明确了“分割先验驱动风险评估”的两阶段分析思路；其次，围绕三维 Attention U-Net、注意力门控、ASPP 与三维坐标注意力等关键模块，对动脉瘤分割模型的结构组成、输入输出关系与优化目标进行了理论化描述；再次，对风险预测模型中的字段嵌入、交叉注意力交互、全局聚合、加权损失及阈值搜索策略进行了形式化说明。总体而言，本文方法通过多尺度空间表征与多源特征融合相结合，为后续实验验证与结果分析奠定了方法学基础。

## 4 实验与结果分析

### 4.1 实验设计概述

本文实验围绕动脉瘤分割与破裂风险预测两个核心任务展开，分别从体素级病灶识别能力与病例级风险判别能力两个层面对所提出方法进行系统评价。分割实验以 CTA 三维体数据为输入，考察模型输出概率图与人工标注掩膜之间的一致程度；风险预测实验以临床信息、影像表型信息及分割衍生特征为输入，考察模型对动脉瘤破裂状态的区分能力。尽管两项任务在输入形式、输出目标与评价粒度上存在差异，但其共同服务于颅内动脉瘤智能分析这一总体目标，即在影像结构识别基础上进一步实现风险评估。

在实验组织上，本文遵循训练集、验证集与测试集相互独立的基本原则。训练集用于模型参数学习，验证集用于超参数调节、阈值选择与模型筛选，测试集仅用于最终性能报告，以尽可能降低信息泄漏带来的偏差。对于分割任务，重点分析模型在训练后期的收敛稳定性、概率判别能力与病灶检出能力；对于风险预测任务，则重点比较深度交叉注意力模型与传统机器学习模型之间的性能差异，并结合多项评价指标讨论不同模型的判别特征与适用性。

### 4.2 实验环境与基本设置

实验在通用 Linux 计算环境下完成，深度学习模型采用主流张量计算框架进行训练与推理，医学影像读写、空间重采样、数值计算与统计分析均依托成熟的科学计算工具实现。为提高实验过程的可重复性，所有实验均在统一数据划分、统一评价口径和一致训练验证流程下完成记录。本文在结果分析中重点讨论模型表现及其方法学含义，而不涉及具体工程实现细节。

在分割任务中，输入为三维 CTA 体数据。训练阶段采用局部补丁学习策略，以缓解显存限制并提高小目标病灶在训练过程中的可见性；验证阶段则采用滑窗方式进行整例推理，以保证输出结果具有空间完整性。风险预测任务中，输入为病例级表格特征，其中数值变量经标准化处理，类别变量经离散嵌入表示，模型输出为病例级破裂概率。考虑到风险预测任务中正负样本分布通常存在不均衡现象，本文在训练阶段采用类别加权策略，并在验证集上搜索最优判别阈值，以提高模型对少数类样本的识别能力。

### 4.3 评价指标

#### 4.3.1 分割任务评价指标

分割任务的评价需要同时考虑概率判别能力、区域重叠程度与阳性体素检出

能力。设真实前景集合为  $Y$ ，预测前景集合为  $\hat{Y}$ ，则 Dice 系数定义为

$$\text{Dice} = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|}. \quad (4.1)$$

Dice 系数越高，说明预测区域与真实区域的重叠程度越高。由于动脉瘤通常属于体积较小的局部结构，少量边界偏差便可能引起 Dice 的明显波动，因此该指标对分割质量具有较强敏感性。

在体素级二分类视角下，真阳性、假阳性、真阴性与假阴性分别记为 TP、FP、TN 和 FN。召回率定义为

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad (4.2)$$

用于度量真实前景体素中被正确识别的比例。对于医学筛查场景而言，召回率具有重要意义，因为漏检病灶可能直接影响后续临床判断。精确率定义为

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad (4.3)$$

用于衡量预测为前景的体素中真实属于前景的比例。进一步地，Precision 与 Recall 的调和平均可写为

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (4.4)$$

AUC 则从阈值无关角度描述模型对前景与背景体素的整体排序能力，可用于刻画概率输出的可分性。

#### 4.3.2 风险预测评价指标

风险预测属于病例级不平衡二分类问题，因此仅使用 Accuracy 难以全面反映模型性能。Accuracy 定义为

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}, \quad (4.5)$$

反映整体分类正确率，但在正负样本比例失衡时可能掩盖模型对少数类样本的识别不足。因此，本文同时报告 Precision、Recall、F1 与 AUC 等指标，以更全面地刻画模型在风险识别任务中的综合表现。

对于风险预测模型输出的概率  $\hat{p}_i$ ，其二分类结果由阈值  $\tau$  决定：

$$\hat{y}_i = \begin{cases} 1, & \hat{p}_i \geq \tau, \\ 0, & \hat{p}_i < \tau. \end{cases} \quad (4.6)$$

本文在验证集上搜索较优阈值，并将其固定用于测试集评估。该策略能够依据数据分布与任务目标自适应调整决策边界，从而减少默认阈值对实验结论的影响。

表 4.1 主要评价指标及其分析侧重点

| 任务类型   | 指标        | 主要反映内容                   |
|--------|-----------|--------------------------|
| 分割任务   | Dice      | 预测区域与真实区域的重叠程度           |
| 分割任务   | Recall    | 病灶前景体素的检出能力              |
| 分割任务   | Precision | 前景预测结果的可靠性               |
| 分割任务   | AUC       | 前景与背景体素的整体可分性            |
| 风险预测任务 | Accuracy  | 整体分类正确率                  |
| 风险预测任务 | Precision | 高风险预测结果的准确性              |
| 风险预测任务 | Recall    | 破裂病例的识别能力                |
| 风险预测任务 | F1        | Precision 与 Recall 的综合平衡 |
| 风险预测任务 | AUC       | 破裂与未破裂病例的排序能力            |

为便于说明各类评价指标在本文中的功能定位，表 4.1 对本章主要指标及其分析侧重点进行了归纳。

## 4.4 动脉瘤分割实验

### 4.4.1 实验目的与训练过程

分割实验的主要目的是验证三维 Attention U-Net 及其增强结构对颅内动脉瘤病灶的定位能力与轮廓恢复能力。训练过程中，模型通过局部补丁样本学习病灶及其邻域的空间结构模式，并在验证阶段对整例体数据进行滑窗推理。由于分割目标在空间上具有显著稀疏性，实验重点不仅在于提高病灶前景的召回率，还在于控制复杂背景下的误检水平。

从训练过程来看，模型在训练后期的关键指标逐渐趋于稳定，表明网络已基本完成从低层纹理表征到高层病灶语义表征的学习。本文重点统计第 80–100 轮的验证结果，用以观察收敛末期的性能变化。在该阶段，AUC 与 Recall 保持在相对稳定区间，说明模型对前景与背景的概率排序能力较强，且病灶检出性能未出现明显波动。

### 4.4.2 分割结果与阈值分析

以较优验证轮次为代表，在阈值 0.5 下模型取得 AUC 为 0.97、Recall 为 0.56 的结果，表明模型在当前验证数据上已具备较好的体素级区分能力。以最终检查点作为报告对象，在相同阈值下 AUC 为 0.96、Recall 为 0.55，与较优轮次表现接近，说明训练后期模型并未出现明显退化，整体泛化性能并未显著降低。

需要指出的是，较高的 AUC 并不意味着分割结果已经在空间层面达到完全理想的状态。AUC 主要衡量不同阈值下模型对正负体素的整体排序质量，而最终二值掩膜的空间一致性还受到阈值选择、病灶体积、边界清晰度以及重建方式等因素影响。对于小目标病灶而言，即便模型在概率排序层面表现良好，不合适的阈值

仍可能导致边界收缩、局部断裂或离散误检区域。因此，对分割模型的评价应结合 Dice、Recall 与典型病例可视化结果综合分析，而不宜依赖单一指标作出判断。

阈值扫描结果表明，随着分割阈值  $\tau_s$  的提高，模型预测趋于保守，误检体素数量可能减少，但 Recall 往往同步下降；反之，当阈值降低时，模型更倾向于保留低置信度疑似前景，Recall 可能上升，但误检风险也会增加。其决策形式可写为

$$\hat{M}_{i,j,k}(\tau_s) = \mathbb{I}(P_{i,j,k} \geq \tau_s). \quad (4.7)$$

当  $\tau_s$  增大时，满足条件的前景集合单调收缩，因此漏检概率通常增加。对于医学辅助分析场景而言，维持较高的病灶检出能力具有重要意义，但同时也需控制误检区域规模，以保证后续结构定量分析与临床展示的可解释性。

#### 4.4.3 可视化分析与误差来源

从典型病例的可视化结果看，模型在多数病灶区域能够较完整地覆盖动脉瘤主体，并在局部边界上形成相对连续的响应。对于形态较规则、对比度较高的病灶，预测掩膜与人工标注具有较高一致性；而当病灶体积较小、边缘对比度不足、与载瘤血管过渡模糊或邻近高密度结构干扰明显时，模型可能出现局部漏检、边界偏移或少量误检。

这类误差具有一定普遍性。一方面，小病灶在多次下采样过程中容易发生空间信息损失，即使通过跳跃连接进行细节补偿，仍可能难以完全恢复极细小结构边界；另一方面，CTA 中血管增强区域与动脉瘤前景在灰度分布上具有相似性，模型需要借助空间上下文与拓扑关系而非单纯强度差异进行判别。由此可见，后续若需进一步提升分割性能，可从更具针对性的前景采样、边界敏感损失设计、多尺度监督及稳健后处理策略等方面展开优化。

#### 4.4.4 分割模型消融分析

为进一步分析模型性能提升的来源，本文从结构设计角度对分割模型进行了消融讨论。可将基础三维 Attention U-Net、引入 ASPP 的增强模型以及进一步加入三维坐标注意力的模型视为逐步增强的结构序列。基础模型主要依赖编码器—解码器结构和注意力门控完成病灶恢复；ASPP 模块通过多尺度空洞卷积扩大感受野，有助于增强模型对不同尺度病灶及其邻域上下文的刻画能力；三维坐标注意力则进一步引入方向感知的位置建模，对边界模糊、形态不规则或空间走向复杂的病灶具有潜在优势。

在现有实验结果中，增强模型相较于基础模型表现出更优的综合分割性能。在相同训练轮次条件下，ASPP-CA-UNet 的 Recall 达到 0.67，AUC 达到 0.96；与基础模型相比，其 Dice 系数提升约 20%，F1 值提升约 40%。此外，两类模型在绝大

多数背景体素上均保持较高一致性，说明增强模型性能提升并非来源于对背景的过度拟合，而更可能归因于对病灶区域表征能力的增强。为便于比较，表 4.2 对分割消融结果作了汇总。

表 4.2 分割模型消融结果比较

| 模型                          | Recall | AUC  | Dice（相对变化） | F1（相对变化） |
|-----------------------------|--------|------|------------|----------|
| 基础三维 Attention U-Net        | 较低     | 基准水平 | 基准水平       | 基准水平     |
| Attention U-Net + ASPP + CA | 0.67   | 0.96 | +20%       | +40%     |

需要说明的是，由于动脉瘤分割属于高度不平衡的体素级任务，背景体素占比远高于病灶体素，因此“整体像素一致性”往往会受到大量真阴性体素的主导，其解释价值相对有限。相比之下，Dice、Recall 与 F1 等更能体现病灶区域识别能力的指标，能够更加真实地反映模型在本任务中的性能差异。基于此，本文在消融分析中更强调增强结构对病灶区域识别质量的改善，而非单纯关注整体一致性指标。

## 4.5 破裂风险预测实验

### 4.5.1 实验目的与模型设置

破裂风险预测实验旨在评价多源表格特征对病例级破裂状态的判别能力，并比较交叉注意力模型与传统机器学习模型在中小规模医学数据条件下的表现。所有模型均基于相同训练集、验证集与测试集划分进行评估，并在验证集上完成阈值选择，以保证不同模型之间具有统一的比较基础。

本文纳入比较的模型包括交叉注意力深度表格模型、随机森林、逻辑回归、支持向量机、 $k$  近邻以及融合模型。逻辑回归可视为线性可解释基线，随机森林代表非线性集成树模型，支持向量机与  $k$  近邻分别代表基于核映射与局部相似性判别的传统分类方法，而交叉注意力模型则代表通过字段交互学习高阶依赖关系的深度方法。融合模型进一步综合树模型与注意力模型输出，用于检验不同模型范式之间的互补性。

### 4.5.2 对比实验结果

风险预测模型测试集结果如表 4.3 所示。表中 Threshold 表示由验证集确定并固定用于测试集评估的分类阈值。

从表 4.3 可以看出，Forest-Attention Ensemble 在测试集上取得最高的 F1 值 0.7330 与 AUC 值 0.8568，说明传统树模型与深度注意力模型在当前任务中具有一定互补优势。Risk Cross-Attention 模型取得 F1 值 0.7266 和 AUC 值 0.8546，其性能与最优融合模型非常接近，并明显优于逻辑回归、支持向量机及  $k$  近邻等传统单

表 4.3 风险预测模型测试集对比结果

| 模型                        | Accuracy | Precision | Recall        | F1            | AUC           | Threshold |
|---------------------------|----------|-----------|---------------|---------------|---------------|-----------|
| Forest-Attention Ensemble | 0.7944   | 0.6931    | 0.7778        | <b>0.7330</b> | <b>0.8568</b> | 0.350     |
| Risk Cross-Attention      | 0.7852   | 0.6832    | 0.7667        | 0.7266        | 0.8546        | 0.325     |
| Random Forest             | 0.7419   | 0.6182    | 0.7556        | 0.6800        | 0.8284        | 0.400     |
| Logistic Regression       | 0.6895   | 0.5512    | 0.7778        | 0.6452        | 0.7342        | 0.450     |
| KNN                       | 0.5766   | 0.4576    | <b>0.9000</b> | 0.6067        | 0.6966        | 0.200     |
| SVM-RBF                   | 0.5565   | 0.4451    | <b>0.9000</b> | 0.5956        | 0.6732        | 0.300     |

模型基线。这表明基于字段级交互的深度建模方式能够较有效地捕获临床变量与影像表型变量之间的非线性关联。

进一步分析可见，随机森林在 Accuracy、F1 和 AUC 等多项指标上均优于多个传统基线，体现出集成树模型在中小规模表格数据上的稳定性与适应性。相比之下，KNN 与 SVM-RBF 虽然在 Recall 上达到 0.9000，表现出较强的阳性病例检出倾向，但其 Precision 分别仅为 0.4576 和 0.4451，导致 F1 与 AUC 均处于较低水平。这说明上述模型更倾向于将样本判定为高风险类别，虽提高了召回能力，却显著增加了误报率。逻辑回归具有较强可解释性，但其 AUC 仅为 0.7342，提示线性决策边界难以充分刻画当前多源特征中的复杂非线性关系。

4.5.3 阈值选择与不平衡分类讨论

风险预测实验中，各模型的最优阈值普遍低于或接近 0.5，这表明在类别不平衡条件下，默认判别阈值未必能够适配医学风险识别任务的实际需求。对于输出概率  $\hat{p}$  而言，降低阈值会使更多病例被判定为高风险，进而提高 Recall，但也可能降低 Precision；提高阈值则会产生相反效果。因此，阈值选择本质上是在漏诊风险与误报代价之间进行权衡。

从临床辅助分析角度看，破裂风险预测通常更关注高风险病例的检出能力，因此 Recall 具有较高参考价值；但若 Precision 过低，则可能导致过多低风险病例被误判为高风险，从而增加后续检查、复核与干预负担。F1 值通过综合考察 Precision 与 Recall，为不平衡二分类任务提供了更平衡的评价视角；AUC 则从全阈值范围反映模型对阳性与阴性病例的排序能力，可用于模型间总体判别能力的比较。

4.5.4 风险模型结果讨论

综合各类指标可以看出，基于交叉注意力的深度表格模型在当前任务中具有较强竞争力，但并未绝对优于所有传统方法。其原因可能在于：一方面，交叉注意力机制能够显式建模异构字段之间的复杂依赖关系，因此在处理多源医学表格特



征时具有较强表达能力；另一方面，在样本规模相对有限的条件下，传统集成学习模型往往具有更好的稳健性与更低的过拟合风险。因此，深度模型与传统模型之间并非简单替代关系，而在不同数据条件和评价目标下各具优势，因此，使用融合模型以结合二者优点往往可以获取更好的结果。

融合模型取得最优综合性能，进一步支持了上述判断。该结果说明，基于树模型的分裂规则与基于注意力机制的表示学习关注到了不同类型的判别模式与数据特征，二者结合能够在一定程度上缓解单一模型的偏差，从而提升整体分类性能。这也提示后续研究可进一步探索更加系统的模型融合策略，以提高风险预测结果的稳定性与泛化能力。

## 4.6 结果综合讨论

综合分割与风险预测实验可以看出，本文方法在当前数据条件下实现了较为完整的从影像结构识别到病例风险估计的分析流程。分割模型在体素级 AUC 与 Recall 上表现稳定，说明其能够较好地地区分病灶前景与复杂背景；风险预测模型在 F1 与 AUC 上接近最优融合模型，说明交叉注意力机制在多源表格特征建模方面具有较好的适用性。

从方法构成看，分割任务中的注意力门控、ASPP 与三维坐标注意力分别对应背景抑制、多尺度上下文聚合与方向位置建模，三者共同增强了模型对复杂血管结构的表达能力。风险预测任务中的字段级嵌入与交叉注意力机制则将传统的特征拼接过程转化为可学习的交互表示，使模型能够在病例层面捕获临床变量、影像表型与形态特征之间的潜在依赖关系。

同时，实验结果也提示了若干值得进一步关注的问题。首先，医学影像数据规模有限且标注成本较高，单次数据划分结果可能受到样本分布差异影响；其次，风险预测任务中的类别不平衡会显著影响阈值选择与指标解释；再次，深度表格模型在中小样本医学任务中并不必然稳定优于传统集成模型，合理的正则化、特征选择、模型校准与外部验证仍然十分必要。因此，本文实验结果更适宜被理解为对所提方法有效性的阶段性验证，而非对其临床泛化能力的最终结论。

## 4.7 系统闭环验证

为验证整体方法流程的完整性，本文将分割推理、特征提取与风险预测组织为端到端演示闭环。该闭环能够从输入影像出发，依次完成病灶概率图生成、二值掩膜输出、结构信息汇聚与破裂风险概率估计，并以可视化形式呈现关键结果。系统闭环验证的意义不在于替代临床诊断，而在于证明所提出的分割方法与风险建模方法可以在统一分析流程中协同运行，从而为后续临床可用性研究与系统化部署

提供原型基础。

## 4.8 本章小结

本章从实验设计、评价指标、分割实验、风险预测对比、消融分析与结果讨论等方面，对本文方法进行了较为系统的实验性评价。结果表明，分割模型在当前验证数据上具有较好的体素级判别能力与病灶检出能力；风险预测模型能够有效利用多源表格特征，并在测试集上取得接近最优融合模型的综合表现。总体而言，本文方法在病灶识别与风险评估两个层面均达到了预期目标，但其稳健性，泛化能力的检测与提升仍有赖于更大规模、多中心的多轮重复实验的进一步验证与优化。

## 5 总结与展望

### 5.1 研究工作总结

本文围绕颅内动脉瘤智能分析问题，构建了由病灶分割与破裂风险预测组成的研究框架，并在统一实验流程下完成了方法设计、模型训练、结果评估与原型验证。研究工作的核心目标在于：一方面，利用三维医学影像分割方法实现对动脉瘤区域的精细识别与结构刻画；另一方面，结合病例层面的临床信息、影像表型信息及分割衍生结构特征，建立面向破裂风险评估的分类模型，从而形成由解剖结构分析到病例级风险判别的完整技术链条。

在方法层面，本文针对 CTA 图像中动脉瘤体积小、背景复杂和类别不平衡等问题，构建了以三维 Attention U-Net 为主干的分割模型，并结合多尺度上下文增强与方向敏感注意力机制提升病灶表征能力。针对风险预测任务中多源异构表格特征之间存在复杂非线性交互的问题，本文进一步设计了基于字段嵌入与交叉注意力的风险模型，以增强对变量间高阶依赖关系的刻画能力。通过上述设计，本文实现了影像空间表征与病例级决策建模的有机衔接，同时给出了完整的工程实现。

### 5.2 主要研究结论

基于实验结果，可以得到以下几点主要结论。

第一，在动脉瘤分割任务中，所构建的三维分割模型在验证阶段表现出较高的体系级判别能力和较稳定的阳性检出能力，说明该模型能够较好地复杂 CTA 背景中识别目标病灶区域。注意力门控机制有助于抑制无关背景响应，多尺度上下文聚合与方向敏感注意力则进一步增强了模型对小目标、复杂形态和空间走向特征的表达能力。

第二，在破裂风险预测任务中，基于交叉注意力的深度表格模型能够有效学习临床变量、影像表型变量与结构化形态特征之间的交互关系。测试结果表明，该模型在 F1 与 AUC 等核心指标上接近最优融合模型，并整体优于多种传统单模型基线，说明通过字段级表示学习和注意力交互机制能够提升多源医学表格数据的风险判别能力。

第三，融合模型取得了最高的综合性能，这表明深度注意力模型与传统集成学习模型在当前任务中具有一定互补性。前者更擅长挖掘连续隐空间中的复杂关联模式，后者则在中小样本场景下表现出较强稳健性。因此，在医学风险预测问题中，单一模型范式未必能够完全占优，合理结合不同方法的优势可能是提升性能的重要方向。

第四，从整体流程角度看，本文实现了由病灶分割到风险评估的闭环验证，说

明基于影像结构识别结果构建病例级风险表征具有可行性。这一结果表明，分割任务不仅可以作为独立的病灶检测工具，也可以为后续风险判别提供具有解剖学意义的表征，从而增强模型的医学使用价值。

### 5.3 研究不足

尽管本文在方法构建与实验验证方面取得了一定结果，但仍存在若干不足，主要体现在以下几个方面。

首先，数据规模与来源范围仍然有限。医学影像与临床数据的采集和标注成本较高，导致当前研究更多是在相对有限的条件下开展。样本量不足不仅会限制深度模型对复杂模式的充分学习，也可能使实验结果对特定数据划分较为敏感，从而影响统计稳健性与泛化能力。

其次，外部验证仍然不足。本文实验主要基于既定数据划分展开，虽然能够反映模型在当前数据分布下的有效性，但尚不能充分说明模型在不同中心、不同扫描设备、不同人群结构和不同标注标准下的稳定泛化能力。对于医学人工智能模型而言，外部独立验证是评价模型真实应用价值的重要环节。

再次，风险预测任务仍然面临类别不平衡与特征异质性带来的挑战。虽然本文通过类别加权、阈值搜索和注意力交互机制在一定程度上缓解了相关问题，但在小样本条件下，深度表格模型对特征噪声、超参数设置和初始化随机性的敏感性仍然不可忽视。这也是为何传统树模型在当前实验中依然具有较强竞争力的原因之一。

最后，本文的结果解释仍主要集中于性能指标层面，对模型内部决策依据的临床可解释分析仍有待加强。例如，不同临床变量、形态变量和影像表型变量在风险预测中的相对贡献尚需通过更系统的可解释性方法进行量化；分割结果中的局部误差如何进一步影响后续风险建模，也值得深入研究。

### 5.4 未来工作展望

针对上述不足，未来研究可从以下几个方向进一步推进。

第一，扩大数据规模并开展多中心验证。后续工作可进一步引入来自不同中心、不同设备和不同扫描协议的数据，以增强样本多样性，并通过外部测试集、交叉验证和置信区间分析更严格地评估模型稳定性与泛化性能。这不仅有助于提升方法的可信度，也更符合医学人工智能从学术研究向临床应用推广转化的基本要求。

第二，进一步优化分割模型的结构表达与监督机制。未来可探索更强的三维上下文建模策略、边界敏感损失函数、层级监督机制以及面向小目标的困难样本挖掘方法，以提升病灶边界恢复能力和对复杂解剖背景的鲁棒性。同时，还可研究如

何将血管拓扑先验或形态约束显式引入模型训练，以增强分割结果的结构合理性。

第三，深化风险预测中的特征融合与可解释性建模。后续可结合更丰富的形态学定量指标、时序随访信息或多模态影像表征，构建更全面的病例级特征空间；同时可引入注意力可视化、特征归因、概率校准和不确定性估计等方法，从而提高风险预测结果的可解释性、可信度与临床可读性。

第四，探索分割与风险预测的联合优化机制。本文采用的是两阶段分析框架，具有结构清晰、实现简洁的优点，但分割与风险建模之间仍可能存在更深层次的协同关系。未来可以考虑建立端到端联合学习框架，使影像空间特征、病灶结构表征与风险标签在部分统一模型中协同优化，从而进一步增强任务间的信息传递效率与特征捕获能力，进而提升模型的整体性能。

第五，推动方法从实验验证走向更规范的应用研究。未来工作可进一步完善推理效率评估、结果一致性分析、临床工作流适配和人机协同机制设计，并结合前瞻性研究验证模型在真实场景中的辅助价值。只有在算法性能、可解释性、稳定性和使用流程等多个层面均得到充分论证，相关研究成果才可能具备更高的临床转化潜力。

## 5.5 结束语

总体而言，本文围绕颅内动脉瘤智能分析任务，完成了从三维病灶分割到破裂风险预测的系统研究，并在方法设计与实验分析层面取得了较为完整的阶段性结果。本文工作表明，结合多尺度医学影像表征与多源临床特征融合，可以为动脉瘤的自动识别与风险评估提供具有一定实证基础的技术路径。尽管当前研究仍存在数据规模、外部验证和可解释性等方面的局限，但其在方法框架与实验结果上已为后续深入研究奠定了基础，也为相关医学人工智能技术的持续优化与应用探索提供了参考。

## 参 考 文 献

- [1] Chen S, Xu Z, Zhao X, et al. Coarse-to-fine guided salient object detection for automatic cerebral aneurysm identification[J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 3052-3063.
- [2] Ou Y, Hua K L, Cheng X, et al. Automatic diagnosis of 3D cerebral vascular images using deep learning[J]. IEEE Access, 2022, 10: 34281-34291.
- [3] Greving J P, Wermer M J H, Brown R D J, et al. Development of the PHASES score for prediction of risk of rupture of intracranial aneurysms[J]. The Lancet Neurology, 2014, 13(1): 59-66.
- [4] Backes D, Rinkel G J E, Laban K G, et al. ELAPSS score for prediction of risk of growth of unruptured intracranial aneurysms[J]. Neurology, 2017, 88(17): 1600-1606.
- [5] Morita A, Kirino T, Hashi K, et al. The natural course of unruptured cerebral aneurysms in a japanese cohort[J]. The New England Journal of Medicine, 2012, 366(26): 2474-2482.
- [6] Thompson B G, Brown R D J, Amin-Hanjani S, et al. Guidelines for the management of patients with unruptured intracranial aneurysms: A guideline for healthcare professionals from the american heart association/american stroke association[J]. Stroke, 2015, 46(8): 2368-2400.
- [7] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2015: 234-241.
- [8] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 3431-3440.
- [9] Cicek O, Abdulkadir A, Lienkamp S S, et al. 3D u-net: learning dense volumetric segmentation from sparse annotation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2016: 424-432.
- [10] Milletari F, Navab N, Ahmadi S A. V-net: Fully convolutional neural networks for volumetric medical image segmentation[C]//2016 Fourth International Conference on 3D Vision (3DV). IEEE, 2016: 565-571.
- [11] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-net: Learning where to look for the pancreas [A]. 2018.
- [12] Isensee F, Jaeger P F, Kohl S A A, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature Methods, 2021, 18(2): 203-211.
- [13] Kamnitsas K, Ledig C, Newcombe V F J, et al. Efficient multi-scale 3D CNN with fully connected CRF for accurate brain lesion segmentation[J]. Medical Image Analysis, 2017, 36: 61-78.

- [14] Chen J, Zhuang J, Shen Y, et al. StrokeNet: A multi-task neural network for stroke outcome prediction[J]. *NeuroImage: Clinical*, 2022, 33: 102927.
- [15] Xiong L, Wang Y, Chen H, et al. Multimodal deep learning for predicting ischemic stroke outcome [J]. *IEEE Transactions on Medical Imaging*, 2025, 44(2): 523-534.
- [16] Huang X, Khetan A, Cvitkovic M, et al. Tabtransformer: Tabular data modeling using contextual embeddings[A]. 2020.
- [17] Gorishniy Y, Rubachev I, Khrulkov V, et al. Revisiting deep learning models for tabular data[C]// *Advances in Neural Information Processing Systems*. 2021.
- [18] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]// *Advances in Neural Information Processing Systems*. 2017: 5998-6008.
- [19] Litjens G, Kooi T, Bejnordi B E, et al. A survey on deep learning in medical image analysis[J]. *Medical Image Analysis*, 2017, 42: 60-88.
- [20] Shen D, Wu G, Suk H I. Deep learning in medical image analysis[J]. *Annual Review of Biomedical Engineering*, 2017, 19: 221-248.
- [21] Maier A, Syben C, Lasser T, et al. A gentle introduction to deep learning in medical image processing[J]. *Zeitschrift f"ur Medizinische Physik*, 2019, 29(2): 86-101.
- [22] Cicek O, Abdulkadir A, Lienkamp S, et al. 3d u-net: Learning dense volumetric segmentation from sparse annotation[C]// *MICCAI*. 2016: 424-432.
- [23] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. Unet++: A nested u-net architecture for medical image segmentation[J]. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, 2018: 3-11.
- [24] Sudre C H, Li W, Vercauteren T, et al. Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations[J]. *DLMIA/ML-CDS@MICCAI*, 2017: 240-248.
- [25] Salehi S S M, Erdogmus D, Gholipour A. Tversky loss function for image segmentation using 3d fully convolutional deep networks[J]. *MLMI@MICCAI*, 2017: 379-387.
- [26] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]// *Proceedings of the IEEE International Conference on Computer Vision*. 2017: 2980-2988.
- [27] Breiman L. Random forests[J]. *Machine Learning*, 2001, 45(1): 5-32.
- [28] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[J]. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016: 785-794.
- [29] Hastie T, Tibshirani R, Friedman J. The elements of statistical learning[J]. *Springer Series in Statistics*, 2009.
- [30] Saito T, Rehmsmeier M. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets[J]. *PLOS ONE*, 2015, 10(3): e0118432.

- [31] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[J]. International Conference on Machine Learning, 2017: 1321-1330.
- [32] Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning[J]. Proceedings of the 22nd International Conference on Machine Learning, 2005: 625-632.
- [33] Chicco D, Jurman G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation[J]. BMC Genomics, 2020, 21(1): 6.



## 附录 A：关键配置与复现实验步骤

### A.1 项目结构说明

本项目采用模块化目录布局，便于维护、扩展与复现实验：

- core/：配置数据结构、YAML 加载与随机种子管理；
- data/：医学影像补丁数据管线与风险表格数据处理；
- model/：分割模型（aneurysm）与风险模型（risk）；
- script/：训练、评估与对比实验入口脚本；
- ui/：FastAPI 服务与推理接口封装；
- utils/：日志、路径与通用工具函数。

### A.2 环境配置建议

Python  $\geq 3.8$

torch $\geq 1.9.0$

monai $\geq 0.7.0$

numpy $\geq 1.21.0$

pandas $\geq 1.3.0$

scikit-learn $\geq 1.0.0$

SimpleITK $\geq 2.1.0$

tensorboard

tqdm

fastapi

uvicorn

建议安装后执行 `python -c "import torch; print(torch.cuda.is_available())"` 验证 GPU 可用性。

### A.3 分割任务复现实验步骤

1. 准备 NIfTI 影像与标签数据，确保命名规则与配置文件一致；
2. 复制并修改配置文件（如 config/host.yaml），填写训练/验证路径；
3. 运行训练命令：`python script/train_split.py -config path/to/your.yaml`；
4. 通过 TensorBoard 观察收敛曲线并记录最优检查点；
5. 运行评估脚本导出指标与可视化结果。

## A. 4 风险预测复现实验步骤

1. 准备包含标签列与病例 ID 的表格数据（Excel/CSV）；
2. 在配置中启用风险模块并设置特征与训练参数；
3. 运行训练命令：`python script/train_risk.py --config path/to/your.yaml`；
4. 查看输出 `risk_report.json` 并记录 F1、AUC 与最优阈值；
5. 可选运行 `compare_risk_models.py` 与传统模型进行统一对比。

## A. 5 关键参数说明

- 分割参数：`train.epochs`、`train.patch_size`、`train.learning_rate`、`eval_interval`；
- 风险参数：`risk.hidden_dim`、`risk.num_heads`、`risk.num_layers`、`risk.threshold_search_steps`；
- 数据参数：`data.patch_sampling_mode`、`risk.feature_select_method`。

## A. 6 常见问题与排查建议

- **显存不足**：减小 `patch_size` 或减少每例补丁数量；
- **训练不收敛**：检查学习率、标签映射及数据归一化流程；
- **指标异常波动**：固定随机种子并核查数据划分一致性；
- **LaTeX 目录报错**：清理 `.aux/.toc/.out` 后重新编译。

## 致 谢

本论文的完成离不开各位老师、同学和家人的支持与帮助。

首先，我要感谢我的指导教师，感谢您在论文选题、研究方法和实验设计等方面的悉心指导，您的严谨治学态度和渊博的专业知识使我受益匪浅。

其次，我要感谢实验室的各位同学，在项目开发过程中，大家互相交流、共同探讨，营造了良好的学术氛围。特别感谢师兄师姐们在技术实现方面给予的宝贵经验和建议。

再次，我要感谢我的家人，感谢你们一直以来的理解、支持和鼓励，让我能够安心完成学业。

最后，感谢所有为本研究提供数据和技术支持的机构和个人。正是有了各方的支持与帮助，本研究才能够顺利完成。

## 原创性声明

郑重声明：所呈交的论文（设计）《\_\_\_\_\_》，是本人在导师的指导下，独立进行研究取得的成果。除论文（设计）中已经标注引用的内容外，本论文（设计）不包含其他人或集体已经发表或撰写过的作品成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

论文（设计）作者签名：\_\_\_\_\_

日期：\_\_\_\_\_

## 使用授权书

本论文（设计）作者完全了解学校有关保留、使用论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）复印件和电子版，允许论文（设计）被查阅和借阅。本人授权重庆大学将本论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制方式保存和汇编本论文（设计）。

本论文（设计）属于：

保 密 ☐ 在\_\_\_\_\_年解密后适用本授权书

不保密 ☐

论文（设计）作者签名：\_\_\_\_\_

指导教师签名：\_\_\_\_\_

日期：\_\_\_\_\_

日期：\_\_\_\_\_