

重庆大学本科生毕业论文（设计）

基于深度学习的颅内动脉瘤检测与破裂风险 预测系统



学 生： 申建松

学 号： 20221556

指导教师： 文静

专 业： 计算机科学与技术

重庆大学计算机学院

2026 年 6 月

Undergraduate Thesis (Design) of Chongqing University

**Deep Learning-Based Intracranial
Aneurysm Detection and Rupture Risk
Prediction System**



By

SHEN Jiansong

Supervised by

Assoc. Prof. WEN Jing

and

Computer Science and Technology

College of Computer Science, Chongqing University

Chongqing University

June, 2026

摘 要

颅内动脉瘤属于较常见的脑血管异常，破裂后可能引发蛛网膜下腔出血，整体危险性较高。CTA 可以较清楚地呈现载瘤血管以及瘤体形态，但鉴于切片数量多、血管分叉复杂且存在骨伪影，人工阅片仍容易出现漏检或判断不一致。动脉瘤破裂风险还会受到年龄、基础病、瘤体形态以及位置等因素影响，单纯依靠传统量表或统计模型，往往难以充分刻画这些变量之间的非线性关系。因此，研究一种能够从影像中稳定分割动脉瘤，并结合临床信息开展风险分层的辅助方法，具有实际应用价值。

针对这一需求，本文在毕业设计阶段实现了两条可复现的技术路线。首先，在分割任务中选用三维 Attention U-Net，并在基础结构上进一步集成 ASPP 多尺度上下文模块以及三维坐标注意力模块。基础模型保留 U-Net 的多尺度跳跃连接，同时在解码端加入注意力门控，对来自编码器的特征进行筛选，使网络在大量背景体素当中更关注疑似瘤体区域；增强模型则在瓶颈层借助 ASPP 扩大感受野，并运用坐标注意力沿深度、高度以及宽度方向重标定特征，以提高对细小动脉瘤以及复杂血管走向的表达能力。训练时选用病例级流式加载以及三维补丁采样，并结合重采样以及强度归一化，以便在有限显存下处理大体积 CTA 数据；损失函数由二元交叉熵以及 Dice 损失组合而成，用于同时兼顾分类准确性以及区域重叠度。推理时，模型会对整例数据进行分块预测，再把结果拼接回原始空间，便于后续使用。

其次，在破裂风险预测任务中，本文面向表格型临床以及影像衍生特征，构建基于交叉注意力的深度表格模型：数值与类别字段分别映射到统一隐空间，经过多层交叉注意力融合后由多层感知机输出破裂概率。数据处理囊括缺失值填补、低频类别合并、特征筛选，以及面向类别不平衡的加权损失与验证集阈值优选。

在固定训练/验证/测试划分下，本文进一步将所提模型与随机森林、逻辑回归、支持向量机、 k 近邻以及融合模型进行离线比较。结果表明，融合模型在测试集上取得最高 F1 值 0.7330 以及 AUC 0.8568；本文的交叉注意力模型取得 F1 值 0.7266 以及 AUC 0.8546，整体性能接近最优结果，同时优于单独的逻辑回归、支持向量机以及 k 近邻方法。这说明基于注意力的特征交互机制可以有效建模异构风险因素之间的非线性关系，但在当前小样本条件下，传统机器学习模型仍保持较好效果。

整体实现以配置驱动方式串联分割以及风险两条流程，并提供简易交互界面，支撑从体数据读入到辅助分析演示的闭环。受数据脱敏以及伦理审批进度限制，分割定量指标需结合具体实验设置进行解读；风险预测结果目前仍基于固定划分下的一次离线对比，尚不构成多中心外部验证结论。

关键词：颅内动脉瘤；CTA；三维分割；Attention U-Net；表格学习；交叉注意力；破裂风险预测

ABSTRACT

Intracranial aneurysms are a common cerebrovascular abnormality. If they rupture, they can cause subarachnoid hemorrhage and lead to serious outcomes. CTA can show the parent vessel and aneurysm shape clearly before treatment, but the full image series is large, and vessel bifurcations and bone artifacts make manual reading difficult. Rupture risk is also influenced by multiple factors such as age, comorbidities, aneurysm shape, and location, so traditional scores or simple statistical models often fail to capture the nonlinear relations among mixed data types. For this reason, a computer-aided method that can segment aneurysms from vascular images and stratify risk using clinical features is practically valuable.

To address this problem, this thesis implements two reproducible pipelines. First, for segmentation, a 3D Attention U-Net is adopted and further enhanced with an ASPP module and a 3D coordinate-attention module. The base model keeps the multi-scale skip connections of U-Net and adds attention gates in the decoder to filter encoder features, helping the network focus on likely aneurysm regions in CTA volumes dominated by background voxels. The enhanced model inserts ASPP at the bottleneck to enlarge the receptive field and aggregate multi-scale vascular context, and then applies coordinate attention along the depth, height, and width axes to recalibrate position-sensitive features, thereby improving the representation of small aneurysms and tortuous vessel structures. Training uses case-wise streaming and 3D patch sampling, together with spacing resampling and intensity normalization, so that large CTA volumes can be processed with limited GPU memory. The loss combines binary cross-entropy and Dice loss to balance classification accuracy and region overlap. During inference, the full volume is predicted patch by patch and then stitched back into the original space for later use.

Second, for rupture-risk prediction, this thesis builds a cross-attention-based deep tabular model for clinical and imaging-derived features. Numeric and categorical fields are mapped into a shared latent space, fused through stacked cross-attention blocks, and passed to an MLP head for rupture probability. The pipeline includes missing-value imputation, rare-category grouping, feature selection, class-frequency-weighted loss, and validation-set threshold tuning to mitigate imbalance.

Under a fixed train/validation/test split, the proposed model is further compared with random forest, logistic regression, SVM, KNN, and an ensemble model. The ensemble achieves the best test performance with an F1 score of 0.7330 and an AUC of 0.8568, while

the proposed cross-attention model reaches an F1 score of 0.7266 and an AUC of 0.8546. These results show that attention-based feature interaction is effective for heterogeneous risk factors, although traditional ensemble methods remain highly competitive under the current small-sample setting.

The implementation is configuration-driven for both branches and includes a lightweight web interface for volume upload and an end-to-end auxiliary-analysis demonstration. The data are de-identified and ethics review is ongoing, so quantitative segmentation should be read with the experimental setup in mind; the risk-prediction results are still based on a single offline comparison under a fixed split rather than a multi-center external validation.

Key words: intracranial aneurysm; CTA; 3D segmentation; Attention U-Net; tabular learning; cross-attention; rupture risk prediction

目 录

摘要.....	I
ABSTRACT.....	III
1 绪论.....	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 动脉瘤与脑血管影像分析的传统途径	2
1.2.2 基于深度学习的分割与多模态预测	2
1.3 本文面临的问题与主要思路	2
1.4 课题来源与研究内容	3
1.5 论文结构安排	3
1.6 本章小结	4
2 相关理论基础.....	5
2.1 脑动脉瘤及分割基本原理	5
2.2 医学图像分割基本理论	5
2.3 卷积神经网络与 U-Net 结构	6
2.4 注意力机制与 Attention U-Net	6
2.5 类别不平衡与损失函数设计	7
2.6 表格数据学习与特征表示理论	7
2.7 临床风险评分与深度模型的互补关系	8
2.8 评价指标基础	8
2.9 本章小结	8
3 模型设计.....	9
3.1 研究方法总体框架	9
3.2 分割任务的理论基础与建模动机	10
3.3 动脉瘤分割模块设计	10
3.3.1 输入表示与数据采样机制	10
3.3.2 三维 Attention U-Net 主干结构	11
3.3.3 注意力门控跳跃连接机制	12
3.3.4 ASPP 多尺度上下文增强模块	13
3.3.5 三维坐标注意力模块	14
3.3.6 输出映射与整例重建	14
3.3.7 分割损失函数与优化目标	15

3.4 破裂风险预测模块设计	17
3.4.1 多源特征表示与问题定义	17
3.4.2 字段嵌入与统一隐空间映射	17
3.4.3 交叉注意力特征交互机制	18
3.4.4 全局聚合与风险概率输出	19
3.4.5 风险预测损失函数	19
3.5 训练与优化过程	20
3.6 本章小结	20
4 实验与结果分析	22
4.1 实验设计概述	22
4.2 实验环境与基本设置	22
4.3 评价指标	23
4.3.1 分割任务评价指标	23
4.3.2 风险预测评价指标	24
4.4 动脉瘤分割实验	25
4.4.1 实验目的与训练过程	25
4.4.2 分割结果与阈值分析	26
4.4.3 可视化分析与误差来源	26
4.4.4 分割模型消融分析	27
4.5 破裂风险预测实验	28
4.5.1 实验目的与模型设置	28
4.5.2 对比实验结果	29
4.5.3 阈值选择与不平衡分类讨论	30
4.5.4 风险模型结果讨论	31
4.6 结果综合讨论	31
4.7 系统闭环验证	32
4.8 本章小结	32
5 总结与展望	33
5.1 研究工作总结	33
5.2 主要研究结论	33
5.3 研究不足	34
5.4 未来工作展望	35
5.5 结束语	36
参考文献	37

附录 A：关键配置与复现实验步骤.....	40
致谢.....	42
原创性声明和使用授权书.....	43

1 绪论

1.1 研究背景与意义

脑血管疾病长期位居我国居民死因构成前列，其中颅内动脉瘤即 **Intracranial Aneurysm, IA** 可在无症状阶段被影像学检查偶然发现；一旦瘤壁完整性受损并导致蛛网膜下腔出血，病情通常较为凶险，遗留神经功能障碍的比例也不容忽视。数字减影血管造影即 **DSA** 被视作诊断“金标准”，但它的有创性以及费用限制了其在大规模筛查场景中的普及。**CT 血管成像**，即 **CT Angiography, CTA** 具有无创、可及性高的特性，在当前门诊以及急诊情境下，是动脉瘤检出与术前评估的重要工具^[1,2]。

然而在临床实际工作当中，仍然存在三方面痛点。第一，单次检查产生的切片可达数百层，医生需要在三维空间中追踪复杂血管脉络，并且辨别细微隆起，长时间阅片容易引起视觉疲劳以及漏诊。第二，不同扫描协议、重建层厚以及对比剂充盈程度会带来图像对比度、颜色以及间隔等差异，同一算法在不同数据以及硬件条件下难以保持足够稳定性与可靠泛化能力。第三，是否建议干预不仅取决于“有没有瘤”，还与瘤体大小、形态不规则度、位置、患者年龄以及合并症等因素相关；现有临床诊断往往还需要参考 **PHASES**、**ELAPSS** 以及日本 **UCAS** 等研究所揭示的自然病程与风险规律^[3-6]。因此，如果仅依靠分割掩膜而缺少风险预测，实际上较难直接支撑完整的临床规划任务。

近年来，以多层神经网络为主的深度学习在医学影像分割任务中取得了显著进展。全卷积网络以及 **U-Net** 族结构能够输出像素级病灶概率图，极大程度上缩短临床医师的标注辅助时间^[7,8]；三维卷积网络可直接建模沿血管走向的上下文信息，同时有利于识别瘤体在层间连续性等形态学特征^[9,10]。**Attention U-Net** 在解码路径中加入注意力门控单元，使网络更关注与任务相关的空间区域，从而提升模型表现，且已在腹部脏器、胰腺等分割任务中得到验证^[11]。**nnU-Net** 的成功进一步说明，在医学分割任务中，除网络骨架外，数据预处理、补丁采样以及后处理同样会对性能产生重要影响^[12]。在脑血管领域，已有工作尝试把粗定位与细分割结合起来使用，或借助多尺度三维卷积来提升细小病灶检出率^[1,2,13]。与此同时，运用动脉瘤临床信息以及动脉瘤本体属性来预测风险的网络也开始出现，这提示出“影像 + 临床”联合建模的重要性^[14,15]。在表格数据学习领域，**TabTransformer** 与 **FT-Transformer** 等模型证明了注意力机制不仅适用于视觉特征建模，同时也适用于多维临床字段之间的交互建模，这为本项目风险预测模块的设计提供了参考^[16,17]。

在这一背景下，本文依托课程设计任务，围绕“动脉瘤的自动分割定位”以及“破裂风险的概率预测”两个相互衔接的子问题，完成一套以配置文件驱动、脚本

可复现为特征的软件系统。该系统一方面可以减轻医师在体数据层面的重复勾画负担，另一方面也为后续把影像组学特征或形态学参数与表型数据进行融合提供工程接口，具有较明确的辅助诊疗价值，并为医学影像与临床信息结合的医学软件系统提供完整解决方案。

1.2 国内外研究现状

1.2.1 动脉瘤与脑血管影像分析的传统途径

在深度学习普及之前，血管分割以及病灶提取主要还是依靠传统图像处理手段，比如基于强度的阈值分割、区域生长、水平集方法，或者部分基于几何先验的滤波器。此类流程往往需要人工去调节种子点、平滑核大小或曲率约束参数，并且对低对比度瘤颈、邻近骨质高密度灶等干扰较为敏感，在面对不同数据集时常常需要重新调参。面向风险评估，临床诊断多采用 Hunt-Hess 分级、WFNS 评分、PHASES 评分或 ELAPSS 评分等规则体系，其中 PHASES 更侧重未破裂动脉瘤未来破裂风险，ELAPSS 更强调肿瘤增长风险预测^[3,4]。这些评分简洁且具有可解释性，便于临床沟通，但对瘤体形态不规则、局部血管形态变化以及影像纹理等非线性特征的捕捉与运用能力较为有限。统计学习阶段则常选用逻辑回归、随机森林等传统机器学习模型；它们在变量个数较少、线性可分性较强的回顾性队列上可以给出可解释结果，但对多维关联特征的自动建模能力仍然有限。

1.2.2 基于深度学习的分割与多模态预测

随着公开数据集以及算力条件的改善，U-Net 及其三维变体逐渐成为血管与病灶分割的主流骨架^[7,9]。nnU-Net 等工作进一步强调预处理、网络拓扑以及后处理的自动化配置，从而提升跨任务迁移效率^[12]。针对颅内动脉瘤，研究者探索了从血管分割到瘤体检测的多阶段流程，或引入注意力以及多尺度模块来强调细小结构^[1,2]。在预测层面，Transformer 与注意力机制为序列化或多模态特征融合提供了较标准的实现方式^[18]；StrokeNet 等多任务结构尝试同时编码影像以及临床信息，以预测卒中结局^[14]。这些工作表明，分割精度与下游临床推理并不是割裂的——高质量掩膜既可以直接服务于手术规划，同时也可以作为形态学等衍生特征的载体。

1.3 本文面临的问题与主要思路

综合文献以及工程经验，本文把任务难点概括为三点。（1）**体数据占用与显存矛盾**：完整 CTA 体积可达数百兆字节以上，如果一次性加载多病例批次，普通 GPU 往往难以承受；因此需要在“流式 IO—补丁采样—梯度更新”之间取得平衡。（2）

前景极度稀疏：动脉瘤体素在整幅体积中的占比极低，单纯交叉熵容易使模型偏向预测背景；因此需要区域重叠型损失以及采样策略共同进行约束。（3）**风险标签与特征异质性：**破裂与未破裂病例分布不均衡，类别字段存在长尾取值；因此需要合理的加权损失、阈值搜索以及特征筛选，避免模型仅学习到训练集分布而导致过拟合。

针对上述难点，本文采用“分割骨干+表格风险头”的系统级方案：分割侧选用三维 Attention U-Net，并且配合病例级流式训练与前景优先补丁采样；风险侧使用基于交叉注意力的表格模型，统一处理数值以及类别特征，并在验证集上搜索决策阈值。

1.4 课题来源与研究内容

本课题来源于指导教师下达的毕业设计任务书，目标是对颅内动脉瘤 CTA 数据开展计算机辅助检测，并在临床表型与影像衍生特征基础上完成破裂风险的二分类预测。本文工作具体包括：

1. 基于 AttentionUnet 实现三维分割网络，完成编码器—解码器通道配置、注意力门控以及 sigmoid 输出的端到端前向传播；
2. 在 MedicalPatchDataset 上实现多目录数据扫描、重采样、标准化以及前景优先/顺序采样策略，支撑低显存条件下的长时间训练；
3. 基于 Dice/Tversky/Focal 与 BCE 的组合损失、Adam/AdamW/SGD 以及余弦退火等配置化优化流程，训练过程写入 TensorBoard，并按间隔保存最新模型与验证集最优模型；
4. 推理阶段把补丁结果拼接为完整体积，恢复 spacing、origin、direction，输出概率体与二值掩膜，供可视化或形态学特征提取使用；
5. 构建表格风险数据的清洗、互信息特征筛选、加权 BCE 训练、验证集 F1 最优阈值搜索以及测试集报告导出流程；
6. 提供 FastAPI 交互界面，用于文件上传、分割以及风险预测流程。

1.5 论文结构安排

全文共分五章。第一章介绍研究背景、国内外现状、问题难点以及研究内容。第二章梳理医学图像分割、三维卷积网络、注意力机制、类别不平衡学习以及表格建模等相关理论基础。第三章从系统架构出发，分别说明分割模块、风险模块的模

型设计与实现要点，并简要介绍 Web 服务接口。第四章介绍实验环境、数据集与预处理约定、评价指标以及结果分析框架，说明如何依据日志与配置文件复现指标。第五章总结全文，并展望未来改进方向。

1.6 本章小结

本章从临床需求以及技术趋势两个方面阐述了颅内动脉瘤辅助分析的研究动机，综述了传统方法与深度学习方法的优劣，归纳出本文面向的三个核心难点及对应思路，并列出了与源代码模块相对应的研究内容。后续章节将进一步展开算法与系统实现细节。

2 相关理论基础

2.1 脑动脉瘤及分割基本原理

脑动脉瘤是指脑血管壁局部异常膨出所形成的囊状或梭形结构，最常发生于脑底部的 Willis 环及其主要分支。在 CTA 图像中，脑动脉瘤的主要表现为血管壁的局部囊状突出，呈现为“气球样”或“浆果样”的异常膨出结构。

其中，瘤颈（neck）是指动脉瘤与载瘤动脉之间的连接部位，其宽度和形态对临床诊断具有重要意义。



图 2.1 实际脑动脉瘤 CTA 影像示例

如图所示，红色箭头指示区域中，上方血管轮廓相对正常，而下方箭头所指位置可见血管突然异常膨大，呈现典型的脑动脉瘤病灶特征。

2.2 医学图像分割基本理论

医学图像分割旨在像素或体素层面实现对目标解剖结构的精确定位，本质上属于密集预测（dense prediction）任务。与自然图像分割不同，CTA 体数据具有三维空间连续性、前景占比极低以及病灶形态变异大等特点。因此，模型不仅需要捕捉局部边缘与纹理信息，还必须维持跨层面的空间一致性。该研究范式已在医学影像深度学习综述中得到明确论证^[19-21]。

从数学形式上看，三维医学图像分割可表示为对每个体素位置 $u \in \Omega$ 的类别估计问题，其中 Ω 表示体数据的空间定义域。模型需要学习条件概率 $p(y_u = 1 | X)$ ，并据此生成概率图 $P = \{p_u\}_{u \in \Omega}$ 。当给定阈值 τ 时，二值分割结果可由 $\hat{y}_u = \mathbb{I}(p_u \geq \tau)$

得到。在此过程中，分割模型既需要输出具有空间连续性的概率分布，又要在局部边界处保持足够的敏感性，以便后续的风险预测模型准确捕捉病灶形态细节。

对于颅内动脉瘤分割任务而言，精确的分割结果既能为临床提供直观的可视化依据，也可进一步计算瘤体体积、最大径、形态不规则度等量化指标，成为后续破裂风险评估的重要基础。

在经典监督学习框架下，训练样本由输入图像 X 和金标准标签 Y 构成，模型的目标是学习从 X 到 Y 的映射函数 $f_{\theta}(X)$ 。由于医学图像标注成本高、类别分布极度不平衡以及成像条件复杂，实际训练中需在网络结构、损失函数和采样策略上进行权衡，以平衡模型的表达能力和训练稳定性。

2.3 卷积神经网络与 U-Net 结构

卷积神经网络（CNN）通过局部感受野获取到对层次化特征的高效利用，因此在医学图像分析中得到广泛应用。对于分割任务，Fully Convolutional Network（FCN）首次将分类网络扩展至像素级预测，实现端到端的密集输出^[8]。U-Net 则在此基础上引入对称的编码器—解码器结构和跳跃连接（skip connection），有效融合浅层细节信息与深层语义信息，显著提升了医学图像分割性能^[7]。

鉴于三维医学图像在层间具有较强的连续性，3D U-Net 将二维卷积替换为三维卷积和三维上采样，从而能同时捕捉切片内部和切片之间的空间上下文信息^[9,22]。在后续出现的 V-Net、UNet++ 与 nnU-Net 在体素级残差建模、跳跃连接设计以及自动化配置等方面做了改进，进一步提升了医学图像分割的性能^[10,12,23]。不过，三维卷积同时也带来了更高的计算和显存开销，因此实际应用中常采用补丁训练（patch-based training）、流式加载及混合精度训练方法缓解此问题。

2.4 注意力机制与 Attention U-Net

注意力机制的核心在于使模型能够自适应地聚焦于与当前任务最相关的特征区域。对于体积小、背景血管复杂的颅内动脉瘤分割任务，若直接拼接所有跳跃连接特征，易将大量无关背景响应传递至解码器，增加误分割风险。Attention U-Net 在跳跃连接处引入注意力门控（Attention Gate）模块，对编码器特征进行筛选，使解码器更关注目标相关区域^[11]。

从实现机制来看，注意力门控将解码器特征与同尺度编码器特征进行融合映射，生成一张空间权重图，再使用生成的权重图对编码器特征进行加权。本质上它完成了空间特征筛选的作用：当某位置更可能属于动脉瘤或邻近血管时，权重被提升；反之则被抑制。通过这种方式，模型在减少背景干扰的同时，较好地保留了 U-Net 对局部边界细节的敏感性。

2.5 类别不平衡与损失函数设计

颅内动脉瘤在 CTA 体数据中通常仅占极小比例（往往不足 0.1%），且其分布不均匀。若仅采用标准交叉熵损失，模型容易陷入“全部预测为背景”的平凡解，导致整体准确率虚高而病灶检出能力不足。因此，需要引入侧重前景区域重叠的损失函数。

在损失函数设计上，常见做法是在二元交叉熵（BCE）的基础上引入区域重叠型损失或难分割病例挖掘型损失^[24-26]。其中，Tversky 损失是 Dice 损失在假阳性与假阴性惩罚权重上的推广，在训练过程中，Tversky 损失往往比 Dice 损失更敏感，更关注于分割结果中的边界，其定义如下：

$$\mathcal{L}_{\text{Tversky}} = 1 - \frac{TP + \epsilon}{TP + \alpha FP + \beta FN + \epsilon}, \quad (2.1)$$

其中 TP 、 FP 、 FN 分别表示软预测意义下的真阳性、假阳性和假阴性， α 与 β 控制两类错误的相对权重， ϵ 为平滑系数。当任务更关注降低漏检时，可适当提高假阴性项的惩罚权重；当任务更关注减少误检时，则可提高假阳性项的惩罚权重。Focal 损失则通过降低易分类样本的损失贡献，使优化过程更加关注难分类体素。上述损失函数从不同角度缓解前景稀疏问题，为后续分割模型的训练目标设计提供了理论依据。

对于后续的动脉瘤破裂风险预测任务，由于正负样本同样存在不平衡，通常需采用正类加权或基于验证集的阈值优化策略，以提升模型对少数类（破裂组）的敏感性。

2.6 表格数据学习与特征表示理论

除了影像数据外，临床信息、人口统计学特征和既往病史等通常以结构化表格的形式存储。传统机器学习方法（如逻辑回归、随机森林）在特征维度较低时表现不错，但面对高维混合特征（数值型 + 类别型）以及复杂的非线性交互时，表达能力会明显受限。

近年来，深度表格学习借鉴 NLP 中的 Token 化思想，将每个特征字段映射为统一维度的隐向量，再通过注意力机制捕捉字段间的交互关系。其中，TabTransformer 利用上下文文化嵌入增强了类别变量表达能力，FT-Transformer 则进一步验证了对数值字段进行 token 化并使用 Transformer 编码的有效性^[16,17]。这类方法无需人工构造高阶交叉特征，且能统一处理连续与离散变量，为多模态融合提供了灵活高效的方案。

本文的风险预测模块即基于这一思路构建；同时，我也保留了随机森林和梯度提升树等传统集成学习方法作为小样本表格数据上的重要对比基线^[27-29]。

2.7 临床风险评分与深度模型的互补关系

未破裂颅内动脉瘤的管理并非单纯的图像分割问题。PHASES 评分综合人群来源、高血压、年龄、动脉瘤大小、既往蛛网膜下腔出血史和部位等因素，用于估计未来破裂风险^[3]；ELAPSS 评分则将年龄、部位、大小、形态和既往蛛网膜下腔出血等因素纳入未破裂动脉瘤增长风险预测^[4]。此外，大规模自然病程队列研究也提示，不同部位、不同直径和形态不规则程度的动脉瘤具有不同的破裂倾向^[5,6]。

上述评分体系具有解释性强、使用门槛低的优点，但其变量项相对固定，难以充分吸收三维分割衍生出的体积、表面不规则度、瘤颈宽度、影像组学纹理等高维信息。深度学习模型则可在数据充分且划分严格的前提下学习非线性交互。因此，将注意力表示学习与传统机器学习方法进行比较或融合，有助于同时考察非线性表征能力与小样本稳健性，并为风险预测提供更全面的方法学参照。

2.8 评价指标基础

分割任务常用 Dice 系数、敏感度（Sensitivity）、特异度（Specificity）、Hausdorff 距离等指标，其中 Dice 系数重点衡量预测区域与真实区域的重叠程度。分类与风险预测任务则常用准确率、精确率、召回率、F1 值以及 AUC-ROC 等指标。AUC 反映模型整体排序能力，F1 值则在不平衡场景下更能综合体现精确率与召回率的平衡。鉴于医学管理系统中，对病灶的漏诊远远严重于误诊，因此，本文选择使用召回率来进行模型的首要评判标准，兼用 AUC 进行模型性能评估。

针对极度稀疏的医学分割任务，单纯依赖总体准确率易产生误导。因此，在实验代码中同时报告 Dice 系数、体素级 F1、多阈值统计结果及基于直方图近似的 voxel-wise AUC，以实现模型性能的全面评估；同时在这种不平衡二分类场景中 PR 曲线与校准分析同样具有重要参考价值^[30-33]。

2.9 本章小结

本章系统概述了本文研究所需的核心理论基础，包括脑动脉瘤的影像学表现、三维医学图像分割基本问题、U-Net 及其注意力变体、类别不平衡下的损失函数设计、表格数据深度表征方法，以及相关评价指标体系。这些理论为后续章节的模型设计、优化策略与实验分析提供了坚实的理论支撑。

3 模型设计

3.1 研究方法总体框架

本文面向颅内动脉瘤智能分析任务，构建了由病灶分割与破裂风险评估组成的两阶段研究框架。该框架遵循“病灶定位—特征生成—风险判别”的基本逻辑：首先利用三维分割网络对 CTA 体数据中的疑似动脉瘤区域进行体素级识别，获得病灶概率分布与空间掩膜；随后基于分割结果与病例层面的临床、形态及影像表型信息构建统一的特征表示，并输入风险预测模型完成患者级破裂概率估计。该流程兼顾了医学影像任务中病灶分割与辅助临床决策的双重需求。

从形式化角度看，设单例 CTA 体数据记为 $X \in \mathbb{R}^{D \times H \times W}$ ，其对应分割标注为 $Y^{(s)} \in \{0,1\}^{D \times H \times W}$ ，病例级风险标签为 $y^{(r)} \in \{0,1\}$ 。本文方法可形式化表示为

$$P = f_{\theta}(X), \quad (3.1)$$

$$\hat{M} = \mathcal{T}(P; \tau_s), \quad (3.2)$$

$$z = \phi(X, \hat{M}, c), \quad (3.3)$$

$$\hat{p} = g_{\omega}(z), \quad (3.4)$$

其中， $f_{\theta}(\cdot)$ 表示分割网络， $P \in [0,1]^{D \times H \times W}$ 为体素级概率图， $\mathcal{T}(\cdot)$ 为基于阈值 τ_s 的二值化映射， c 表示病例层面的临床及影像表型变量， $\phi(\cdot)$ 表示多源特征构造过程， $g_{\omega}(\cdot)$ 为风险预测模型， $\hat{p} \in [0,1]$ 为动脉瘤破裂概率估计。由此，本文实际上将像素级结构识别与样本级风险判别纳入统一分析链条，在保证解剖定位能力的同时增强风险建模的结构依据。

从任务之间的关联看，分割模块与风险预测模块并非相互独立的两个流程，而是具有明确的信息传递关系。分割模块输出的掩膜可继续用于风险模型的特征生成部分，使风险模型得到有效数据来预案，而非整幅影像中的无关背景，同时也能实现有模型解耦。若将病例级风险判别写作条件概率建模问题，则可进一步表示为

$$\hat{p} = \Pr(y^{(r)} = 1 | X, \hat{M}, c), \quad (3.5)$$

其中 $\hat{M}$ 提供病灶位置和形态先验， c 提供病例层面的临床与表型信息。在风险预测流程中，风险预测并非仅依赖原始影像或单一临床变量，而是建立在影像结构信息与病例属性共同约束之上。

在整体设计上，本文遵循三个原则。第一，分割阶段应优先保证对小体积病灶的敏感性，以降低漏检对后续分析造成的影响；第二，特征表示阶段应尽量保持不同来源变量的统一表达，使连续变量、离散变量和分割衍生变量能够在同一隐空

间内比较和交互；第三，风险判别阶段应避免仅依赖线性叠加，而应建模变量之间的条件依赖关系。上述原则共同构成本文方法设计的总体依据。

进一步地，本文将两阶段任务理解为具有条件依赖关系的分层建模问题。分割阶段提供对潜在病灶区域的空间估计，风险预测阶段则在该空间估计的约束下完成病例级判别。若以 M 表示真实但不可直接观测的病灶结构变量，则风险预测可视为对如下后验概率的近似：

$$\Pr(y^{(r)} = 1 | X, c) = \int \Pr(y^{(r)} = 1 | M, c) \Pr(M | X) dM. \quad (3.6)$$

由于真实结构变量 M 只能通过人工标注或模型估计获得，本文采用分割网络输出的概率图 P 与二值掩膜 $\hat{M}$ 作为其可计算近似。该表达说明，分割模块的意义不仅在于获得可视化结果，还在于为下游风险建模提供对病灶空间位置和形态属性的结构性约束。

为降低不同任务目标之间的混淆，本文未将分割标签与风险标签直接合并为单一目标，而是采用阶段化训练与统一评估的方式。该策略能够分别考察体素级结构识别能力和病例级风险判别能力，使各模块的误差来源更容易被分析。同时，分割输出所形成的形态特征和空间先验又可进入风险模型，从而保持两类任务之间的信息关联。

3.2 分割任务的理论基础与建模动机

颅内动脉瘤在 CTA 图像中通常表现为体积小、边界复杂且与邻近血管相互黏连的异常膨出区域，这使得分割任务面临明显的小目标、强背景干扰和类别不平衡等问题。

在这种情况下，单纯依靠局部卷积感受野容易出现两方面不足：浅层特征虽能保留较多空间细节，但语义判别能力较弱；而深层特征虽有较强的抽象表达能力，但经过多次下采样后，病灶的边界细节又容易丢失。U-Net 类编码器-解码器结构通过跳跃连接较好地平衡了这两类矛盾，因此成为三维医学图像分割的常用基础框架。

然而，标准 U-Net 在面对复杂血管背景时，仍会引入较多与病灶无关的高响应区域。有鉴于此，本文在网络主干中加入了注意力门控机制，用于抑制无关背景特征通过跳跃连接的传播；同时在瓶颈层引入多尺度上下文增强模块和方向敏感注意力，以更好地捕捉病灶的尺度变化、形态不规则性以及复杂的空间走向。这种设计的核心考虑在于：病灶分割不能仅依赖局部灰度差异，而是需要综合局部边界、邻域血管拓扑关系以及多尺度上下文信息进行联合判断。

3.3 动脉瘤分割模块设计

3.3.1 输入表示与数据采样机制

由于 CTA 体数据具有高维、稀疏和病例间差异较大的特点，本文首先对输入体数据进行统一空间归一化与强度规范化，以减弱扫描条件、体素间距与成像范围差异对模型学习带来的干扰。对于归一化后的三维影像，训练阶段采用基于局部补丁的学习方式，以在有限显存约束下维持足够的空间上下文范围；验证与测试阶段则通过覆盖式滑窗实现覆盖整个数据的推理，保证输出结果的完整性与连续性，减小 patch 边缘的影响。

动脉瘤区域在整个 CTA 体积数据中通常只占很小的比例。如果采用完全均匀的采样策略，训练过程中模型容易被大量背景区域主导，导致对前景病灶的召回率不足。为此，本文采用了一种兼顾前景强化与背景约束的补丁采样机制：在构造训练样本时，适当提高病灶及其邻域补丁的出现概率，以增强网络对少数类（病灶）的感知能力；同时保留一定比例的背景补丁，帮助模型维持对正常解剖结构的判别边界。该策略本质上是一种面向类别不平衡场景的数据分布重加权方法，能够有效提升模型对小体积病灶的学习效率。设从整例体数据中抽取补丁 x_p 的采样分布为 $\pi(x_p)$ ，则经验风险表示为

$$\hat{R}(\theta) = \frac{1}{B} \sum_{b=1}^B \mathcal{L}(f_{\theta}(x_{p_b}), y_{p_b}), \quad x_{p_b} \sim \pi(x_p), \quad (3.7)$$

其中 B 为批量大小。当前景邻域补丁的采样概率被适度提高时，训练过程中的梯度估计将包含更多与病灶相关的局部模式，从而缓解由背景样本占比过高导致的优化偏置。与此同时，保留背景补丁可避免模型仅学习前景邻域的局部统计特征，进而维持对正常血管和非目标组织的辨别能力。

在补丁学习框架下，局部样本的空间覆盖范围也会影响模型可获得的上下文信息。若补丁尺寸过小，模型虽然能够获得更多前景样本，但可能无法完整观察动脉瘤与载瘤血管之间的空间关系；若补丁尺寸过大，则单批次中前景体素占比进一步降低，且训练计算负担增加。因此，补丁采样需要在局部细节、上下文范围与类别平衡之间取得折中。该折中可理解为对训练分布 $\pi(x_p)$ 的约束优化：

$$\pi^* = \arg \min_{\pi} |\mathbb{E}_{x_p \sim \pi}[r(x_p)] - r_0| + \lambda_c \mathcal{C}(x_p), \quad (3.8)$$

其中 $r(x_p)$ 表示补丁中的前景比例， r_0 表示期望的前景可见程度， $\mathcal{C}(x_p)$ 表示上下文不足或计算代价带来的约束项， λ_c 为权衡系数。该表达并非要求严格求解采样分布，而是说明补丁构造应兼顾病灶可见性与上下文完整性。

3.3.2 三维 Attention U-Net 主干结构

分割主干采用三维 Attention U-Net。编码器由多层三维卷积块和逐级下采样操作构成，用于提取从低层纹理到高层语义的分层特征；解码器则通过上采样和特征

融合逐步恢复空间分辨率，实现精细的体素级预测。设第 l 层编码器特征为 E_l ，解码器特征为 D_l ，则主干网络可抽象为下式：

$$E_l = \mathcal{E}_l(E_{l-1}), \quad l = 1, 2, \dots, L, \quad (3.9)$$

$$B = \mathcal{B}(E_L), \quad (3.10)$$

$$D_l = \mathcal{D}_l(D_{l+1}, \tilde{E}_l), \quad l = L-1, \dots, 1, \quad (3.11)$$

其中， $\mathcal{E}_l(\cdot)$ 表示第 l 层编码映射， $\mathcal{B}(\cdot)$ 表示瓶颈层特征变换， $\mathcal{D}_l(\cdot)$ 表示第 l 层解码映射， $\tilde{E}_l$ 为经注意力筛选后的跳跃连接特征。通过这种由粗到细的层级重建过程，网络能够同时利用深层全局语义信息与浅层边界细节信息，从而提高病灶轮廓恢复能力。

从特征尺度角度看，编码器逐级压缩空间分辨率并扩大有效感受野，使高层特征能够表达病灶与邻近血管之间的上下文关系；解码器则逐级恢复分辨率，使预测结果重新对齐至原始体素网格。若记第 l 层特征的空间尺度为 (D_l, H_l, W_l) 、通道数为 C_l ，则 $E_l \in \mathbb{R}^{C_l \times D_l \times H_l \times W_l}$ 。随着层级加深， (D_l, H_l, W_l) 逐渐减小而 C_l 通常增加，模型由此在空间精度与语义抽象之间形成层次化表示。跳跃连接的作用在于将浅层空间细节重新注入解码路径，避免小病灶在连续下采样过程中被过度平滑。

更具体地，三维卷积块可被视为在局部邻域内对体素上下文进行加权聚合。设输入特征为 $U \in \mathbb{R}^{C_{in} \times D \times H \times W}$ ，卷积核为 $K \in \mathbb{R}^{C_{out} \times C_{in} \times r_d \times r_h \times r_w}$ ，则输出特征在位置 (i, j, k) 的第 c 个通道可写为

$$V_{c,i,j,k} = \sigma \left(\sum_{c'=1}^{C_{in}} \sum_{a,b,m} K_{c,c',a,b,m} U_{c',i+a,j+b,k+m} + b_c \right), \quad (3.12)$$

其中 $\sigma(\cdot)$ 表示非线性激活函数。该形式说明，网络通过层层局部聚合逐步扩大感受野，并在通道维度上形成多级语义表示。对于动脉瘤这类小目标结构，浅层卷积更关注边缘和局部灰度变化，深层卷积则更关注病灶与周围血管之间的空间关系，二者通过跳跃连接实现互补。

此外，编码器与解码器之间的特征融合并非简单的尺度恢复过程，而是一个语义信息与定位信息重新对齐的过程。若将上采样后的解码特征记为 U_l ，跳跃连接特征记为 $\tilde{E}_l$ ，则融合操作概括为

$$D_l = \rho_l \left(\text{Concat}(U_l, \tilde{E}_l) \right), \quad (3.13)$$

其中 $\rho_l(\cdot)$ 表示卷积融合映射。该操作使网络能够利用深层语义判断目标类别，同时利用浅层细节修正边界位置，从而提升小体积分割目标的空间一致性。




图 3.2 三维 Attention U-Net 分割模型结构

3.3.3 注意力门控跳跃连接机制

在传统 U-Net 中，编码器特征通常直接与对应尺度的解码器特征拼接。这种做法虽然有助于恢复空间分辨率，但也可能将大量背景响应一并引入解码过程，尤其是在血管、骨性结构及噪声干扰较强的 CTA 场景下更为明显。为缓解这一问题，本文在跳跃连接中采用注意力门控机制，使网络能够依据当前解码语义状态自适应选择更具判别力的编码特征。

设同尺度跳跃特征为 s ，来自解码端的门控信号为 g ，则注意力门控为

$$q = \text{ReLU}(W_s s + W_g g + b), \quad (3.14)$$

$$a = \sigma(\psi(q)), \quad (3.15)$$

$$\hat{s} = a \odot s, \quad (3.16)$$

其中， W_s 与 W_g 为线性投影， $\psi(\cdot)$ 为通道压缩映射， $\sigma(\cdot)$ 为 Sigmoid 函数， a 为取值于 $[0, 1]$ 的注意力权重图， $\odot$ 表示逐元素乘法。该结构的本质是在跳跃连接处引入条件选择机制：当某些空间位置与当前解码语义更加一致时，对应权重被放大；反之，则被抑制。由此可降低无关背景特征对后续重建的干扰，提高分割结果的病灶聚焦能力。

3.3.4 ASPP 多尺度上下文增强模块

动脉瘤的空间形态在不同病例之间可能表现出明显差异，既包括局部球囊样膨出，也包括与载瘤血管边界过渡不清的复杂结构。因此，仅依赖固定尺度卷积核难以充分描述病灶及其邻近血管的多尺度上下文关系。为增强瓶颈层对不同尺度

模式的响应能力，本文引入三维 ASPP 模块，通过多分支空洞卷积并行提取不同感受野下的上下文特征。

设瓶颈输入特征为 X_b ，空洞率集合为 $\{d_1, d_2, \dots, d_K\}$ ，则 ASPP 输出可表示为

$$Y_{ASPP} = \phi \left(\text{Concat} [\mathcal{F}_{d_1}(X_b), \mathcal{F}_{d_2}(X_b), \dots, \mathcal{F}_{d_K}(X_b)] \right), \quad (3.17)$$

其中， $\mathcal{F}_{d_k}(\cdot)$ 表示膨胀率为 d_k 的三维空洞卷积分支， $\text{Concat}[\cdot]$ 表示通道维拼接， $\phi(\cdot)$ 表示后续的线性融合与非线性映射。通过在同一层级聚合不同感受野的信息，模型能够更有效地刻画病灶本体、载瘤血管及局部背景之间的关系，从而增强对复杂形态病灶的识别鲁棒性。

3.3.5 三维坐标注意力模块

在多尺度上下文建模基础上，本文进一步引入三维坐标注意力模块，以增强网络对方向性位置信息的编码能力。与仅基于通道重加权的注意力形式不同，坐标注意力通过沿不同空间轴汇聚上下文信息，在保留位置依赖关系的同时生成方向敏感权重，因此更适合捕捉血管结构细长、走向复杂的空间特征。

设输入特征为 $X \in \mathbb{R}^{C \times D \times H \times W}$ ，则沿深度、高度与宽度方向的上下文聚合可分别表示为

$$Z_d = \text{AvgPool}_{H,W}(X), \quad Z_h = \text{AvgPool}_{D,W}(X), \quad Z_w = \text{AvgPool}_{D,H}(X). \quad (3.18)$$

三路聚合特征经共享映射与分支解码后得到三个方向注意力图 A_d 、 A_h 与 A_w ，最终输出为

$$Y_{CA} = X \odot A_d \odot A_h \odot A_w. \quad (3.19)$$

该模块通过显式建模空间方向依赖关系，使网络能够在保留通道语义的同时强化对关键位置的响应，有利于提升小病灶边界及空间走向敏感结构的识别精度。

3.3.6 输出映射与整例重建

在解码器末端，网络通过 $1 \times 1 \times 1$ 卷积将高分辨率特征映射到单通道对数几率空间，并经 Sigmoid 函数获得体素级前景概率图：

$$P_{i,j,k} = \sigma(h_{i,j,k}), \quad (3.20)$$

其中， $h_{i,j,k}$ 表示位置 (i, j, k) 处的输出 logit， $P_{i,j,k}$ 表示对应体素属于动脉瘤前景的概率。基于给定阈值 τ_s ，可得到二值掩膜

$$\hat{M}_{i,j,k} = \mathbb{I}(P_{i,j,k} \geq \tau_s), \quad (3.21)$$




图 3.3 融合 ASPP 与三维坐标注意力的增强分割模型结构

其中， $\mathbb{I}(\cdot)$ 为示性函数。

在整例推理阶段，由于输入体积较大，本文采用滑窗方式对局部补丁逐块预测，并将各窗口输出重新映射回原空间。对于重叠区域，可通过平均融合或中心区域优先策略进行整合，以减弱窗口边界效应。由此获得的整例概率图与二值分割结果，不仅可用于病灶可视化，也可进一步提取体积、尺寸及形态相关表型，为风险预测阶段提供结构性输入依据。

基于二值掩膜可计算一组具有解剖含义的形态特征。设单个体素的物理体积为 v_{voxel} ，预测前景体素集合为 $\Omega_{\hat{M}}$ ，则病灶体积表示为

$$V_{\text{lesion}} = v_{\text{voxel}} \sum_{(i,j,k)} \hat{M}_{i,j,k}. \quad (3.22)$$

若进一步估计病灶表面积 S_{lesion} ，则可构造球形度等形态描述量，例如

$$\text{Sphericity} = \frac{\pi^{1/3} (6V_{\text{lesion}})^{2/3}}{S_{\text{lesion}}}. \quad (3.23)$$

该类特征能够从几何角度描述动脉瘤大小、外形规则性和局部结构复杂程度，为后续病例级风险建模提供可解释的结构化输入。

3.3.7 分割损失函数与优化目标

考虑到动脉瘤分割具有显著的前景稀疏特征，单独使用逐体素交叉熵损失容易使模型偏向背景预测，导致小病灶召回不足。为兼顾像素级分类准确性与病灶

的准确分割，本文采用由二元交叉熵损失与重叠敏感损失（tversky）组成的联合损失函数以获取更优秀的模型。

二元交叉熵损失定义为

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{n=1}^N [y_n \log p_n + (1 - y_n) \log(1 - p_n)], \quad (3.24)$$

其中， N 为体素总数， $y_n \in \{0, 1\}$ 为第 n 个体素的真实标签， $p_n \in [0, 1]$ 为对应预测概率。为进一步提高模型对前景区域及漏检错误的敏感性，本文引入 Tversky 型损失。设真阳性、假阳性和假阴性分别记为 TP、FP 和 FN，则 Tversky 系数可写为

$$\text{TI} = \frac{\text{TP}}{\text{TP} + \alpha \text{FP} + \beta \text{FN} + \varepsilon}, \quad (3.25)$$

其中， α 与 β 用于平衡假阳性与假阴性的惩罚权重， ε 为避免分母为零的平滑项。对应损失可定义为

$$\mathcal{L}_{\text{T}} = 1 - \text{TI}. \quad (3.26)$$

因此，分割阶段总体优化目标写为

$$\mathcal{L}_{\text{seg}} = \lambda_1 \mathcal{L}_{\text{BCE}} + \lambda_2 \mathcal{L}_{\text{T}}, \quad (3.27)$$

其中， λ_1 与 λ_2 为权重系数。该联合目标在理论上同时约束局部判别误差与病灶的错误分割，适合小目标医学图像分割场景。

进一步地，Tversky 损失中的权重设置可被理解为对错误类型的任务偏好建模。对于医学筛查和辅助诊断任务，漏检前景通常比少量误检具有更高代价，因此可通过提高 β 的方式增加假阴性项在损失中的影响。若将软预测形式下的三类统计量写为

$$\text{TP} = \sum_{n=1}^N p_n y_n, \quad (3.28)$$

$$\text{FP} = \sum_{n=1}^N p_n (1 - y_n), \quad (3.29)$$

$$\text{FN} = \sum_{n=1}^N (1 - p_n) y_n, \quad (3.30)$$

则损失函数能够直接对前景区域的重叠关系进行优化，而非仅依赖逐体素独立分类误差。与 BCE 损失相比，重叠型损失对前景体素的整体连通性和区域一致性更敏感；与单独使用 Dice 或 Tversky 损失相比，引入 BCE 项又能够提高概率输出的数值稳定性。因此，联合损失在本任务中具有更合理的优化性质。

在优化过程中，模型参数通过基于梯度下降的自适应优化算法进行更新。设第 t 次迭代的参数为 θ_t ，学习率为 η_t ，则其更新形式可概括为

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \mathcal{L}_{\text{seg}}(\theta_t). \quad (3.31)$$

由于三维医学图像分割的梯度估计受到补丁采样、前景稀疏和病例差异的共同影响，训练过程中需要结合验证集性能对模型进行选择，从而在拟合能力与泛化能力之间取得平衡。若记验证集指标为 $S_{val}(\theta)$ ，则模型选择可概括为

$$\theta^* = \arg \max_{\theta_t} S_{val}(\theta_t), \quad (3.32)$$

其中 S_{val} 可由 Dice、Recall 或二者的综合指标确定。该策略避免仅依据训练损失下降选择模型，有助于降低过拟合对最终分割结果的影响。

3.4 破裂风险预测模块设计

3.4.1 多源特征表示与问题定义

风险预测任务关注病例级破裂状态判别，与分割任务的体素级预测不同，其核心在于从多源异构变量中学习稳定的判别表示。设单个病例的输入由数值特征集合 $x^{(n)} \in \mathbb{R}^m$ 与类别特征集合 $x^{(c)} \in \mathbb{N}^q$ 构成，其中数值特征可包括临床指标、形态学统计量及影像表型描述，类别特征则对应离散化的病例属性。本文通过统一的数据清洗、缺失值处理与标准化策略将不同来源变量映射到可学习特征空间，并将问题定义为概率形式的二分类任务：

$$\hat{p} = \Pr(y^{(r)} = 1 \mid x^{(n)}, x^{(c)}). \quad (3.33)$$

与传统基于手工规则或浅层线性模型的方法相比，本文更关注变量之间潜在的非线性交互作用。例如，某一形态学指标对风险的影响可能依赖于年龄、病灶位置或其他影像表型变量，因此简单线性叠加往往难以充分表达这类高阶关联。为此，本文采用基于 token 表示与交叉注意力机制的表格深度模型，对异构字段之间的依赖关系进行显式建模。

3.4.2 字段嵌入与统一隐空间映射

为使数值特征与类别特征能够在同一模型中进行交互，需先将其映射到维度一致的隐空间。对于第 i 个数值特征 $x_i^{(n)}$ ，本文通过可学习线性变换获得其嵌入表示：

$$e_i^{(n)} = W_i^{(n)} x_i^{(n)} + b_i^{(n)}, \quad i = 1, 2, \dots, m, \quad (3.34)$$

其中， $W_i^{(n)}$ 与 $b_i^{(n)}$ 为可学习参数。对于第 j 个类别特征 $x_j^{(c)}$ ，其嵌入表示由查表方式获得：

$$e_j^{(c)} = \text{Emb}_j(x_j^{(c)}), \quad j = 1, 2, \dots, q. \quad (3.35)$$

由此，所有字段均被表示为同维度向量，并共同组成字段级 token 序列

$$E = [e_1, e_2, \dots, e_{m+q}] \in \mathbb{R}^{(m+q) \times d}, \quad (3.36)$$

其中, d 为隐空间维度。该表示方式使模型能够将每个字段视为独立信息单元, 从而为后续的注意力交互建模提供基础。

在表格数据中, 不同字段的量纲、取值范围和语义含义差异较大, 直接拼接可能使模型偏向数值尺度较大的变量。字段嵌入的作用在于将原始变量从观测空间映射到统一语义空间, 使每个字段都以可学习 token 的形式参与交互。对于标准化后的数值变量, 线性嵌入不仅保留变量大小信息, 还通过字段特异参数刻画变量语义; 对于类别变量, 嵌入矩阵则将离散状态转化为连续向量, 使模型能够学习类别之间的潜在相似性。

若将所有字段嵌入后的表示视为随机变量集合 $\{e_i\}_{i=1}^{m+q}$, 风险模型的目标并非仅估计各字段边际贡献, 而是学习其联合条件分布下的判别函数:

$$g_{\omega}(E) \approx \Pr(y^{(r)} = 1 \mid e_1, e_2, \dots, e_{m+q}). \quad (3.37)$$

该建模方式能够表达“某一变量的风险含义依赖于其他变量取值”的条件交互关系, 更符合复杂医学风险因素共同作用的特点。

3.4.3 交叉注意力特征交互机制

本文风险模型的核心思想并非将全部字段直接拼接后输入分类器, 而是通过注意力机制自适应学习字段间的相关性权重。设输入 token 表示为 E , 经过线性映射得到查询、键和值矩阵:

$$Q = EW_Q, \quad K = EW_K, \quad V = EW_V, \quad (3.38)$$

其中, W_Q 、 W_K 与 W_V 为可学习参数。字段间的相关性通过注意力自动计算:

$$\text{Att}(Q, K, V) = \text{Softmax}\left(\frac{QK^{\top}}{\sqrt{d}}\right)V. \quad (3.39)$$

对于多头注意力机制, 可将上述过程扩展为多个子空间并行学习, 再通过拼接与线性变换进行融合, 从而提高对多类型交互关系的表达能力。

若进一步区分数值字段流与类别字段流, 则交叉注意力可以刻画一类字段对另一类字段的条件依赖。例如, 设数值字段表示为 $E^{(n)}$, 类别字段表示为 $E^{(c)}$, 则一种典型的跨模态交互形式可写为

$$\tilde{E}^{(n)} = \text{Att}(E^{(n)}W_Q^{(n)}, E^{(c)}W_K^{(c)}, E^{(c)}W_V^{(c)}), \quad (3.40)$$

其含义是使用数值字段作为查询, 以类别字段提供键和值, 从而实现基于类别上下文的数值特征捕捉。通过交替或叠加这两类交互映射, 模型得以学习异构字段之间的双向依赖关系, 从而形成更具判别力的病例级表示。

3.4.4 全局聚合与风险概率输出

在完成字段级交互后，模型需要将多 token 表示汇聚为病例级全局表征。设交互后的字段表示为 $H = [h_1, h_2, \dots, h_{m+q}]$ ，则可采用平均池化、注意力池化或引入全局 token 的方式获得聚合向量 r ：

$$r = \text{Pool}(H). \quad (3.41)$$

随后通过多层感知机完成最终判别，输出破裂风险概率：

$$\hat{p} = \sigma(W_o r + b_o). \quad (3.42)$$

当给定分类阈值 τ_r 时，可得到病例级决策结果

$$\hat{y}^{(r)} = \begin{cases} 1, & \hat{p} \geq \tau_r, \\ 0, & \hat{p} < \tau_r. \end{cases} \quad (3.43)$$

这一过程使模型能够从字段级局部交互过渡到病例级整体判断，符合临床风险评估中“多因素综合判别”的基本思想。

3.4.5 风险预测损失函数

破裂风险预测可建模为病例级二分类问题。设第 i 个病例的真实标签为 $y_i \in \{0, 1\}$ ，模型输出的破裂概率为 $\hat{p}_i \in [0, 1]$ 。本文直接采用标准二元交叉熵作为风险预测训练目标：

$$\mathcal{L}_{\text{risk}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)], \quad (3.44)$$

其中， N 为训练样本数。二元交叉熵从最大似然估计角度约束模型输出概率，使阳性病例的预测概率趋近于 1，阴性病例的预测概率趋近于 0。该目标形式简洁、稳定，适合作为风险预测模块的基础优化准则。

在训练完成后，本文不直接固定使用 0.5 作为分类阈值，而是基于验证集概率输出搜索最优阈值 τ_r^* ，使综合评价指标达到较优水平：

$$\tau_r^* = \arg \max_{\tau \in [0, 1]} \mathcal{G}(\tau), \quad (3.45)$$

其中， $\mathcal{G}(\tau)$ 可选取 F1 值、Youden 指数或其他适用于不平衡分类的综合准则。该策略有助于根据实际数据分布确定更合理的决策边界，提高风险预测的应用适配性。

除分类损失外，风险预测模型还需要关注概率输出的可解释性。理想的风险概率应在统计意义上接近真实发生概率。若模型输出在验证集中存在普遍性偏高或偏低，则即使 AUC 较高，其概率值在临床辅助解释中仍可能产生偏差。因此，阈

值选择和概率校准是风险预测模型后处理中的两个重要且互补的环节：前者用于确定二分类决策边界，后者用于提升概率值的可靠性。本文主要通过验证集上的阈值搜索来调整决策边界，同时在结果讨论部分保留了对概率校准问题的分析。

3.5 训练与优化过程

本文整体训练过程遵循监督学习范式。对于分割任务，网络通过最小化体素级联合损失学习从三维影像到病灶概率图的映射；对于风险预测任务，模型通过最小化标准二元交叉熵损失学习从病例级特征表示到破裂概率的映射。两个任务分别在训练集上进行参数更新，在验证集上完成模型选择与超参数调节，并在独立测试集上报告最终性能。

从优化角度看，训练过程本质上是在参数空间中求解经验风险最小化问题：

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(x_i, y_i; \theta), \quad (3.46)$$

其中， $\mathcal{L}(\cdot)$ 对于不同任务分别对应 $\mathcal{L}_{\text{seg}}$ 与 $\mathcal{L}_{\text{risk}}$ 。为提高训练稳定性，优化过程中结合学习率调度、验证监控及最优检查点保留策略，以降低随机波动对最终结果的影响。该过程既保证了模型能够充分拟合训练分布，又为后续实验比较提供了统一且可复核的评价基础。

在分割任务中，训练目标与评价目标之间并非完全一致。联合损失直接作用于体素概率和区域重叠，而最终评价还受到阈值化、连通性和边界偏移的影响。因此，训练过程需要同时观察损失下降趋势与验证集空间指标，避免出现损失持续降低但二值分割质量不再提升的现象。在风险预测任务中，训练损失反映概率拟合程度，而 F1、Recall 等指标还依赖分类阈值，因此验证集阈值搜索应在训练完成后独立进行，避免将测试集信息用于模型选择。

为了减少过拟合风险，训练过程还需结合正则化思想进行约束。对于深度神经网络而言，常见正则化可概括为在经验风险之外加入参数惩罚项：

$$\theta^* = \arg \min_{\theta} \left[\frac{1}{N} \sum_{i=1}^N \mathcal{L}(x_i, y_i; \theta) + \lambda \Omega(\theta) \right], \quad (3.47)$$

其中 $\Omega(\theta)$ 表示模型复杂度约束， λ 控制正则化强度。对于医学小样本任务，正则化、验证集监控与阈值独立选择共同构成防止过拟合和信息泄漏的重要机制。

3.6 本章小结

本章系统阐述了本文所采用的研究方法 with 模型设计。首先，从整体框架层面明确了“分割先验驱动风险评估”的两阶段分析思路；其次，围绕三维 Attention U-Net、注意力门控、ASPP 与三维坐标注意力等关键模块，对动脉瘤分割模型的结

构组成、输入输出关系与优化目标进行了理论化描述；再次，对风险预测模型中的字段嵌入、交叉注意力交互、全局聚合、加权损失及阈值搜索策略进行了形式化说明。总体而言，本文方法通过多尺度空间表征与多源特征融合相结合，为后续实验验证与结果分析奠定了方法学基础。

4 实验与结果分析

4.1 实验设计概述

本文实验围绕动脉瘤分割与破裂风险预测两个核心任务展开，分别从体素级病灶识别能力与病例级风险判别能力两个层面对所提出方法进行系统评价。分割实验以 CTA 三维体数据为输入，考察模型输出概率图与人工标注掩膜之间的一致程度；风险预测实验以临床信息、影像表型信息及分割衍生特征为输入，考察模型对动脉瘤破裂状态的区分能力。尽管两项任务在输入形式、输出目标与评价粒度上存在差异，但其共同服务于颅内动脉瘤智能分析这一总体目标，即在影像结构识别基础上进一步实现风险评估。

在实验组织方面，本文严格遵循训练集、验证集和测试集相互独立的基本原则。训练集用于模型参数的学习，验证集用于超参数调节、阈值确定和模型筛选，而测试集仅用于最终性能评估，从而最大限度地减少信息泄漏带来的偏差。对于分割任务，本文重点考察模型在训练后期的收敛稳定性、概率判别能力和病灶检出能力。对于风险预测任务，则主要对比深度交叉注意力模型与传统机器学习模型在多项评价指标上的表现，并进一步讨论了不同模型的判别特点与适用场景。

4.2 实验环境与基本设置

实验在通用 Linux 计算环境下完成，深度学习模型采用主流张量计算框架进行训练与推理，医学影像读写、空间重采样、数值计算与统计分析均依托成熟的科学计算工具实现。为提高实验过程的可重复性，所有实验均在统一数据划分、统一评价口径和一致训练验证流程下完成记录。本文在结果分析中重点讨论模型表现及其方法学含义，而不涉及具体工程实现细节。

在分割任务中，输入为三维 CTA 体数据。训练阶段采用局部补丁学习策略，以缓解显存限制并提高小目标病灶在训练过程中的可见性；验证阶段则采用滑窗方式进行整例推理，以保证输出结果具有空间完整性。风险预测任务中，输入为病例级表格特征，其中数值变量经标准化处理，类别变量经离散嵌入表示，模型输出为病例级破裂概率。考虑到风险预测任务中正负样本分布通常存在不均衡现象，本文在训练阶段采用类别加权策略，并在验证集上搜索最优判别阈值，以提高模型对少数类样本的识别能力。

为保证比较的公平性，所有对比模型均遵循相同的数据划分原则，测试集不参与训练、调参和阈值选择。分割实验中，模型选择主要依据验证集的重叠指标和阳性检出能力；风险预测实验中，阈值选择仅基于验证集输出概率完成，随后固定该阈值在测试集上报告性能。该设计能够减少因测试集反馈而产生的乐观偏差，使

实验结果更能反映模型在未见样本上的泛化表现。

从统计学习角度看，实验设计的关键在于使模型选择过程与最终性能评估过程相互隔离。设训练集、验证集与测试集分别记为 $\mathcal{D}_{tr}$ 、 $\mathcal{D}_{val}$ 和 $\mathcal{D}_{te}$ ，模型参数由训练集确定：

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{|\mathcal{D}_{tr}|} \sum_{(x_i, y_i) \in \mathcal{D}_{tr}} \mathcal{L}(x_i, y_i; \theta), \quad (4.1)$$

超参数与阈值由验证集确定：

$$\hat{\gamma} = \arg \max_{\gamma \in \Gamma} S_{val}(\hat{\theta}, \gamma), \quad (4.2)$$

最终性能则仅在测试集上计算：

$$S_{test} = S(\mathcal{D}_{te}; \hat{\theta}, \hat{\gamma}). \quad (4.3)$$

其中 γ 可表示分类阈值、模型结构选择或其他验证集选择变量。上述形式化描述强调，测试集不应参与任何模型选择过程，否则容易造成性能估计乐观。

此外，医学数据通常存在病例间异质性、标注不确定性和类别分布不均衡等特点，因此单一指标难以完整刻画模型行为。本文在分割任务中同时关注区域重叠、阳性检出和概率排序，在风险预测任务中同时关注总体判别、阳性识别和阈值敏感性，以减少由单一评价标准带来的解释偏差。

4.3 评价指标

4.3.1 分割任务评价指标

分割任务的评价需要同时考虑概率判别能力、区域重叠程度与阳性体素检出能力。设真实前景集合为 Y ，预测前景集合为 $\hat{Y}$ ，则 Dice 系数定义为

$$\text{Dice} = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|}. \quad (4.4)$$

Dice 系数越高，说明预测区域与真实区域的重叠程度越高。由于动脉瘤通常属于体积较小的局部结构，少量边界偏差便可能引起 Dice 的明显波动，因此该指标对分割质量具有较强敏感性。

在体素级二分类视角下，真阳性、假阳性、真阴性与假阴性分别记为 TP、FP、TN 和 FN。召回率定义为

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad (4.5)$$

用于度量真实前景体素中被正确识别的比例。对于医学筛查场景而言，召回率具有重要意义，因为漏检病灶可能直接影响后续临床判断。精确率定义为

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad (4.6)$$

用于衡量预测为前景的体素中真实属于前景的比例。进一步地，Precision 与 Recall 的调和平均可写为

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (4.7)$$

AUC 则从阈值无关角度描述模型对前景与背景体素的整体排序能力，可用于刻画概率输出的可分性。若以真阳性率 $\text{TPR}(\tau)$ 和假阳性率 $\text{FPR}(\tau)$ 分别表示阈值 τ 下的敏感度和误报率，则 ROC-AUC 可形式化表示为

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(u)) du, \quad (4.8)$$

其含义是在所有可能阈值下综合评估模型将前景体素排序在背景体素之前的能力。

对于边界敏感的分割评估，还可引入 Hausdorff 距离等轮廓指标。设预测边界点集与真实边界点集分别为 A 和 B ，则 Hausdorff 距离定义为

$$H(A, B) = \max \left\{ \sup_{a \in A} \inf_{b \in B} \|a - b\|, \sup_{b \in B} \inf_{a \in A} \|b - a\| \right\}. \quad (4.9)$$

该指标反映两个边界点集之间的最大偏离程度，适合补充评价分割轮廓的局部极端误差。考虑到小目标分割中边界少量偏差会造成较大指标波动，本文主要以 Dice、Recall、F1 与 AUC 为核心指标，并结合可视化结果讨论边界误差。

4.3.2 风险预测评价指标

风险预测属于病例级不平衡二分类问题，因此仅使用 Accuracy 难以全面反映模型性能。Accuracy 定义为

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}, \quad (4.10)$$

反映整体分类正确率，但在正负样本比例失衡时可能掩盖模型对少数类样本的识别不足。因此，本文同时报告 Precision、Recall、F1 与 AUC 等指标，以更全面地刻画模型在风险识别任务中的综合表现。

对于风险预测模型输出的概率 $\hat{p}_i$ ，其二分类结果由阈值 τ 决定：

$$\hat{y}_i = \begin{cases} 1, & \hat{p}_i \geq \tau, \\ 0, & \hat{p}_i < \tau. \end{cases} \quad (4.11)$$

本文在验证集上搜索较优阈值，并将其固定用于测试集评估。该策略能够依据数据分布与任务目标自适应调整决策边界，从而减少默认阈值对实验结论的影响。例如，当以 F1 值作为阈值选择准则时，可写为

$$\tau^* = \arg \max_{\tau \in [0, 1]} \frac{2\text{Precision}(\tau)\text{Recall}(\tau)}{\text{Precision}(\tau) + \text{Recall}(\tau)}. \quad (4.12)$$

除上述指标外，医学风险预测还需要关注概率输出的可解释性和校准性。理想情况下，当模型对一组病例给出接近 p 的风险概率时，该组病例中实际阳性比例也应接近 p 。若将样本按预测概率划分为 K 个区间 B_k ，则期望校准误差可写为

$$\text{ECE} = \sum_{k=1}^K \frac{|B_k|}{N} |\text{acc}(B_k) - \text{conf}(B_k)|, \quad (4.13)$$

其中 $\text{acc}(B_k)$ 表示第 k 个区间内的真实阳性比例， $\text{conf}(B_k)$ 表示平均预测概率。虽然本文重点报告分类判别指标，但校准分析对于后续临床使用具有重要意义，因为风险概率不仅影响二分类决策，也影响临床复核和随访优先级安排。

为便于说明各类评价指标在本文中的功能定位，表 4.1 对本章主要指标及其分析侧重点进行了归纳。

表 4.1 主要评价指标及其分析侧重点

任务类型	指标	主要反映内容
分割任务	Dice	预测区域与真实区域的重叠程度
分割任务	Recall	病灶前景体素的检出能力
分割任务	Precision	前景预测结果的可靠性
分割任务	AUC	前景与背景体素的整体可分性
风险预测任务	Accuracy	整体分类正确率
风险预测任务	Precision	高风险预测结果的准确性
风险预测任务	Recall	破裂病例的识别能力
风险预测任务	F1	Precision 与 Recall 的综合平衡
风险预测任务	AUC	破裂与未破裂病例的排序能力

4.4 动脉瘤分割实验

4.4.1 实验目的与训练过程

分割实验的主要目的是验证三维 Attention U-Net 及其改进结构对颅内动脉瘤的定位能力和轮廓恢复能力。训练时，模型通过局部补丁样本学习病灶及其邻域的空间结构；在验证和测试阶段，则对整例 CTA 体数据进行滑窗推理。由于动脉瘤在空间上极为稀疏，实验不仅关注病灶前景的召回率，还着重考虑在复杂血管背景下的误检控制。从训练过程来看，模型在后期的验证指标逐渐趋于稳定，表明网络已基本完成从低层纹理到高层病灶语义的表征学习。本文重点统计了这一阶段的验证结果，以观察收敛末期的性能表现。在此期间，AUC 和 Recall 均保持在相对稳定的区间，说明模型对前景与背景的概率排序能力较强，且病灶检出性能未出现明显波动。在优化曲线解读上，如果训练损失持续下降而验证指标不再提升，通常意味着模型可能开始拟合训练集中的噪声；若训练损失与验证指标同步改善，则说明模型仍在学习具有泛化价值的特征。因此，本文并未单纯以训练损失作为

模型选择的依据，而是综合考虑验证集上的重叠指标、检出指标和概率排序指标进行判断。对于动脉瘤这类小目标任务，验证集 Recall 的稳定性尤为关键，因为较高的 AUC 并不一定能保证所有小病灶在固定阈值下都被正确检出。此外，训练过程还反映出小目标分割中“概率排序”与“空间成形”之间的区别。前者侧重模型能否给真实病灶体素赋予高于背景的概率，后者则关注阈值化后是否能形成连续、解剖合理的三维区域。若模型 AUC 较高但 Dice 较低，往往说明其概率排序能力已经较好，但阈值化后的分割结果可能存在边界收缩、离散假阳性或局部漏检等问题。因此，在训练后期，除了关注损失函数和 AUC 外，还需要结合固定阈值下的 Dice、Recall 以及可视化结果，综合判断模型是否具备稳定的空间分割能力。

4.4.2 分割结果与阈值分析

以较优验证轮次为代表，在阈值 0.5 下模型取得 AUC 为 0.97、Recall 为 0.56 的结果，表明模型在当前验证数据上已具备较好的体素级区分能力。以最终检查点作为报告对象，在相同阈值下 AUC 为 0.96、Recall 为 0.55，与较优轮次表现接近，说明训练后期模型并未出现明显退化，整体泛化性能并未显著降低。

需要指出的是，较高的 AUC 并不意味着分割结果已经在空间层面达到完全理想的状态。AUC 主要衡量不同阈值下模型对正负体素的整体排序质量，而最终二值掩膜的空间一致性还受到阈值选择、病灶体积、边界清晰度以及重建方式等因素影响。对于小目标病灶而言，即便模型在概率排序层面表现良好，不合适的阈值仍可能导致边界收缩、局部断裂或离散误检区域。因此，对分割模型的评价应结合 Dice、Recall 与典型病例可视化结果综合分析，而不宜依赖单一指标作出判断。

阈值扫描结果表明，随着分割阈值 τ_s 的提高，模型预测趋于保守，误检体素数量可能减少，但 Recall 往往同步下降；反之，当阈值降低时，模型更倾向于保留低置信度疑似前景，Recall 可能上升，但误检风险也会增加。其决策形式可写为

$$\hat{M}_{i,j,k}(\tau_s) = \mathbb{I}(P_{i,j,k} \geq \tau_s). \quad (4.14)$$

当 τ_s 增大时，满足条件的前景集合单调收缩，因此漏检概率通常增加。对于医学辅助分析场景而言，维持较高的病灶检出能力具有重要意义，但同时也需控制误检区域规模，以保证后续结构定量分析与临床展示的可解释性。

4.4.3 可视化分析与误差来源

从典型病例的可视化结果看，模型在多数病灶区域能够较完整地覆盖动脉瘤主体，并在局部边界上形成相对连续的响应。对于形态较规则、对比度较高的病灶，预测掩膜与人工标注具有较高一致性；而当病灶体积较小、边缘对比度不足、与载瘤血管过渡模糊或邻近高密度结构干扰明显时，模型可能出现局部漏检、边

界偏移或少量误检。

这类误差具有一定普遍性。一方面，小病灶在多次下采样过程中容易发生空间信息损失，即使通过跳跃连接进行细节补偿，仍可能难以完全恢复极细小结构边界；另一方面，CTA 中血管增强区域与动脉瘤前景在灰度分布上具有相似性，模型需要借助空间上下文与拓扑关系而非单纯强度差异进行判别。由此可见，后续若需进一步提升分割性能，可从更具针对性的前景采样、边界敏感损失设计、多尺度监督及稳健后处理策略等方面展开优化。

从误差分解角度看，分割误差可大致分为阈值误差、边界误差和结构误差三类。阈值误差主要源于概率输出与二值决策之间的不匹配；边界误差主要表现为预测轮廓相对于真实轮廓的局部偏移；结构误差则表现为病灶区域断裂、漏检或与邻近血管粘连。设预测概率为 P ，真实标签为 Y ，阈值化结果为 $\hat{M}(\tau_s)$ ，则不同阈值下的分割质量可表示为

$$S(\tau_s) = m(\hat{M}(\tau_s), Y), \quad (4.15)$$

其中 $m(\cdot)$ 表示任一分割评价指标。若 $S(\tau_s)$ 在较宽阈值区间内保持稳定，说明模型概率图具有较好的校准性与空间鲁棒性；若指标随阈值剧烈波动，则提示模型输出中存在较多低置信度或边界不确定区域。

对于动脉瘤分割而言，误差分析还应关注空间位置和解剖背景。病灶与载瘤血管交界处通常是最容易发生边界偏移的区域，原因在于二者在增强影像中具有相近灰度分布，且真实标注本身也可能受到观察者经验影响。邻近骨性结构、高密度伪影或血管分叉区域则可能诱发假阳性响应。上述现象说明，模型性能改进不能仅依赖更复杂的网络结构，还需要从数据表示、监督信号和评价方式上共同约束。

4.4.4 分割模型消融分析

为进一步分析模型性能提升的来源，本文从结构设计角度对分割模型进行了消融讨论。可将基础三维 Attention U-Net、引入 ASPP 的增强模型以及进一步加入三维坐标注意力的模型视为逐步增强的结构序列。基础模型主要依赖编码器—解码器结构和注意力门控完成病灶恢复；ASPP 模块通过多尺度空洞卷积扩大感受野，有助于增强模型对不同尺度病灶及其邻域上下文的刻画能力；三维坐标注意力则进一步引入方向感知的位置建模，对边界模糊、形态不规则或空间走向复杂的病灶具有潜在优势。

在现有实验结果中，增强模型相较于基础模型表现出更优的综合分割性能。在相同训练轮次条件下，ASPP-CA-UNet 的 Recall 达到 0.67，AUC 达到 0.96；与基础模型相比，其 Dice 系数提升约 20%，F1 值提升约 40%。此外，两类模型在绝大多数背景体素上均保持较高一致性，说明增强模型性能提升并非来源于对背景的

过度拟合，而更可能归因于对病灶区域表征能力的增强。为便于比较，表 4.2 对分割消融结果作了汇总。

表 4.2 分割模型消融结果比较

模型	Recall	AUC	Dice（相对变化）	F1（相对变化）
基础三维 Attention U-Net	0.56	0.97	基准水平	基准水平
Attention U-Net + ASPP + CA	0.67	0.96	+20%	+40%

需要说明的是，由于动脉瘤分割属于高度不平衡的体素级任务，背景体素占比远高于病灶体素，因此“整体像素一致性”往往会受到大量真阴性体素的主导，其解释价值相对有限。相比之下，Dice、Recall 与 F1 等更能体现病灶区域识别能力的指标，能够更加真实地反映模型在本任务中的性能差异。基于此，本文在消融分析中更强调增强结构对病灶区域识别质量的改善，而非单纯关注整体一致性指标。

ASPP 与坐标注意力的作用机制和增益来源有所不同。ASPP 通过不同空洞率的并行分支来扩大感受野，主要提升模型对不同尺度病灶及其周围血管背景的上下文理解能力；而坐标注意力则通过对空间方向信息的建模来强化位置感知，更有利于处理走向复杂或边界模糊的血管结构。如果只引入多尺度特征而缺乏位置约束，模型容易加强对背景血管的响应；反之，若仅加入位置注意力而缺少多尺度上下文，对形态变化较大的病灶适应性则可能不足。因此，这两类模块在理论上具有较好的互补性，联合使用能更有效地平衡小目标分割中的背景抑制与结构保持问题。

若用 S_0 表示基础模型性能，用 S_A 表示加入 ASPP 后的性能，用 S_{A+C} 表示同时加入 ASPP 与坐标注意力后的性能，则各模块的边际贡献可形式化表示为

$$\Delta_A = S_A - S_0, \quad (4.16)$$

$$\Delta_{C|A} = S_{A+C} - S_A. \quad (4.17)$$

其中 Δ_A 反映多尺度上下文增强的直接贡献， $\Delta_{C|A}$ 反映在已有多尺度表示基础上方向注意力带来的增量效果。若二者均为正，则说明两个模块对目标指标具有累积增益；若单独增益较弱但联合增益明显，则可能存在互补作用。本文实验结果显示，增强结构在 Dice 与 F1 上的相对提升更为明显，表明其主要改善的是前景区域的重叠质量与阳性预测可靠性，而不仅是概率排序能力。

4.5 破裂风险预测实验

4.5.1 实验目的与模型设置

破裂风险预测实验旨在评价多源表格特征对病例级破裂状态的判别能力，并比较交叉注意力模型与传统机器学习模型在中小规模医学数据条件下的表现。所

有模型均基于相同训练集、验证集与测试集划分进行评估，并在验证集上完成阈值选择，以保证不同模型之间具有统一的比较基础。

本文纳入比较的模型包括交叉注意力深度表格模型、随机森林、逻辑回归、支持向量机、 k 近邻以及融合模型。逻辑回归可视为线性可解释基线，随机森林代表非线性集成树模型，支持向量机与 k 近邻分别代表基于核映射与局部相似性判别的传统分类方法，而交叉注意力模型则代表通过字段交互学习高阶依赖关系的深度方法。融合模型进一步综合树模型与注意力模型输出，用于检验不同模型范式之间的互补性。

4. 5. 2 对比实验结果

风险预测模型测试集结果如表 4.3 所示。表中 Threshold 表示由验证集确定并固定用于测试集评估的分类阈值。

表 4.3 风险预测模型测试集对比结果

模型	Accuracy	Precision	Recall	F1	AUC	Threshold
Forest-Attention Ensemble	0.7944	0.6931	0.7778	0.7330	0.8568	0.350
Risk Cross-Attention	0.7852	0.6832	0.7667	0.7266	0.8546	0.325
Random Forest	0.7419	0.6182	0.7556	0.6800	0.8284	0.400
Logistic Regression	0.6895	0.5512	0.7778	0.6452	0.7342	0.450
KNN	0.5766	0.4576	0.9000	0.6067	0.6966	0.200
SVM-RBF	0.5565	0.4451	0.9000	0.5956	0.6732	0.300

从表 4.3 可以看出，Forest-Attention Ensemble 在测试集上取得最高的 F1 值 0.7330 与 AUC 值 0.8568，说明传统树模型与深度注意力模型在当前任务中具有一定互补优势。Risk Cross-Attention 模型取得 F1 值 0.7266 和 AUC 值 0.8546，其性能与最优融合模型非常接近，并明显优于逻辑回归、支持向量机及 k 近邻等传统单模型基线。这表明基于字段级交互的深度建模方式能够较有效地捕获临床变量与影像表型变量之间的非线性关联。

进一步分析可见，随机森林在 Accuracy、F1 和 AUC 等多项指标上均优于多个传统基线，体现出集成树模型在中小规模表格数据上的稳定性与适应性。相比之下的 KNN 与 SVM-RBF 模型虽然在 Recall 上达到 0.9000，表现出较强的阳性病例检出倾向，但其 Precision 分别仅为 0.4576 和 0.4451，同时 F1 与 AUC 均处于较低水平。这说明上述模型更倾向于将样本判定为高风险类别，在此虽略微提高了召回能力，但是却显著增加了误报率，从整体上而言并未取得超过随机森林或随机森林-注意力融合模型的结果。逻辑回归具有较强可解释性，但从其 AUC 仅为 0.7342 可见线性决策边界难以充分刻画当前多源特征中的复杂非线性关系。

从模型假设角度看，不同方法的差异可归纳为判别函数空间的差异。逻辑回归对应线性形式

$$\log \frac{\hat{p}}{1-\hat{p}} = \beta_0 + \sum_j \beta_j x_j, \quad (4.18)$$

其优势在于参数含义明确，但难以自动表达高阶非线性交互。随机森林通过多棵决策树的集成形成分段非线性判别函数，可较好处理变量间的条件分裂关系。交叉注意力模型则通过字段 token 之间的注意力权重学习全局交互，其判别函数可抽象为

$$\hat{p} = \sigma(F_\omega(e_1, e_2, \dots, e_{m+q})), \quad (4.19)$$

其中 $F_\omega(\cdot)$ 表示由多层注意力与非线性映射构成的可学习函数。该类模型具有更强表达能力，但对样本规模、正则化和数据噪声更敏感。因此，实验结果中深度模型与集成树模型表现接近，符合中小规模医学表格数据的一般规律。

4.5.3 阈值选择与不平衡分类讨论

风险预测实验中，各模型的最优阈值普遍低于或接近 0.5，这表明在类别不平衡条件下，默认判别阈值未必能够适配医学风险识别任务的实际需求。对于输出概率 $\hat{p}$ 而言，降低阈值会使更多病例被判定为高风险，进而提高 Recall，但也可能降低 Precision；提高阈值则会产生相反效果。因此，阈值选择本质上是在漏诊风险与误报代价之间进行权衡。

从临床辅助分析角度看，破裂风险预测通常更关注高风险病例的检出能力，因此相对其他属性而言，Recall 具有较高参考价值；但若 Precision 过低，则可能导致过多低风险病例被误判为高风险，从而增加后续检查、复核与干预负担。F1 值通过综合考察 Precision 与 Recall，为动脉瘤破裂风险预测的二分类任务提供了更平衡的评价方案。AUC 则从全阈值范围反映模型对阳性与阴性病例的排序能力，可用于模型间总体判别能力的比较。

进一步地，阈值选择可被视为代价敏感决策问题。若假阴性代价为 C_{FN} ，假阳性代价为 C_{FP} ，则在给定预测概率 $\hat{p}$ 时，将病例判定为阳性的期望代价为 $C_{FP}(1-\hat{p})$ ，判定为阴性的期望代价为 $C_{FN}\hat{p}$ 。当

$$C_{FP}(1-\hat{p}) < C_{FN}\hat{p} \quad (4.20)$$

时，选择阳性判定更为合理。由此可得理论阈值

$$\tau_c = \frac{C_{FP}}{C_{FP} + C_{FN}}. \quad (4.21)$$

当漏诊代价高于误报代价时， $C_{FN} > C_{FP}$ ，对应阈值 τ_c 将低于 0.5，这与实验中多个模型的最优阈值低于默认阈值的现象一致。该分析表明，阈值并非纯粹的技术参数，而反映了具体应用场景下对漏诊与误报的权衡。

4.5.4 风险模型结果讨论

综合各项指标来看，基于交叉注意力的深度表格模型在本次任务中表现出了较强的竞争力，但并未全面超越所有传统方法。其主要原因在于：一方面，交叉注意力机制能够显式捕捉异构字段间的复杂依赖关系，在处理多源医学表格数据时具有较好的表达能力；另一方面，在样本规模相对有限的情况下，传统集成学习模型通常表现出更好的稳健性和更低的过拟合风险。

因此，深度模型与传统模型之间并非简单的替代关系，而是在不同数据条件和评价目标下各有优势。在融合模型在本实验中取得了最优的综合性能的这一结果进一步验证了这一判断。由此表明，基于树模型的分裂规则与基于注意力机制的表示学习其实捕捉到了不同类型的判别模式，二者结合能在一定程度上缓解单一模型的偏差，从而提升整体分类效果。这也为后续研究探索更系统的模型融合策略提供了支持，从而进一步提高风险预测的稳定性和泛化能力。

从误差类型来看，假阴性和假阳性在风险预测任务中具有不同的临床意义。假阴性意味着高风险病例被低估，可能延误复查和干预时机；假阳性则意味着低风险病例被高估，可能会增加不必要的随访负担和临床资源消耗。因此，在该任务中不能单纯追求 Accuracy，而应根据具体临床场景权衡 Recall、Precision 和 F1 等指标的相对重要性。本实验中，部分模型通过降低阈值获得了较高的 Recall，但 Precision 明显下降，说明其对阳性类别的概率输出较为敏感，却缺乏足够的可靠性。相比之下，交叉注意力模型和融合模型在 Precision 与 Recall 之间取得了更为均衡的表现，综合评价指标也更高。

同时，当前结果也提示应谨慎理解深度表格模型的优势。在样本数量有限、变量噪声较高或阳性比例不足时，复杂模型可能学习到与训练分布相关但泛化能力有限的模式。因此，较高的测试集指标需要结合置信区间、重复划分或外部验证进一步确认。本文实验结果表明交叉注意力模型具备较好的风险判别潜力，但其临床稳定性仍需在更大规模数据和更严格验证条件下进一步评估。

4.6 结果综合讨论

综合分割和风险预测实验结果可以看出，本文方法在当前数据集上初步构建了从影像结构识别到病例风险估计的完整分析流程。分割模型在体素级 AUC 和 Recall 上表现稳定，表明其能够较好地地区分病灶与复杂血管背景；风险预测模型在 F1 和 AUC 上接近最优融合模型，显示交叉注意力机制在多源表格特征建模中具有较好的适用性。

从方法构成来看，分割任务通过注意力门控、ASPP 和三维坐标注意力分别实现了背景抑制、多尺度上下文聚合与方向位置建模，三者共同提升了模型对复杂血

管结构的表达能力。而在风险预测任务中，字段级嵌入与交叉注意力机制将传统的特征拼接转化为可学习的交互表示，使模型能够在病例层面捕捉临床变量、影像表型和形态特征之间的潜在依赖关系。

同时，实验也暴露了一些值得关注的问题。首先，医学影像数据的规模有限，标注成本高，单次数据划分结果容易受样本分布影响；其次，风险预测任务中的类别不平衡问题会显著影响阈值选择和指标解读；此外，深度表格模型在中小样本医学任务中并不总是稳定优于传统集成模型，合理的正则化、特征选择、概率校准以及外部验证仍非常必要。

4.7 系统闭环验证

为验证整体方法流程的完整性，本文将分割推理、特征提取与风险预测组织为端到端演示闭环。该闭环能够从输入影像出发，依次完成病灶概率图生成、二值掩膜输出、结构信息汇聚与破裂风险概率估计，并以可视化形式呈现关键结果。系统闭环验证的意义不在于替代临床诊断，而在于证明所提出的分割方法与风险建模方法可以在统一分析流程中协同运行，从而为后续临床可用性研究与系统化部署提供原型基础。

4.8 本章小结

本章从实验设计、评价指标、分割实验、风险预测对比、消融分析与结果讨论等方面，对本文方法进行了较为系统的实验性评价。结果表明，分割模型在当前验证数据上具有较好的体素级判别能力与病灶检出能力；风险预测模型能够有效利用多源表格特征，并在测试集上取得接近最优融合模型的综合表现。总体而言，本文方法在病灶识别与风险评估两个层面均达到了预期目标，但其稳健性，泛化能力的检测与提升仍有赖于更大规模、多中心的多轮重复实验的进一步验证与优化。

5 总结与展望

5.1 研究工作总结

本文围绕颅内动脉瘤智能分析问题，构建了由病灶分割与破裂风险预测组成的研究框架，并在统一实验流程下完成了方法设计、模型训练、结果评估与原型验证。研究工作的核心目标在于：一方面，利用三维医学影像分割方法实现对动脉瘤区域的精细识别与结构刻画；另一方面，结合病例层面的临床信息、影像表型信息及分割衍生结构特征，建立面向破裂风险评估的分类模型，从而形成由解剖结构分析到病例级风险判别的完整技术链条。

在方法层面，本文针对 CTA 图像中动脉瘤体积小、背景复杂和类别不平衡等问题，构建了以三维 Attention U-Net 为主干，辅以 APSS 与坐标注意力的分割模型来提升病灶表征能力。针对风险预测任务中多维表格特征之间存在复杂且非线性关联的问题，本文进一步设计了基于字段嵌入与交叉注意力的风险模型，以增强对变量间高阶依赖关系的刻画能力。通过上述设计，本文实现了影像空间表征与病例级决策建模的有机衔接，形成了较为完整的研究流程。整体而言，本文工作不仅关注单一模型性能提升，也强调从输入影像、病灶结构、病例特征到风险输出之间的信息流动、变换关系，不仅使分割模型的结果能够服务于后续风险模型分析，也在工程上解耦模型实现，从而提高项目的效果与可靠性。

5.2 主要研究结论

基于实验结果，可以得到以下几点主要结论。

第一，在动脉瘤分割任务中，所构建的三维分割模型在验证阶段表现出较高的体系级判别能力和较稳定的阳性检出能力，说明该模型能够较好地复杂 CTA 背景中识别目标病灶区域。注意力门控机制有助于抑制无关背景响应，多尺度上下文聚合与方向敏感注意力则进一步增强了模型对小目标、复杂形态和空间走向特征的表达能力。

第二，在破裂风险预测任务中，基于交叉注意力的深度表格模型能够有效学习临床变量、影像表型变量与结构化形态特征之间的交互关系。测试结果表明，该模型在 F1 与 AUC 等核心指标上接近最优融合模型，并整体优于多种传统单模型基线，说明通过字段级表示学习和注意力交互机制能够提升多源医学表格数据的风险判别能力。

第三，融合模型取得了最高的综合性能，这表明深度注意力模型与传统集成学习模型在当前任务中具有一定互补性。前者更擅长挖掘连续隐空间中的复杂关联模式，后者则在中小样本场景下表现出较强稳健性。因此，在医学风险预测问题

中，单一模型范式未必能够完全占优，合理结合不同方法的优势可能是提升性能的重要方向。

第四，从整体流程角度看，本文实现了由病灶分割到风险评估的闭环验证，说明基于影像结构识别结果构建病例级风险表征具有可行性。这一结果表明，分割任务不仅可以作为独立的病灶检测工具，也可以为后续风险判别提供具有解剖学意义的表征，从而增强模型的医学使用价值。

第五，从方法论角度看，本文实验进一步说明医学人工智能研究需要同时关注模型性能、评价口径和任务目标之间的一致性。在分割任务中，体素级 AUC 较高并不必然意味着二值掩膜在边界和结构上完全可靠；在风险预测任务中，Accuracy 较高也不必然代表高风险病例能够被充分检出。因此，本文采用多指标联合评价方式，对模型的排序能力、阳性识别能力和综合分类能力进行分别讨论。这一分析方式有助于避免单一指标解释所带来的片面性。

第六，本文研究表明，分割结果向风险预测阶段传递的不仅是病灶位置，还包括体积、形态、边界规则性等具有医学含义的结构信息。该类信息能够作为临床和影像表型变量的补充，使风险模型在病例级判别中获得更明确的解剖依据。因此，影像分割与风险预测之间存在较强的任务关联，合理组织二者的输入输出关系是构建完整智能分析流程的重要基础。

5.3 研究不足

尽管本文在方法构建与实验验证方面取得了一定结果，但仍存在若干不足，主要体现在以下几个方面。

首先，数据规模与来源范围仍然有限。医学影像与临床数据的采集和标注成本较高，导致当前研究更多是在相对有限且数据特征（灰度，对比度等）较为单一的数据条件下开展。样本量不足与样本的缺点不仅会限制深度模型对复杂模式的充分学习，也可能使实验结果对特定数据划分较为敏感，从而影响统计稳健性与泛化能力。

其次，外部验证仍然是值得优化的部分。本文实验主要基于既定数据划分展开，虽然能够反映模型在当前数据分布下的有效性，但尚不能充分说明模型在不同条件、不同扫描设备、不同人群临床信息和不同标注标准下的稳定泛化能力。对于医学人工智能模型而言，外部独立验证是评价模型真实应用价值的重要环节。

再次，风险预测任务仍然面临类别不平衡带来的挑战。虽然本文通过类别加权、阈值搜索和注意力交互机制在一定程度上缓解了相关问题，但在小样本条件下，深度表格模型对特征噪声、超参数设置和初始化随机性的敏感性仍然不可忽视。这也是为何传统树模型在当前实验中依然具有较强竞争力的原因之一。

最后，本文的结果解释仍主要集中于性能指标层面，对模型内部决策依据的临床可解释分析仍有待加强。例如，不同临床变量、形态变量和影像表型变量在风险预测中的相对贡献尚需通过更系统的可解释性方法进行量化；分割结果中的局部误差如何进一步影响后续风险建模，也值得深入研究。

此外，本文采用两阶段流程能够提高项目的工程化水平与训练效率，但也意味着分割误差可能在后续风险预测中产生传递误差，进而影响风险预测模型输出的准确性。当分割掩膜存在边界收缩、局部漏检或误检时，体积、形态规则性等特征变量可能随之发生偏移，进而影响风险估计。当前研究尚未对这种误差传播进行系统建模，也未充分评估不同分割质量水平对风险预测稳定性的影响。因此，如何量化上游结构识别不确定性并减少其对下游风险预测任务的影响，是后续需要进一步解决的问题。

5.4 未来工作展望

针对上述不足，未来研究可从以下几个方向进一步推进。

第一，扩大数据规模并开展多中心验证。后续工作可进一步引入来自不同中心、不同设备和不同扫描协议的数据，以增强样本多样性，并通过外部测试集、交叉验证和置信区间分析更严格地评估模型稳定性与泛化性能。这不仅有助于提升方法的可信度，也更符合医学人工智能从学术研究向临床应用推广转化的基本要求。

第二，进一步优化分割模型的结构表达与监督机制。未来可探索更强的三维上下文建模策略、边界敏感损失函数、层级监督机制以及面向小目标的困难样本挖掘方法，以提升病灶边界恢复能力和对复杂解剖背景的鲁棒性。同时，还可研究如何将血管拓扑先验或形态约束显式引入模型训练，以增强分割结果的结构合理性。

第三，深化风险预测中的特征融合与可解释性建模。后续可结合更丰富的形态学定量指标、时序随访信息或多模态影像表征，构建更全面的病例级特征空间；同时可引入注意力可视化、特征归因、概率校准和不确定性估计等方法，从而提高风险预测结果的可解释性、可信度与临床可读性。

第四，探索分割与风险预测的联合优化机制。本文采用的是两阶段分析框架，具有结构清晰、实现简洁的优点，但分割与风险建模之间仍可能存在更深层次的协同关系。未来可以考虑建立端到端联合学习框架，使影像空间特征、病灶结构表征与风险标签在部分统一模型中协同优化，从而进一步增强任务间的信息传递效率与特征捕获能力，进而提升模型的整体性能。

第五，开展误差传播与不确定性分析。后续研究可在分割概率图、形态特征和风险预测概率之间建立更明确的统计联系，评估分割阈值、病灶边界扰动和特征测

量误差对最终风险输出的影响。同时，可引入贝叶斯近似、模型集成或置信区间估计等方法刻画预测不确定性，使模型在输出风险结果时能够同步提供可信度信息。

第六，推动方法从实验验证走向更规范的应用研究。未来工作可进一步完善推理效率评估、结果一致性分析、临床工作流适配和人机协同机制设计，并结合前瞻性研究验证模型在真实场景中的辅助价值。只有在算法性能、可解释性、稳定性和使用流程等多个层面均得到充分论证，相关研究成果才可能具备更高的临床转化潜力。

5.5 结束语

总体而言，本文围绕颅内动脉瘤的智能分析任务，系统开展了从三维病灶分割到破裂风险预测的完整研究，并在方法设计和实验验证上取得了阶段性成果。研究表明，将多尺度医学影像特征与多源临床信息进行有效融合，能够为动脉瘤的自动识别和风险评估提供一条具有实证支持的技术路径。尽管本研究在数据规模、外部验证以及可解释性等方面仍存在一定局限，但其提出的方法框架和实验结果为后续的深入研究奠定了基础，也可为医学人工智能在该领域的进一步优化和临床应用探索提供参考。

参 考 文 献

- [1] Chen S, Xu Z, Zhao X, et al. Coarse-to-fine guided salient object detection for automatic cerebral aneurysm identification[J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 3052-3063.
- [2] Ou Y, Hua K L, Cheng X, et al. Automatic diagnosis of 3D cerebral vascular images using deep learning[J]. IEEE Access, 2022, 10: 34281-34291.
- [3] Greving J P, Wermer M J H, Brown R D J, et al. Development of the PHASES score for prediction of risk of rupture of intracranial aneurysms[J]. The Lancet Neurology, 2014, 13(1): 59-66.
- [4] Backes D, Rinkel G J E, Laban K G, et al. ELAPSS score for prediction of risk of growth of unruptured intracranial aneurysms[J]. Neurology, 2017, 88(17): 1600-1606.
- [5] Morita A, Kirino T, Hashi K, et al. The natural course of unruptured cerebral aneurysms in a japanese cohort[J]. The New England Journal of Medicine, 2012, 366(26): 2474-2482.
- [6] Thompson B G, Brown R D J, Amin-Hanjani S, et al. Guidelines for the management of patients with unruptured intracranial aneurysms: A guideline for healthcare professionals from the american heart association/american stroke association[J]. Stroke, 2015, 46(8): 2368-2400.
- [7] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2015: 234-241.
- [8] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 3431-3440.
- [9] Cicek O, Abdulkadir A, Lienkamp S S, et al. 3D u-net: learning dense volumetric segmentation from sparse annotation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2016: 424-432.
- [10] Milletari F, Navab N, Ahmadi S A. V-net: Fully convolutional neural networks for volumetric medical image segmentation[C]//2016 Fourth International Conference on 3D Vision (3DV). IEEE, 2016: 565-571.
- [11] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-net: Learning where to look for the pancreas [A]. 2018.
- [12] Isensee F, Jaeger P F, Kohl S A A, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature Methods, 2021, 18(2): 203-211.
- [13] Kamnitsas K, Ledig C, Newcombe V F J, et al. Efficient multi-scale 3D CNN with fully connected CRF for accurate brain lesion segmentation[J]. Medical Image Analysis, 2017, 36: 61-78.

- [14] Chen J, Zhuang J, Shen Y, et al. StrokeNet: A multi-task neural network for stroke outcome prediction[J]. *NeuroImage: Clinical*, 2022, 33: 102927.
- [15] Xiong L, Wang Y, Chen H, et al. Multimodal deep learning for predicting ischemic stroke outcome [J]. *IEEE Transactions on Medical Imaging*, 2025, 44(2): 523-534.
- [16] Huang X, Khetan A, Cvitkovic M, et al. Tabtransformer: Tabular data modeling using contextual embeddings[A]. 2020.
- [17] Gorishniy Y, Rubachev I, Khrulkov V, et al. Revisiting deep learning models for tabular data[C]// *Advances in Neural Information Processing Systems*. 2021.
- [18] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]// *Advances in Neural Information Processing Systems*. 2017: 5998-6008.
- [19] Litjens G, Kooi T, Bejnordi B E, et al. A survey on deep learning in medical image analysis[J]. *Medical Image Analysis*, 2017, 42: 60-88.
- [20] Shen D, Wu G, Suk H I. Deep learning in medical image analysis[J]. *Annual Review of Biomedical Engineering*, 2017, 19: 221-248.
- [21] Maier A, Syben C, Lasser T, et al. A gentle introduction to deep learning in medical image processing[J]. *Zeitschrift f"ur Medizinische Physik*, 2019, 29(2): 86-101.
- [22] Cicek O, Abdulkadir A, Lienkamp S, et al. 3d u-net: Learning dense volumetric segmentation from sparse annotation[C]// *MICCAI*. 2016: 424-432.
- [23] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. Unet++: A nested u-net architecture for medical image segmentation[J]. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, 2018: 3-11.
- [24] Sudre C H, Li W, Vercauteren T, et al. Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations[J]. *DLMIA/ML-CDS@MICCAI*, 2017: 240-248.
- [25] Salehi S S M, Erdogmus D, Gholipour A. Tversky loss function for image segmentation using 3d fully convolutional deep networks[J]. *MLMI@MICCAI*, 2017: 379-387.
- [26] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]// *Proceedings of the IEEE International Conference on Computer Vision*. 2017: 2980-2988.
- [27] Breiman L. Random forests[J]. *Machine Learning*, 2001, 45(1): 5-32.
- [28] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[J]. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016: 785-794.
- [29] Hastie T, Tibshirani R, Friedman J. The elements of statistical learning[J]. *Springer Series in Statistics*, 2009.
- [30] Saito T, Rehmsmeier M. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets[J]. *PLOS ONE*, 2015, 10(3): e0118432.

- [31] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[J]. International Conference on Machine Learning, 2017: 1321-1330.
- [32] Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning[J]. Proceedings of the 22nd International Conference on Machine Learning, 2005: 625-632.
- [33] Chicco D, Jurman G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation[J]. BMC Genomics, 2020, 21(1): 6.

附录 A：关键配置与复现实验步骤

A.1 项目结构说明

本项目采用模块化目录布局，便于维护、扩展与复现实验：

- core/：配置数据结构、YAML 加载与随机种子管理；
- data/：医学影像补丁数据管线与风险表格数据处理；
- model/：分割模型（aneurysm）与风险模型（risk）；
- script/：训练、评估与对比实验入口脚本；
- ui/：FastAPI 服务与推理接口封装；
- utils/：日志、路径与通用工具函数。

A.2 环境配置建议

Python ≥ 3.8

torch $\geq 1.9.0$

monai $\geq 0.7.0$

numpy $\geq 1.21.0$

pandas $\geq 1.3.0$

scikit-learn $\geq 1.0.0$

SimpleITK $\geq 2.1.0$

tensorboard

tqdm

fastapi

uvicorn

建议安装后执行 `python -c "import torch; print(torch.cuda.is_available())"` 验证 GPU 可用性。

A.3 分割任务复现实验步骤

1. 准备 NIfTI 影像与标签数据，确保命名规则与配置文件一致；
2. 复制并修改配置文件（如 config/host.yaml），填写训练/验证路径；
3. 运行训练命令：`python script/train_split.py -config path/to/your.yaml`；
4. 通过 TensorBoard 观察收敛曲线并记录最优检查点；
5. 运行评估脚本导出指标与可视化结果。

A. 4 风险预测复现实验步骤

1. 准备包含标签列与病例 ID 的表格数据（Excel/CSV）；
2. 在配置中启用风险模块并设置特征与训练参数；
3. 运行训练命令：`python script/train_risk.py --config path/to/your.yaml`；
4. 查看输出 `risk_report.json` 并记录 F1、AUC 与最优阈值；
5. 可选运行 `compare_risk_models.py` 与传统模型进行统一对比。

A. 5 关键参数说明

- 分割参数：`train.epochs`、`train.patch_size`、`train.learning_rate`、`eval_interval`；
- 风险参数：`risk.hidden_dim`、`risk.num_heads`、`risk.num_layers`、`risk.threshold_search_steps`；
- 数据参数：`data.patch_sampling_mode`、`risk.feature_select_method`。

A. 6 常见问题与排查建议

- **显存不足**：减小 `patch_size` 或减少每例补丁数量；
- **训练不收敛**：检查学习率、标签映射及数据归一化流程；
- **指标异常波动**：固定随机种子并核查数据划分一致性；
- **LaTeX 目录报错**：清理 `.aux/.toc/.out` 后重新编译。

致 谢

本论文的完成离不开各位老师、同学和家人的支持与帮助。

首先，我要感谢我的指导教师，感谢您在论文选题、研究方法和实验设计等方面的悉心指导，您的严谨治学态度和渊博的专业知识使我受益匪浅。

其次，我要感谢实验室的各位同学，在项目开发过程中，大家互相交流、共同探讨，营造了良好的学术氛围。特别感谢师兄师姐们在技术实现方面给予的宝贵经验和建议。

再次，我要感谢我的家人，感谢你们一直以来的理解、支持和鼓励，让我能够安心完成学业。

最后，感谢所有为本研究提供数据和技术支持的机构和个人。正是有了各方的支持与帮助，本研究才能够顺利完成。

原创性声明

郑重声明：所呈交的论文（设计）《_____》，是本人在导师的指导下，独立进行研究取得的成果。除论文（设计）中已经标注引用的内容外，本论文（设计）不包含其他人或集体已经发表或撰写过的作品成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

论文（设计）作者签名：_____

日期：_____

使用授权书

本论文（设计）作者完全了解学校有关保留、使用论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）复印件和电子版，允许论文（设计）被查阅和借阅。本人授权重庆大学将本论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制方式保存和汇编本论文（设计）。

本论文（设计）属于：

保 密 ☐ 在_____年解密后适用本授权书

不保密 ☐

论文（设计）作者签名：_____

指导教师签名：_____

日期：_____

日期：_____